

최종 연구 방향

RACE-PFN: Residual Advantage-Guided Context Experts for Robust Intrusion Detection

우리 연구의 중심은 **XGBoost**보다 단일 정적 분류 성능을 조금 높이는 것이 아닙니다.

핵심 질문은 다음과 같습니다.

고정된 단일 IDS가 취약한 **long-tail imbalance**, **temporal/data drift**, 그리고 학습 **support** 밖의 **traffic**에 대해, **Tabular Foundation Model**의 **in-context adaptability**를 이용해 필요한 상황에만 **specialist context**를 호출함으로써 더 안정적으로 대응할 수 있는가?

최종 알고리즘은 다음처럼 정의하는 것이 가장 좋습니다.

하나의 frozen Tabular Foundation Model을 global predictor로 사용한다.
Global이 잘 처리하지 못하는 데이터 영역을 자동으로 찾아 context experts를 구성한다.
Test sample마다 모든 expert를 실행하지 않고, global보다 성능을 개선할 가능성이 있는 expert 하나만 선택적으로 호출한다.
실제로 expert가 global보다 유리할 것으로 판단될 때만 global prediction을 수정한다.

이렇게 하면 현재 exp21에서 확인한 장점을 유지하면서 다음 휴리스틱을 제거할 수 있습니다.

- 사람이 Flood, BF-Bot, Tail 그룹을 직접 지정
- 오분류가 benign이 많다는 이유로 benign-return 규칙 추가
- energy score가 가장 큰 expert를 무조건 선택
- 모든 sample에 모든 expert를 실행
- expert membership을 routing target으로 사용

1. 논문의 문제 정의

학습 데이터는 다음과 같습니다.

$$D_s = \{(x_i, y_i)\}_{i=1}^N, \quad y_i \in \{1, \dots, C\}$$

실제 IDS deployment에서는 세 가지 문제가 발생합니다.

1.1 Long-tail class imbalance

$$P(Y = c_{\text{tail}}) \ll P(Y = c_{\text{head}})$$

Benign과 몇몇 공격이 대부분을 차지하고, web attack이나 infiltration 같은 클래스는 극히 적습니다.

1.2 Temporal/data drift

$$P_t(X | Y) \neq P_s(X | Y)$$

같은 공격 label이라도 시간, 네트워크 환경, 공격 도구, flow behavior가 바뀌면 feature distribution이 달라집니다.

1.3 Unsupported/OOD traffic

$$x_t \notin \text{Support}(D_s)$$

학습한 어떤 traffic regime과도 충분히 유사하지 않은 새로운 공격 또는 새로운 정상 traffic이 들어올 수 있습니다.

다만 논문의 주 기여는 **long-tail**과 **temporal drift**로 잡는 것이 좋습니다. OOD는 별도의 calibrated abstention extension으로 넣고, 성능이 충분히 확보될 때만 정식 기여로 올리는 편이 안전합니다.

2. 왜 Tabular Foundation Model인가

TabPFN과 같은 Tabular Foundation Model은 task-specific parameter training보다 **labeled context**를 통한 **in-context prediction**을 수행합니다. 특히 TabPFN-3의 multiclass decoder는 test row와 context rows 간 attention을 이용해 class probability를 만드는 retrieval-based decoder이므로, context를 바꾸면 같은 frozen model이 서로 다른 local evidence에 기반한 prediction을 만들 수 있습니다. TabPFN-3는 최대 100만 행 규모까지 확장되었지만, context 구성과 inference cost는 여전히 중요한 설계 요소입니다.  [arXiv +1](#)

우리 연구는 이 특성을 이용합니다.

$$\text{Expert} = \text{Frozen Tabular FM} + \text{Specialized Context}$$

따라서 여러 개의 대형 expert network를 따로 학습하지 않습니다.


3. 제안 알고리즘 전체 구조

알고리즘 이름은 일단 다음이 적절합니다.

RACE-PFN

Residual Advantage-Guided Context Experts for Tabular Foundation Models

최종 inference 구조는 다음과 같습니다.



핵심은 **global-first, sparse, safe override**입니다.

4. 학습 데이터 분할

현재 반복해서 사용한 CIC2018의 미래 400만 행은 이제 final test가 아니라 development set으로 취급해야 합니다.

학습 pool 내부도 다음처럼 분리해야 합니다.

$$D = D_{\text{context}} \cup D_{\text{mine}} \cup D_{\text{router}} \cup D_{\text{val}} \cup D_{\text{test}}$$

Split	용도
D_{context}	Global 및 expert context 생성
D_{mine}	Global의 어려운 영역 발견
D_{router}	Proposal router와 verifier 학습

Split	용도
D_{val}	Expert 수, context 크기, 비용 계수 선택
D_{test}	알고리즘 고정 후 단 한 번 평가

시간순 데이터에서는 이 분할도 chronological order를 유지해야 합니다.

Gate 학습용 sample이나 validation sample이 expert context에 들어가면 안 됩니다. 그렇지 않으면 router가 해당 sample을 context에서 직접 본 상태가 되어 advantage estimation이 과대평가될 수 있습니다.

5. Step 1 — Global Context Predictor

전체 분포를 대표하는 context를 만듭니다.

$$C_0 = \text{RepresentativeContext}(D_{\text{context}}, B_0)$$

Global prediction은 다음과 같습니다.

$$p_0(y \mid x) = F_\theta(C_0, x)$$

- F_θ : frozen Tabular Foundation Model
- B_0 : global context budget
- p_0 : 전체 C -class posterior

Global model은 항상 먼저 실행하며 다음 역할을 합니다.

1. 일반적인 benign/head traffic 처리
2. 모든 expert가 도움이 되지 않을 때의 기본 prediction
3. Expert의 상대적 이득을 계산하는 기준선

Global context는 random sampling 하나에만 의존하지 말고, class-aware medoid나 k-center 등 재현 가능한 대표 sample 선택을 사용하는 것이 좋습니다. 현재 실험에서 context 추첨에 따라 global macro-F1이 크게 변했기 때문에, context-seed sensitivity를 줄이는 것 자체가 중요한 설계 목표입니다.

6. Step 2 — Global이 어려워하는 영역 자동 발견

기존 exp21에서는 사람이 attack family를 보고 expert 그룹을 지정했습니다.

최종 방법에서는 expert를 class 이름이 아니라 global residual region으로 정의합니다.

6.1 Cross-fitted global residual

D_{mine} 의 각 sample에 대해 global loss를 계산합니다.

$$r_i = \omega_{y_i} [-\log p_0(y_i | x_i)]$$

여기서 ω_{y_i} 는 class-balanced weight입니다.

예:

$$\omega_c = \frac{1}{n_c^\gamma}$$

이 weight가 필요한 이유는 단순합니다.

- Benign sample 수가 압도적으로 많음
- 일반 loss만 사용하면 residual clustering도 benign 중심이 됨
- rare class에서 발생한 중요한 오류가 묻힘

따라서 r_i 는 단순 오분류 여부가 아니라:

Global이 이 sample을 얼마나 어렵게 처리했는지, 그리고 그 오류가 long-tail 관점에서 얼마나 중요한지

를 나타냅니다.

6.2 Residual representation

각 sample을 representation space에 매핑합니다.

$$z_i = \phi(x_i)$$

초기 구현에서는 다음 순서가 좋습니다.

1. Robust scaling
2. PCA 또는 learned low-dimensional projection
3. 이후 TabPFN embedding과 비교

TabPFN embedding을 곧바로 사용하면 foundation model에 더 밀접하지만 계산량과 안정성을 먼저 확인해야 합니다.

6.3 Weighted residual clustering

Global residual이 큰 sample이 cluster 형성에 더 큰 영향을 주도록 합니다.

$$\min_{\mu_1, \dots, \mu_K} \sum_i r_i \min_k \|z_i - \mu_k\|^2$$

이 결과로 K 개의 residual regime을 얻습니다.

예를 들어 결과적으로 다음과 비슷한 cluster가 나올 수 있습니다.

```
Cluster A: high-rate flooding traffic
Cluster B: web-like rare traffic
Cluster C: low-rate infiltration-like traffic
Cluster D: temporally shifted benign/attack boundary
```

하지만 알고리즘이 이 이름이나 공격 family를 미리 알지는 않습니다.

이것이 수동 Flood/BF-Bot/Tail 그룹과 가장 중요한 차이입니다.

7. Step 3 — Residual Context Experts 생성

각 residual cluster R_k 에 대해 하나의 context를 만듭니다.

7.1 Common anchor

모든 expert가 전체 class space를 유지하도록 공통 anchor를 넣습니다.

$$A = \text{RepresentativeAnchor}(D_{\text{context}})$$

Anchor에는 모든 class의 대표 sample을 포함합니다.

이 역할은 현재 benign-return보다 일반적입니다.

- Expert가 자기 residual region만 보고 모든 입력을 특정 공격으로 강제 분류하는 것을 방지
- 다른 known class도 구분 가능
- 모든 expert가 같은 C -class posterior 출력

7.2 Residual-specific block

Cluster k 와 가깝고 residual loss가 큰 sample을 선택합니다.

$$s_{ik} = r_i \exp \left(-\frac{\|z_i - \mu_k\|^2}{\tau_c} \right)$$

상위 sample들을 선택합니다.

$$S_k = \text{TopB}(s_{ik})$$

최종 context는:

$$C_k = A \cup S_k$$

입니다.

Expert prediction:

$$p_k(y | x) = F_\theta(C_k, x)$$

모든 expert는 전체 class를 출력합니다.

```
Expert 1 → 전체 7 classes
Expert 2 → 전체 7 classes
Expert 3 → 전체 7 classes
...
```

따라서 다음 규칙은 필요 없습니다.

- Tail expert는 Web/Inf만 출력
- Tail이 아니면 benign
- Benign이면 global return
- non-owned class면 return

Expert가 전체 label space를 직접 예측합니다.

8. Step 4 — Expert의 실제 Advantage 정의

Router에게 “이 sample은 어느 expert 소속인가?”를 가르치지 않습니다.

다음 질문을 가르칩니다.

Expert k 를 호출하고 그 prediction을 사용하면 Global보다 실제 loss가 줄어드는가?

Router training sample (x_i, y_i) 에 대해:

$$L_{i0} = \ell_{\text{bal}}(p_0(x_i), y_i)$$

$$L_{ik} = \ell_{\text{bal}}(p_k(x_i), y_i)$$

Expert advantage는:

$$\Delta_{ik} = L_{i0} - L_{ik} - \lambda_{\text{cost}} c_k$$

입니다.

- $\Delta_{ik} > 0$: Expert가 Global보다 유리
- $\Delta_{ik} \leq 0$: Global 유지가 더 적절
- c_k : expert inference cost
- λ_{cost} : 성능과 overhead 간 trade-off

비용 항을 넣는 이유는 작은 성능 차이를 위해 매번 expensive expert를 호출하지 않도록 하기 위해서입니다.

예시

실제 label이 web attack이고:

```
Global:
Benign 0.80
Web    0.10

Expert 2:
Benign 0.05
Web    0.90
```

이면:

$$\Delta_{i2} \gg 0$$

입니다.

반대로 실제 benign이고:

```
Global:
Benign 0.99

Expert 2:
Web    0.65
Benign 0.30
```

이면:

$$\Delta_{i2} < 0$$

입니다.

이 advantage target은 현재 ownership target보다 직접적입니다.

9. Step 5 — Sparse Proposal Router

모든 test sample에 모든 expert를 실행하면 overhead가 너무 큼니다.

따라서 expert를 실행하기 전에 작은 proposal router가 먼저 판단합니다.

9.1 Router 입력

Expert prediction은 아직 계산하지 않았으므로, cheap feature만 사용합니다.

$$h_{\text{pre}}(x) = [p_0(x), H(p_0), m_0, z(x), d_1(x), \dots, d_K(x), a_0(x)]$$

여기서:

Feature	의미
p_0	Global class probability
$H(p_0)$	Global entropy
m_0	Global top-1/top-2 margin
$z(x)$	sample representation
$d_k(x)$	residual cluster k 와의 거리
$a_0(x)$	Global context affinity

Proposal router 출력:

$$g_\phi(h_{\text{pre}}(x)) \rightarrow \{\text{NO EXPERT}, 1, \dots, K\}$$

학습 target은 offline에서 계산한 actual advantage로 만듭니다.

$$k_i^* = \begin{cases} \arg \max_k \Delta_{ik}, & \max_k \Delta_{ik} > 0 \\ \text{NO EXPERT}, & \max_k \Delta_{ik} \leq 0 \end{cases}$$

즉:

- Global이 이미 최선이면 NO EXPERT
- 실제로 Global을 개선하는 expert가 있으면 그 expert
- Class ownership과 무관

10. Step 6 — Top-1 Expert만 실행

Proposal router가 expert k^* 를 제안한 경우에만 해당 expert를 실행합니다.

$$p_{k^*}(y | x) = F_\theta(C_{k^*}, x)$$

다른 expert는 실행하지 않습니다.

평균 expert activation 비율을 ρ 라고 하면:

$$C_{\text{total}} \approx C_{\text{global}} + \rho C_{\text{expert}} + C_{\text{router}}$$

예를 들어 $\rho = 0.15$ 이면 평균 호출 수는:

1.15

회 정도입니다.

Dense 4-expert 방식의 5회 호출보다 훨씬 실용적입니다.

Context cache를 유지하면 추가 expert의 비용도 더 줄일 수 있습니다.

11. Step 7 — Advantage Verifier

Proposal router는 cheap feature만 보기 때문에 틀릴 수 있습니다.

따라서 expert prediction을 얻은 뒤 한 번 더 확인합니다.

Verifier 입력:

$$h_{\text{post}}(x, k) = [p_0, p_k, p_k - p_0, H(p_0), H(p_k), m_0, m_k, a_0, a_k, d_k]$$

여기서 a_k 에는 TabPFN context-query affinity statistics를 사용할 수 있습니다.

TabPFN-3는 retrieval decoder를 사용하므로 context-row affinity는 sample이 해당 context와 얼마나 잘 맞는지를 나타내는 유용한 신호가 될 수 있습니다.  ar...

Shared verifier는 actual advantage를 예측합니다.

$$\widehat{\Delta}_k(x) = v_\psi(h_{\text{post}}(x, k))$$

학습 loss는 Huber loss 또는 pairwise ranking loss로 시작하는 것이 좋습니다.

$$\mathcal{L}_{\text{adv}} = \text{Huber}(\widehat{\Delta}_k, \Delta_k)$$

Expert별 별도 score head가 아니라 shared verifier를 사용해야 score scale이 비교 가능합니다.

12. Step 8 — 최종 결정

최종 decision은 매우 단순합니다.

$$p_{\text{final}}(y | x) = \begin{cases} p_{k^*}(y | x), & \widehat{\Delta}_{k^*}(x) > 0 \\ p_0(y | x), & \text{otherwise} \end{cases}$$

즉:

Expert가 Global보다 실제로 좋을 것으로 예상됨
→ Expert 사용

그렇지 않음
Global 유지

0이라는 기준은 임의 threshold가 아닙니다.

$$\widehat{\Delta} > 0$$

은 정의상 “예상 loss reduction이 양수”라는 의미입니다.

Soft mixture는 ablation으로 평가할 수 있습니다.

$$p_{\text{final}} = (1 - w)p_0 + wp_k$$

하지만 첫 구현은 hard selective override가 더 단순하고 해석하기 쉽습니다.

13. Temporal drift에 대한 adaptation

고정된 residual expert bank만으로도 학습 중 관찰된 여러 traffic regime에 대응할 수 있습니다.

그러나 실제 drift에 더 직접적으로 적응하려면 **backbone retraining** 대신 **context refresh**를 사용합니다.

Context refresh mode

새로운 시점에서 analyst가 확인한 소량의 labeled flow가 들어오면:

1. Global residual 계산
2. 기존 residual cluster에 할당하거나 새로운 cluster 생성
3. 해당 expert context의 일부를 최근 sample로 교체
4. Proposal router와 verifier만 가볍게 업데이트
5. Frozen Tabular FM은 그대로 유지

즉 adaptation 비용은:

XGBoost/신경망 전체 재학습

이 아니라:

Context memory 갱신
+
소형 router 갱신

입니다.

논문에서는 label-free drift adaptation까지 한 번에 주장하지 않는 편이 좋습니다. 대신 다음을 보여주는 것이 명확합니다.

적은 수의 verified recent samples만으로 context를 갱신했을 때, full model retraining보다 훨씬 작은 비용으로 temporal performance를 회복할 수 있다.

Drift-Resilient TabPFN은 temporal shift를 synthetic drifting priors에 포함해 foundation model 자체를 사전학습하는 접근입니다. 우리 방법은 별도의 drift-specific foundation model을 만들지 않고, 일반 frozen TFM 위에서 residual context와 lightweight routing을 갱신한다는 점에서 방향이 다릅니다.  ar...

14. OOD/Unknown 확장

OOD는 메인 알고리즘과 분리해 다음처럼 추가합니다.

Global과 선택 가능한 모든 expert가 낮은 support를 보이고:

$$\max_k a_k(x) < \eta_a$$

Global entropy도 높고:

$$H(p_0(x)) > \eta_H$$

어떤 expert도 positive advantage를 제공하지 못하면:

$$\max_k \widehat{\Delta}_k(x) \leq 0$$

해당 sample을:

Unsupported / Abstain / Unknown candidate

로 보냅니다.

Threshold는 test에서 고르지 않고, ID validation set의 support score quantile이나 conformal calibration으로 설정해야 합니다.

첫 논문에서 OOD는 다음 수준으로 두는 것이 좋습니다.

Support-aware abstention extension

다음 결과가 충분히 나올 때만 핵심 contribution으로 승격합니다.

- far-OOD뿐 아니라 near-OOD에서도 개선
- known-class F1 보존
- 낮은 FPR@95TPR
- 여러 dataset에서 재현

15. 각 현실 문제를 어떻게 해결하는가

현실 문제	제안 방법의 대응
Long-tail imbalance	class-balanced residual mining으로 rare failure가 expert 구성에 반영
Majority-dominated context	residual-specific contexts가 minority/local evidence를 강화
Temporal/data drift	여러 residual regimes 및 context refresh로 적응
잘못된 expert routing	Global 대비 positive advantage일 때만 override
Benign false-positive 증폭	Global이 기본 prediction이고 harmful override를 verifier가 차단
Context sampling sensitivity	deterministic residual context와 multiple-seed evaluation
Inference overhead	Global-first, top-1 sparse expert activation
OOD/unsupported traffic	low-support + no-positive-advantage 기반 abstention

16. 현재 실험이 이 방향에 제공하는 근거

현재 exp19–21은 최종 알고리즘 자체는 아니지만 중요한 preliminary evidence입니다.

확인된 것

1. Context specialization이 실제로 존재함

- Flood context가 DDoS에서 Global을 보완
- Tail context가 Web/Infiltration recall을 크게 높임
- 올바른 expert에 들어간 후 조건부 분류는 매우 강함

2. Affinity와 probability가 서로 다른 정보를 가짐

- exp21 affinity signal은 benign/web 분리에 강함
- exp20 probability signal은 infiltration activation에 강함

최종 verifier에서 두 신호를 함께 사용하는 근거가 됩니다.

3. Safe fallback이 중요함

Benign background를 추가했을 때 성능이 크게 회복된 것은 다음을 보여줍니다.

Extreme imbalance에서는 routing accuracy보다 harmful override를 방지하는 구조가 더 중요할 수 있다.

최종 방법은 이를 특정한 benign-return 규칙이 아니라 **global-default selective override**로 일 반화합니다.

4. Dense expert inference는 비효율적임

현재 모든 expert를 병렬 실행하는 구조는 TabPFN 비용을 고려하면 확장성이 낮습니다.

따라서 sparse top-1 호출이 필요합니다.

17. 핵심 연구 기여

논문 contribution은 네 가지로 압축하는 것이 좋습니다.

Contribution 1 — Residual-Aware Context Experts

Global Tabular Foundation Model의 class-balanced residual loss를 이용해 어려운 데이 터 영역을 자동 발견하고, 해당 영역을 강조하는 context experts를 생성한다.

사람이 attack family나 head/tail grouping을 지정하지 않습니다.

Contribution 2 — Counterfactual Advantage Routing

Expert membership이나 cluster proximity가 아니라, 각 expert가 Global 대비 얼마나 prediction loss를 줄일 것인지를 routing target으로 사용한다.

$$\Delta_k = L_{\text{global}} - L_{\text{expert},k}$$

이것이 가장 중요한 기술적 기여입니다.

Contribution 3 — Sparse Global-Safe Activation

대부분의 sample은 Global TFM 하나로 처리하고, positive advantage가 예상되는 sample 에 대해서만 top-1 specialist를 호출한다. Expert 실행 후에도 advantage가 양수일 때만 Global prediction을 수정한다.

성능, 안전성, 계산 효율을 동시에 다룹니다.

Contribution 4 — Robust IDS Evaluation

Static IID 성능만 비교하지 않고, long-tail severity, test-prior shift, temporal drift, context refresh, OOD-like unsupported traffic에서 성능 저하와 복원 능력을 평가한다.

18. 기존 연구와의 차별성

MixturePFN은 전체 데이터를 cluster로 나누고 cluster별 specialized ICL expert를 fine-tune한 뒤 test sample을 해당 cluster expert로 routing합니다. 우리 방법은 전체 데이터 density가 아니라 **Global의 residual failure region**으로 context expert를 구성하고, cluster membership이 아니라 **Global 대비 expected advantage**를 routing 기준으로 사용하며, 도움이 되는 expert가 없으면 **NO EXPERT**로 Global을 유지합니다. [ICLR Proceedi...](#)

DistPFN은 context의 class prior가 TabPFN prediction에 주는 영향을 test-time posterior adjustment로 보정합니다. 이는 label-prior shift에 대한 probability correction이며, residual context construction이나 sparse expert routing은 다루지 않습니다. DistPFN은 중요한 baseline이며 필요하면 expert probability calibration 모듈로도 평가할 수 있습니다. [ar...](#)

SADE는 서로 다른 test class distributions에 특화된 parameter experts를 학습하고 self-supervised하게 aggregation합니다. 우리 방법은 separately trained parameter experts가 아니라 같은 frozen TFM을 서로 다른 context로 condition하며, test-distribution simulation보다 sample별 Global-relative advantage에 기반해 sparse routing합니다. [NeurIPS Proce...](#)

Drift-Resilient TabPFN은 temporal shift를 반영한 synthetic prior로 별도의 PFN을 사전학습합니다. RACE-PFN은 일반 frozen TabPFN 위에서 context memory와 router만 갱신하는 post-hoc adaptation입니다. [ar...](#)

따라서 논문의 차별화 문장은 다음이 적절합니다.

Existing context-mixture methods route queries according to cluster membership or proximity. RACE-PFN instead constructs experts from the residual regions of a global foundation model and activates them only when they are expected to provide positive counterfactual utility over the global prediction.

19. 반드시 보여줘야 할 실험

19.1 Standard/IID guardrail

목적:

Robustness를 얻기 위해 일반 성능을 지나치게 희생하지 않는가?

평가:

- Macro-F1
- Weighted-F1
- Head F1
- Tail F1

- Macro-AUPRC

여기서 XGBoost는 strong static baseline입니다.

반드시 IID에서 XGBoost를 이겨야 하는 것은 아니지만, 크게 뒤처지면 안 됩니다.

19.2 Long-tail stress test

학습 imbalance factor를 통제합니다.

$$IF = \frac{n_{\max}}{n_{\min}} \in \{10, 50, 100, 500\}$$

보여줘야 할 것:

- imbalance가 심해질수록 Global/XGB의 tail F1 감소
- 제안 방법의 감소폭이 더 작음
- Head F1은 유지
- Macro-AUPRC 개선

가장 중요한 그래프:

x축: Imbalance factor
y축: Tail F1 / Macro-F1

19.3 Test class-prior shift

Test distribution을 다음처럼 구성합니다.

- Natural
- Balanced
- Head-heavy
- Tail-heavy 또는 inverse long-tail

SADE는 unknown test class distribution을 다루고, DistPFN은 TabPFN label shift를 직접 보정하므로 핵심 baseline입니다. [arXiv +1](#)

보여줘야 할 것:

$$\text{Performance degradation}_{\text{ours}} < \text{Performance degradation}_{\text{baseline}}$$

19.4 Temporal/data drift

Global chronological split을 사용합니다.

Train: 과거
Test-1: 가까운 미래
Test-2: 중간 미래
Test-3: 먼 미래

중요 지표:

- 각 시점 Macro-F1
- Tail F1
- degradation slope
- temporal average performance
- calibration 변화

가장 좋은 결과는 다음 형태입니다.

IID에서는 XGB와 비슷
시간이 멀어질수록 XGB/Global은 빠르게 감소
제안 방법은 더 완만하게 감소

19.5 Context refresh experiment

새 시점에서 verified labels를 제한적으로 제공합니다.

$$B_{\text{update}} \in \{0, 50, 200, 1000\}$$

비교:

- XGB no retraining
- XGB full retraining
- Global TabPFN
- Global TabPFN context replacement
- RACE-PFN context refresh
- Drift-Resilient TabPFN

보여줘야 할 것:

적은 label과 낮은 업데이트 비용으로 성능을 얼마나 회복하는가?

그래프:

x축: New verified samples / update budget
y축: Temporal test Macro-F1

19.6 OOD/unsupported traffic — 보조 실험

두 설정을 분리해야 합니다.

Far-OOD

attack family 전체를 제거하고 test에서 unknown으로 사용.

Near-OOD

같은 family의 subtype 하나만 제거.

평가:

- AUROC
- AUPRC
- FPR@95TPR
- Known-class Macro-F1
- Coverage-risk curve

Far-OOD만 잘 잡고 near-OOD가 안 되면 강한 OOD contribution으로 주장하면 안 됩니다.

20. Baseline 구성

Static classifiers

- XGBoost
- Class-weighted XGBoost
- LightGBM
- CatBoost
- Focal/class-balanced neural classifier

Tabular Foundation Models

- Global TabPFN-3
- Balanced-context TabPFN
- Multiple random contexts
- DistPFN / DistPFN-T
- MixturePFN
- Nearest/local-context PFN
- Drift-Resilient TabPFN

Router/ensemble baselines

- Uniform context ensemble
- Nearest-cluster hard routing

- Ownership classifier
- Affinity argmax, 즉 exp21
- Probability CE selector, 즉 exp20
- Dense soft router
- Proposed sparse advantage router
- Oracle best expert per sample

21. 핵심 ablation

Ablation	확인할 내용
Random experts vs residual experts	Residual mining 필요성
Manual family grouping vs automatic clustering	휴리스틱 제거 효과
Ownership target vs advantage target	핵심 routing objective 검증
Probability only	exp20 신호
Affinity only	exp21 신호
Probability + affinity	신호 상보성
Proposal router only	1차 routing 효과
Proposal + verifier	harmful override 차단 효과
Dense all-expert	상한과 계산 비용
Sparse top-1	최종 방법
No cost penalty	과도한 expert 호출 여부
No class-balanced residual	rare failure가 묻히는지
No context refresh	drift adaptation 효과
K와 context size 변화	성능-비용 trade-off

22. 반드시 보고해야 할 routing 지표

단순 expert routing accuracy는 중요하지 않습니다.

다음을 측정해야 합니다.

Helpful override

$$\text{Global wrong} \wedge \text{Final correct}$$

Harmful override

$$\text{Global correct} \wedge \text{Final wrong}$$

Net correction

$$N_{\text{helpful}} - N_{\text{harmful}}$$

Override precision

$$\frac{N_{\text{helpful}}}{N_{\text{helpful}} + N_{\text{harmful}}}$$

Positive-advantage proposal recall

실제로 positive advantage인 sample 중 proposal router가 expert를 호출한 비율.

Oracle gap recovery

$$\frac{F_{\text{proposed}} - F_{\text{global}}}{F_{\text{oracle}} - F_{\text{global}}}$$

이 지표들이 있어야 “왜 좋아졌는가”를 설명할 수 있습니다.

23. 효율성에서 보여줄 것

평균 specialist activation rate:

$$\rho = \frac{\text{\#expert calls}}{\text{\#test samples}}$$

평균 TFM 호출 수:

$$1 + \rho$$

반드시 보고할 항목:

- Global-only inference time
- Dense expert ensemble time
- Sparse RACE-PFN time

- expert activation rate
- throughput
- peak GPU memory
- context cache 크기

목표 그림:

모델	평균 TFM 호출	상대 비용
Global	1.0	1.0×
Dense 4-expert	5.0	3–5× 이상
Sparse RACE-PFN	1.1–1.3	약 1.1–1.5×

정확한 비용은 실제 cache와 batch 처리 방식에 따라 측정해야 합니다.

24. 데이터셋 구성

IDS method paper

최소 다음 네 개가 필요합니다.

- CICIDS2017
- CSE-CIC-IDS2018
- ToN-IoT
- BoT-IoT 또는 UNSW-NB15

Dataset마다 attack taxonomy가 다르므로 automatic residual expert construction이 특히 중요합니다.

General Tabular FM paper

방법론 기여를 더 강하게 만들려면 일반 imbalanced tabular dataset도 추가해야 합니다.

- OpenML/TabZilla 계열 10–30개
- natural imbalance
- controlled long-tail split
- label-prior shift

IDS에서만 동작하면 IDS-specific framework로 평가될 가능성이 높습니다. 여러 일반 tabular datasets에서도 작동하면 TFM inference method로 올라갑니다.

25. 논문의 성공 기준

단일 CIC2018 best run보다 다음 조건이 중요합니다.

성능

- Global TabPFN 대비 여러 seed에서 일관된 Macro-F1/Tail-F1 개선
- IID/head 성능을 거의 유지
- Long-tail 및 temporal shift가 심해질수록 baseline 대비 성능 우위 증가
- XGBoost보다 static IID 성능이 조금 낮더라도 shift 환경에서 명확한 robustness 우위

안정성

- 5–10개 context seed의 mean $\pm$ std
- Global보다 context-sampling variance 감소
- 다른 IDS datasets에서 동일 경향

Routing

- Helpful override가 harmful override보다 충분히 많음
- Verifier가 harmful override를 유의미하게 감소
- Oracle gap 일부를 실질적으로 회수

효율

- Average specialist activation이 과도하지 않음
- Dense context ensemble보다 명확히 낮은 비용
- Full retraining보다 context refresh 비용이 작음

내부 목표로는 다음 정도가 합리적입니다.

IID 성능:

strong static baseline과 큰 차이가 나지 않음

Long-tail / drift:

baseline 대비 명확한 Macro-F1 및 Tail-F1 개선

Expert activation:

대부분의 sample은 Global로 종료

Context update:

적은 verified samples로 drift 성능 회복

OOD:

near-OOD까지 유의미하게 개선될 때만 main claim

26. 실제 구현 순서

Phase 0 — 평가 정리

- 현재 exp21을 heuristic baseline으로 freeze
- 현재 400만 행을 development set으로 재정의
- untouched final temporal/cross-dataset test 준비
- context row indices와 seed 저장
- source-only 학습과 external auxiliary 사용 분리

Phase 1 — Context complementarity 확인

자동 residual contexts를 만든 후 offline에서 모든 expert를 실행합니다.

먼저 확인할 질문:

Sample마다 Global보다 나은 expert가 실제로 존재하는가?

Oracle best expert가 Global보다 충분히 좋아야 router 연구의 의미가 있습니다.

Phase 2 — Automatic residual experts

- class-balanced global residual 계산
- residual clustering
- common anchor + residual block 생성
- 모든 expert full-class output
- context size와 K ablation

Phase 3 — Proposal router

- Global probability, entropy, margin
- cluster distance
- Global affinity

만 사용하여:

NO EXPERT / Expert 1 / ... / Expert K

를 예측합니다.

Phase 4 — Advantage verifier

- Global + selected expert probability
- affinity
- entropy
- margin
- actual advantage target

을 사용합니다.

Phase 5 — Sparse final system

Global
→ proposal
→ top-1 expert
→ verifier
→ expert override 또는 Global 유지

Phase 6 — Robustness evaluation

- long-tail severity
- temporal drift
- test-prior shift
- context refresh
- context-seed robustness

Phase 7 — OOD extension

Main method가 안정된 뒤 추가합니다.

27. 논문 중심 서사

논문은 다음 흐름으로 쓰면 됩니다.

문제

Static IDS classifiers are optimized for a fixed training distribution, whereas deployed traffic is long-tailed and evolves over time.

TFM의 기회와 한계

Tabular Foundation Models can adapt predictions through labeled contexts, but a single global context is dominated by frequent traffic and cannot represent all rare or shifted regimes.

기존 context mixture의 한계

Existing methods route samples based on cluster membership or proximity, although geometric membership does not necessarily mean that an expert will outperform a strong global predictor.

제안

We automatically construct residual context experts from regions where the global TFM exhibits high class-balanced loss, and estimate the counterfactual advantage of each expert relative to the global prediction.

안전성과 효율

A cheap proposal router activates at most one specialist, and a verifier accepts its prediction only when the estimated advantage is positive. Otherwise, the global prediction is preserved.

평가

The method is evaluated not only on static classification, but under increasing imbalance, test-prior shift, temporal drift, limited context-refresh budgets, and unsupported traffic.

28. 논문에서 주장해야 할 문장

We do not aim to replace a strong static classifier solely by improving IID accuracy. Instead, we develop a context-adaptive tabular foundation model that selectively specializes when the global predictor becomes unreliable under long-tailed and evolving traffic distributions.

Our key insight is that expert membership is not equivalent to expert utility. We therefore route samples according to the predicted counterfactual advantage of a context expert over the global foundation-model prediction.

The resulting framework preserves the global predictor as a safe default, invokes at most one specialist when useful, and adapts to new regimes by updating contexts rather than retraining the foundation model.

최종 요약

우리가 최종적으로 제안해야 할 것은 단순한 `TabPFN MoE IDS` 가 아닙니다.

Global Tabular FM이 어려워하는 residual traffic regimes를 자동 발견해 context experts를 구성하고, 각 expert가 Global보다 실제로 유리할 것으로 예상되는 sample에 대해서만 top-1 expert를 희소하게 호출하는 adaptive IDS framework

입니다.

핵심 기여는 다음 네 개입니다.

- 1. Automatic residual context expert construction**
- 2. Global-relative counterfactual advantage routing**
- 3. Sparse top-1 activation with exact global fallback**
- 4. Long-tail and temporal-drift robustness through context adaptation**

XGBoost와의 static 성능은 반드시 지켜야 할 guardrail입니다. 그러나 논문의 승부는:

imbalance와 temporal shift가 커질수록 성능이 얼마나 덜 무너지는가,
소량의 최신 context로 얼마나 빠르게 회복하는가,
그리고 이 과정에서 harmful false-positive를 얼마나 억제하는가

에서 내는 것이 가장 적절합니다.