# 사전학습 모델의 활용과 적은 사례로 새 공격을 반영하는 방식

TabPFN 과 v3 작동 원리 · 가중치 fine-tuning
누적 context · 고정 버퍼 · 갱신 없는 추론

랩미팅 2026 년 10 월 15 일

# 0. 연구 관점 · 고정된 F1 경쟁에서 변화에 대응하는 IDS 로

**기존 관점**

고정된 공격 클래스의 closed-set F1 향상에 집중
ICD 의 정적 벤치마크에서도 tuned XGB 의 강세
수치 경쟁에서 실제 갱신 능력의 평가로 전환 필요

**운영의 요구**

네트워크 환경 · 공격 양상이 바뀌는 상황
기존 분포에서 높은 F1 만으로 갱신 후 탐지 능력 설명 곤란

**연구의 전환**

TabPFN 을 기본 모델로 채택하고 새 사례를 context 로 반영
적은 라벨과 낮은 갱신 비용에서 필요한 탐지 품질 확보

Ma et al., In-Context Data Distillation with TabPFN, ICLR 2024 ME-FoMo Workshop

# TabPFN · 표 데이터의 예측 규칙을 사전학습한 모델

## 사전학습

다양한 합성 표 데이터
일부 라벨을 가린 예측 과제
공통 가중치 θ 학습

→

## 새 IDS 데이터

알려진 특징 Xc 와 라벨 yc
예측 대상의 특징 xq
정답 yq 는 입력에서 제외

→

## In-context learning

사례의 관계를 이용한 추론
현재 데이터에 따른 예측
기본 동작에서 θ 고정

$$p\theta(yq \mid xq, Xc, yc)$$

Prior Labs, TabPFN-3: Technical Report, 2026 · §2

# Context 와 query · 모델에 전달되는 두 종류의 행

| 구분 | Flow 특징 1 | Flow 특징 2 | 공격 라벨 | 역할 |
|---|---|---|---|---|
| Context | 관측값 | 관측값 | Benign | 정상 사례 제공 |
| Context | 관측값 | 관측값 | 공격 A | 기존 공격 사례 제공 |
| Context | 관측값 | 관측값 | 공격 B | 신규 라벨 반영 시 추가 |
| Query | 관측값 | 관측값 | 모델에 미제공 | 정상 · 공격 확률 예측 |

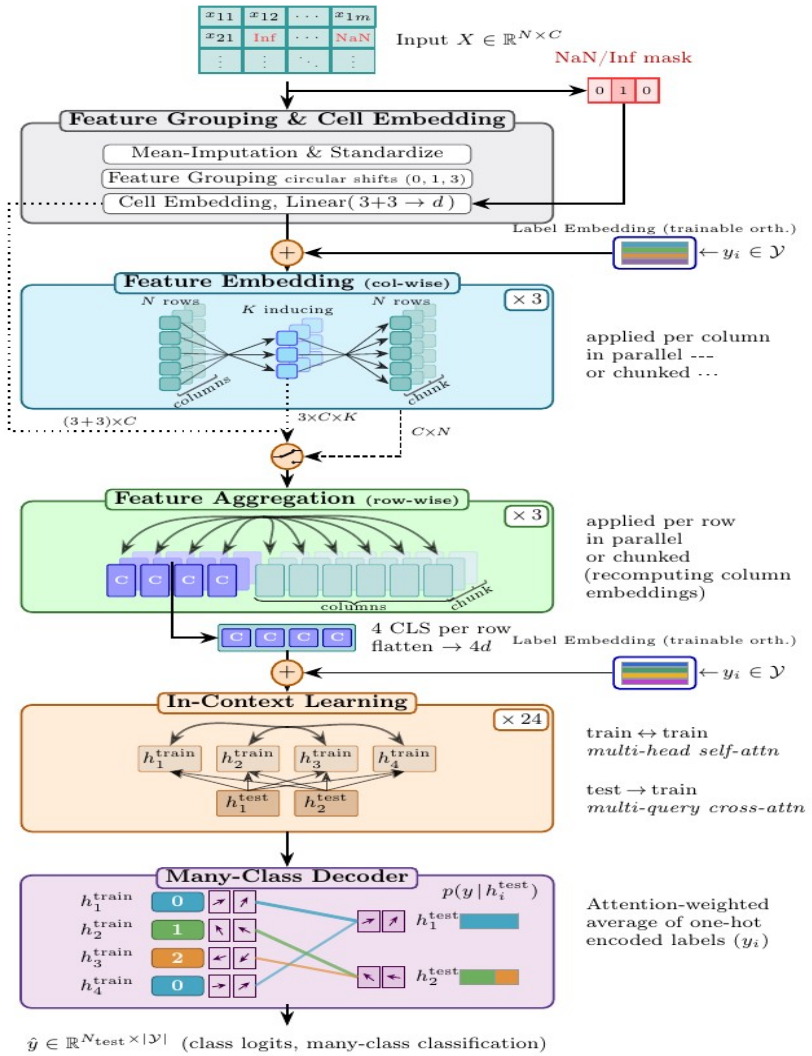
같은 query 도 context 의 구성 · 규모에 따라 예측 변화
라벨 없는 query 를 추가하는 것과 라벨된 context 를 추가하는 것의 구분

# 현재 실험의 TabPFN v3 설정

| 항목 | 실제 사용 설정 |
| --- | --- |
| 모델 / 라이브러리 | TabPFN-v3 multiclass / tabpfn 8.2.0 |
| 입력 | 두 데이터셋의 정제 Flow 특징 46 개 |
| 모델 파라미터 | 53,153,144 개 · 공통 사전학습 가중치 |
| 앙상블 | 서로 다른 전처리 · 순열의 estimator 4 개 |
| Context 처리 | fit_with_cache · 캐시 CPU 저장 |
| 체크포인트 설정 | ICL block 24 개 · 특징 통합 CLS token 4 개 |

실제 checkpoint config 와 실행 코드 확인 · v3 원문 Appendix C 와 대조

# v3 구조 · 열의 분포에서 행 단위 표현으로




TabPFN-3 · Figure 5 · 원문 PDF 6 쪽

## ① 입력 표현 · Feature grouping & cell embedding

특징 3 개와 결측 표시를 묶어 128 차원 표현으로 변환
Context 행에 알려진 라벨의 embedding 추가
Query 에는 정답 라벨을 넣지 않고 특징만 제공

## ② 열별 분포 · Feature embedding

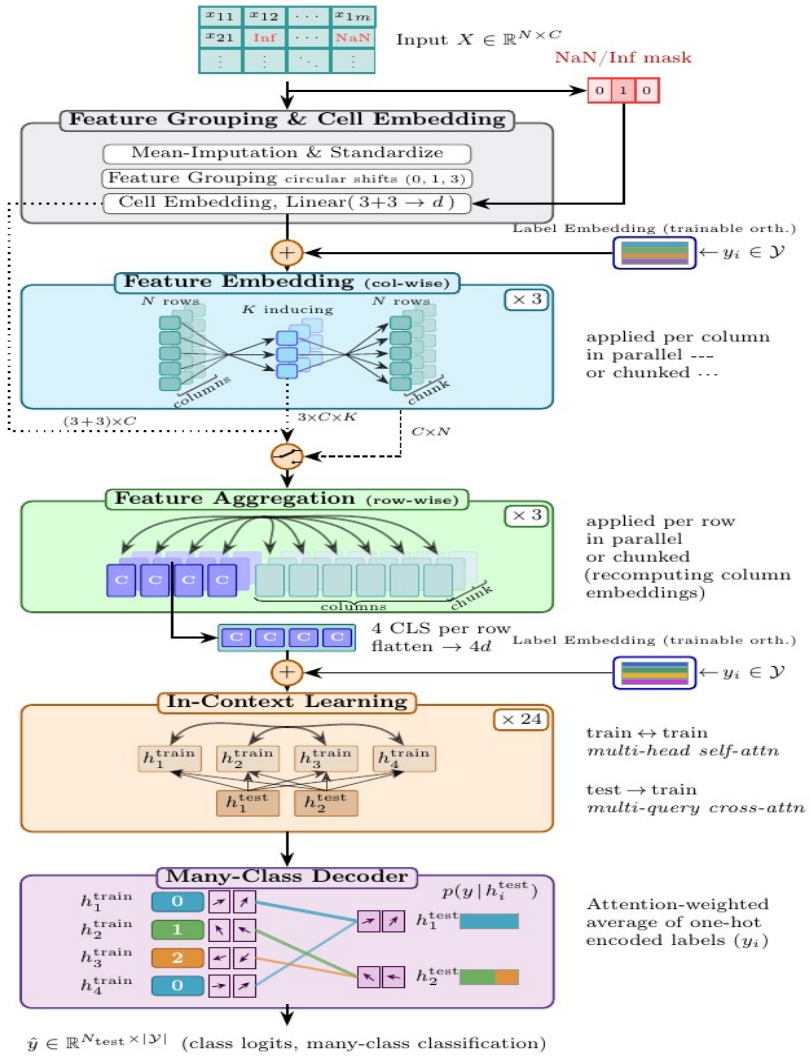
특징 하나의 값들을 128 개 inducing point 로 요약
분포를 요약하는 학습된 보조 표현과 attention 수행
3 개 block 을 통해 현재 context 의 분포 정보 반영

## ③ 행별 통합 · Feature aggregation

한 행 안의 특징들이 attention 으로 정보 교환
행을 요약하는 CLS token 4 개에 특징 관계 통합
4 × 128 차원을 이어 행별 512 차원 표현 생성

**열의 정보를 먼저 통합한 뒤 행 사이의 관계를 추론**

# v3 구조 · context 관계와 클래스 확률의 계산




TabPFN-3 · Figure 5 · 원문 PDF 6 쪽

## ④ 사례 사이의 추론 · In-context learning

Context 의 행 표현에 라벨 표현을 추가

Context ↔ context 관계와 query → context 참조

24 개 block 에서 조건부 예측에 필요한 표현 계산

Query 끼리의 정답 공유나 가중치 최적화 없음

## ⑤ 라벨별 확률 · Many-class decoder

Query 표현과 context 표현의 관련도를 attention 으로 계산

각 context 라벨의 one-hot 벡터를 관련도에 따라 가중합

같은 클래스의 근거를 모아 클래스별 확률 산출

새 클래스 사례 추가 시 출력 라벨에 포함

현재 checkpoint 의 클래스 상한 160 개

신규 라벨이 없는 context 에서 새 공격 이름의 출력 불가

**새 클래스의 라벨 사례를 context 에 넣어 출력 클래스에 반영**

# fit 과 predict · context 캐시의 생성과 재사용

### fit(Xc, yc)

전처리와 라벨 대응 구성
Context 측 표현 ·KV 계산
추론용 상태와 캐시 저장

→

### predict(Xq)

Query 전처리
저장된 context 상태 참조
확률 계산 · 앙상블 결합

→

### 새 context 의 fit

변경된 사례로 상태 재구성
1014 는 누적 전체 재처리
기존 사전학습 가중치 유지

**실제 확인 : 1,000 개 → 1,020 개 fit 후**
**53,153,144 개 파라미터의 SHA-256 동일**

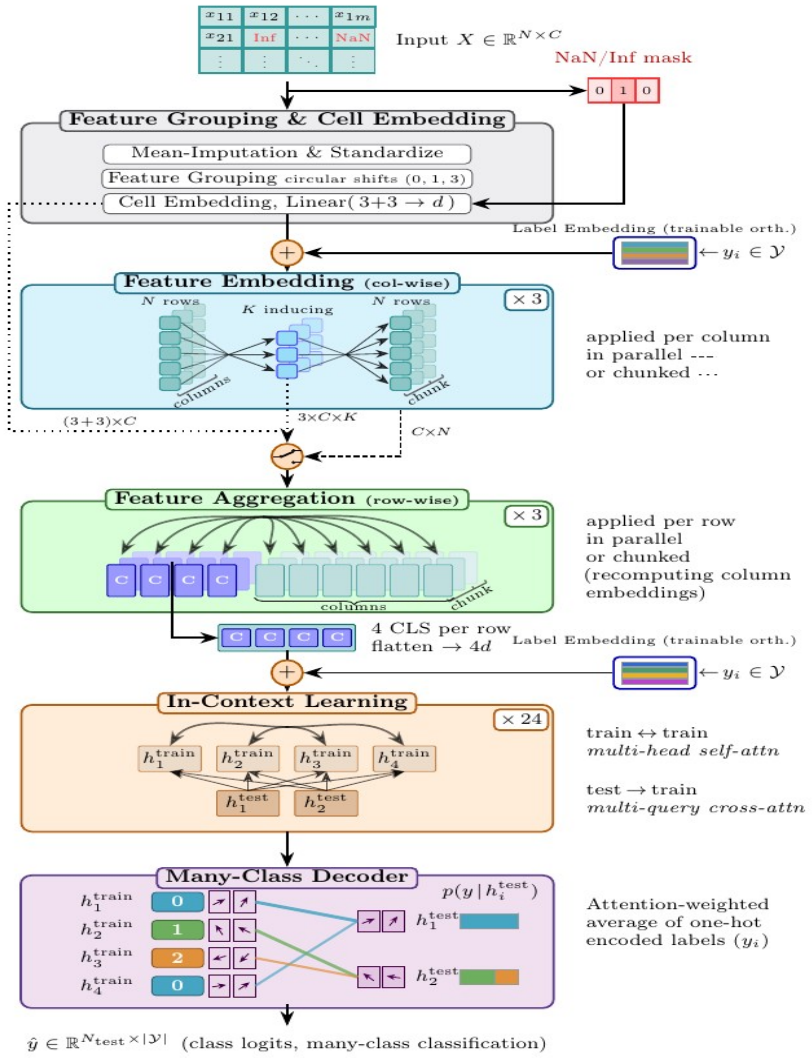
# 데이터 적응의 세 방식과 학습 대상

| 방식 | 변경 대상 | 역전파 | 추론 시 필요한 것 |
|---|---|---|---|
| Context 갱신 | 라벨된 사례의 구성 | 없음 | 사전학습 θ + 현재 context |
| Context 최적화 | Context 의 특징값 | 입력 특징으로 전파 | 고정 θ + 최적화된 context |
| 가중치 fine-tuning | 모델 파라미터 θ | 모델 파라미터로 전파 | 갱신된 θ + 현재 context |

1014 단일 TabPFN: 첫 번째 방식 · LoCalPFN: 별도의 미세조정 비교군

**Context 갱신과 가중치 fine-tuning 은 서로 다른 적응 연산**

# v3 가중치 fine-tuning · 학습 절차




TabPFN-3 · Figure 5 · 원문 PDF 6 쪽

## ① 학습용 context/query 과제 구성

Train 을 context 와 query 로 분할, 예시 비율 80% / 20%

Forward 입력 : context 특징 · 라벨 + query 특징

Query 의 정답은 숨겼다가 loss 계산에만 사용

## ② Query loss 의 역전파와 가중치 갱신

L = −Σq log pθ(yq | xq, context)

출력부터 decoder·ICL·embedding 의 θ 로 gradient 전파

loss.backward() 와 AdamW.step() 으로 θ 갱신

## ③ Validation 선택과 갱신된 모델의 추론

별도 validation 의 log loss 등으로 checkpoint 선택

갱신된 θ 에 라벨 context 를 다시 제공한 뒤 추론

새 query 에는 정답 미제공 · test 는 최종 평가에만 사용

붉은 선 : 모델 파라미터로의 역전파 · 공식 fine-tuning 구현 기준

**Query 정답의 손실로 θ 갱신 · 미세조정 이후에도 context 를 사용**

# 가중치  fine-tuning 의 실제 설정 항목

| 설정 | 역할 |
| --- | --- |
| 사용  checkpoint | 기존  v3 multiclass  가중치를 명시적으로 지정 |
| 학습률 ·epoch· 조기 종료 | 갱신 크기와 최적화 비용 제어 |
| Context + query  크기 | 한 학습 과제의  GPU  메모리와 사례 수 제어 |
| Query  비율 | 손실 계산에 사용할 학습 행의 비율 |
| 학습 · 검증 · 추론  estimator  수 | 품질 · 메모리 · 비용의 비교 조건 고정 |
| Validation 과  test | Checkpoint  선택과 최종 평가의 역할 분리 |

# 신규 사례만 사용하는 갱신의 의미

## Context 갱신

신규 라벨 사례를 context 에 추가
기존 사례를 누적하거나 일부 교체
기존 모델 파라미터의 재학습 없음
추가 · 삭제 이후 캐시 재구성 비용 측정

## 신규 사례 중심의 가중치 학습

신규 query 에 대한 손실로 θ 갱신
기존 클래스 context 의 보존 필요
기존 · 신규 클래스의 별도 유지 평가
기본 fit 과 구분한 추가 학습 설계

1,000 개와 20 개는 정책을 설명하기 위한 예시

# 갱신 비용 · 새 모델을 사용할 수 있는 시점까지

| 비용 | 포함 연산 | 보고 기준 |
| --- | --- | --- |
| 초기 구축 | Checkpoint 적재 · 초기 context 또는 모델 준비 | 초 |
| 후속 갱신 | 삭제 · 선택 · 전처리 · 캐시 재구성 또는 재학습 | 회당 초 · 누적 초 |
| 추론 | 실제 배치의 전처리 · 모델 계산 · 후처리 | 초 · µs/ 행 |
| 자원 · 정보량 | GPU·RAM peak, context 수 , 공개 라벨 수 | GiB · 행 |

**총 연산 시간 = 초기 구축 + 후속 갱신 합계 + 평가한 Q 개 행의 추론**

# 평가 시나리오 · 라벨된 공격 클래스의 순차 도입

클래스 도입 순서 기준 · 실제 수집 시각의 재생과 구분

| 데이터 | 초기 | 도입 1 | 도입 2 | 도입 3 | 도입 4 이후 |
|---|---|---|---|---|---|
| CIC2018 | Benign<br>Brute force · DoS | DDoS | Web attacks | Infiltration | Bot |
| ToN | Benign<br>Scanning · DoS | Injection · DDoS | Password | XSS | Ransomware · Backdoor<br>MitM |

라벨 공급 → context 또는 모델 갱신 → 별도 test 평가

신규 공격의 구분 · 기존 공격의 탐지 · 정상 오탐 · 비용

# 1014 결과 · 누적 10 만 사례의 품질과 갱신 비용

전체 test 순차 재생 · 지연 없음 · seed 43 · 초기 구축 제외 후속 갱신 합계

| 데이터 | 배분 | XGB F1 (%) | PFN F1 (%) | XGB 갱신 (s) | PFN 갱신 (s) |
|---|---|---|---|---|---|
| CIC2018 | 자연 | 76.80 | 77.72 | 4.17 | 44.30 |
| CIC2018 | 균등 | 77.03 | 81.35 | 5.09 | 41.00 |
| ToN | 자연 | 79.37 | 73.66 | 11.09 | 50.45 |
| ToN | 균등 | 74.51 | 73.00 | 12.31 | 48.56 |

개선 방향 : context 사용량 · 교체 정책을 제어하며 품질과 비용을 함께 측정

# 추가 비교 · 누적 · 고정 버퍼 · 갱신 없음

정책 설명용 예시 : 기존 1,000 개 · 신규 라벨 20 개

| 정책 | Context 구성 | 예시 행 수 | 확인할 차이 |
|---|---|---|---|
| a | 기존 전체 + 신규 | 1,020 | 사례 보존과 누적 재준비 비용 |
| b | 기존 일부 삭제 + 신규 | 1,000 | 동일 저장량에서 신규 반영 · 기존 탐지 |
| c | 기존 context 고정 | 1,000 | 갱신 비용 없는 기준선과 신규 유형 한계 |

XGB· 다른 비교 모델은 누적 사례로 재학습 · 재구성

이번 추가 실행에서 LoCalPFN 제외

# 고정 버퍼의 삭제 기준

## 확보 순서 · FIFO

가장 먼저 확보한 사례부터 삭제
실제 노후화의 대리 기준
동일 구간 동률 순서 고정

→

## 신규와 유사

기존 context 로 표준화
신규 사례와 가까운 기존 사례 삭제
중복 근거 감소 가설

→

## 무작위

Seed 로 재현 가능한 삭제
단순 정책의 비교 기준
삭제 후 기존 클래스 유지 확인

공통 조건 : 버퍼 크기 고정 · 신규 사례 수 일치 · 기존 클래스 최소 사례 보존

# EXP76 · 첫 소규모 context 비교 설정

| 항목 | 첫 실행 설정 |
| --- | --- |
| 초기 / 신규 라벨 | 초기 1,000 개 / 신규 공격 클래스당 100 개 |
| 최종 누적 · CIC2018 | 1,400 개 |
| 최종 누적 · ToN | 1,700 개 |
| 고정 버퍼 | 1,000 개 · FIFO / 유사도 / 무작위 |
| 비교 모델 | TabPFN context 정책 · XGB · BoostPFN · DistPFN |
| 평가 | 기존 test 전체 · 지연 없는 순차 도입 · seed 43 |
| 측정 조건 | RTX 4090 단독 실행 · 배치 8,192 개 · 비용 분리 |

# CIC2018 · 소규모 context 의 품질과 비용

EXP76 · 전체 test · 초기 구축 제외 후속 갱신 · FPR 분모는 실제 Benign

| 방법 | F1 (%) | FPR (%) | 갱신 (s) | 추론 (µs/ 행 ) |
|---|---|---|---|---|
| XGBoost 누적 | 73.62 | 1.619 | 2.62 | 0.41 |
| TabPFN 누적 | 74.64 | 0.673 | 1.28 | 32.32 |
| TabPFN FIFO | 73.16 | 1.119 | 1.28 | 32.04 |
| TabPFN 유사도 | 72.13 | 2.972 | 1.27 | 31.96 |
| TabPFN 무작위 | 73.47 | 0.924 | 1.24 | 32.17 |
| TabPFN 고정 | 41.94 | 0.001 | 0.00 | 32.04 |
| BoostPFN 누적 | 71.82 | 2.084 | 2.54 | 143.00 |
| DistPFN 누적 | 76.71 | 0.215 | 1.28 | 32.36 |

라벨 예산과 배치 크기가 다른 1014 수치와 직접적인 개선량 비교 제외

# CIC2018 · 클래스별 구분 성능과 버퍼 정책

전체 test 의 클래스별 F1 (%) · 평가 표본 수 내림차순 · seed 43

| 클래스 | 평가 수 | XGB | PFN 누적 | FIFO | 유사도 | 무작위 |
|---|---|---|---|---|---|---|
| benign | 2,652,203 | 99.00 | 99.50 | 99.27 | 98.36 | 99.36 |
| ddos | 262,680 | 99.70 | 99.71 | 99.71 | 97.96 | 99.71 |
| bot | 41,542 | 97.01 | 99.15 | 99.11 | 99.10 | 99.04 |
| dos | 39,483 | 99.03 | 99.15 | 99.14 | 99.34 | 99.07 |
| brute_force | 37,696 | 99.98 | 99.97 | 99.97 | 99.98 | 99.97 |
| infiltration | 8,742 | 11.59 | 22.80 | 13.24 | 9.10 | 15.41 |
| web_attacks | 127 | 9.00 | 2.22 | 1.70 | 1.07 | 1.71 |

공격별 precision·recall 과 혼동행렬은 연결된 실험 결과에 보존

# ToN · 소규모 context 의 품질과 비용

EXP76 · 전체 test · 초기 구축 제외 후속 갱신 · FPR 분모는 실제 Benign

| 방법 | F1 (%) | FPR (%) | 갱신 (s) | 추론 (µs/ 행 ) |
|---|---|---|---|---|
| XGBoost 누적 | 65.22 | 11.252 | 5.66 | 0.62 |
| TabPFN 누적 | 64.88 | 11.617 | 1.61 | 33.37 |
| TabPFN FIFO | 65.94 | 12.052 | 1.62 | 32.51 |
| TabPFN 유사도 | 59.91 | 17.703 | 1.76 | 32.52 |
| TabPFN 무작위 | 65.62 | 11.965 | 1.59 | 32.50 |
| TabPFN 고정 | 14.02 | 3.564 | 0.00 | 32.06 |
| BoostPFN 누적 | 60.70 | 14.419 | 3.91 | 143.64 |
| DistPFN 누적 | 68.01 | 11.068 | 1.61 | 33.41 |

라벨 예산과 배치 크기가 다른 1014 수치와 직접적인 개선량 비교 제외

# ToN · 클래스별 구분 성능과 버퍼 정책

전체 test 의 클래스별 F1 (%) · 평가 표본 수 내림차순 · seed 43

| 클래스 | 평가 수 | XGB | PFN 누적 | FIFO | 유사도 | 무작위 |
|---|---|---|---|---|---|---|
| benign | 1,474,302 | 93.21 | 93.51 | 93.20 | 90.07 | 93.31 |
| xss | 343,854 | 87.74 | 88.00 | 88.88 | 83.07 | 89.93 |
| password | 210,951 | 89.90 | 90.02 | 90.27 | 79.81 | 89.94 |
| ddos | 103,338 | 92.67 | 93.44 | 93.70 | 84.35 | 93.17 |
| injection | 68,891 | 71.88 | 71.26 | 69.32 | 58.08 | 70.90 |
| backdoor | 40,030 | 99.02 | 99.90 | 99.43 | 98.70 | 99.89 |
| dos | 22,458 | 63.57 | 62.43 | 68.19 | 77.89 | 72.31 |
| scanning | 6,029 | 12.32 | 31.22 | 40.26 | 21.07 | 26.97 |
| mitm | 1,161 | 13.10 | 13.03 | 9.66 | 2.46 | 12.72 |
| ransomware | 709 | 28.78 | 6.01 | 6.47 | 3.66 | 7.01 |

공격별 precision·recall 과 혼동행렬은 연결된 실험 결과에 보존

# 채택 판단 · 품질을 유지하는 작은 context 와 낮은 갱신 비용

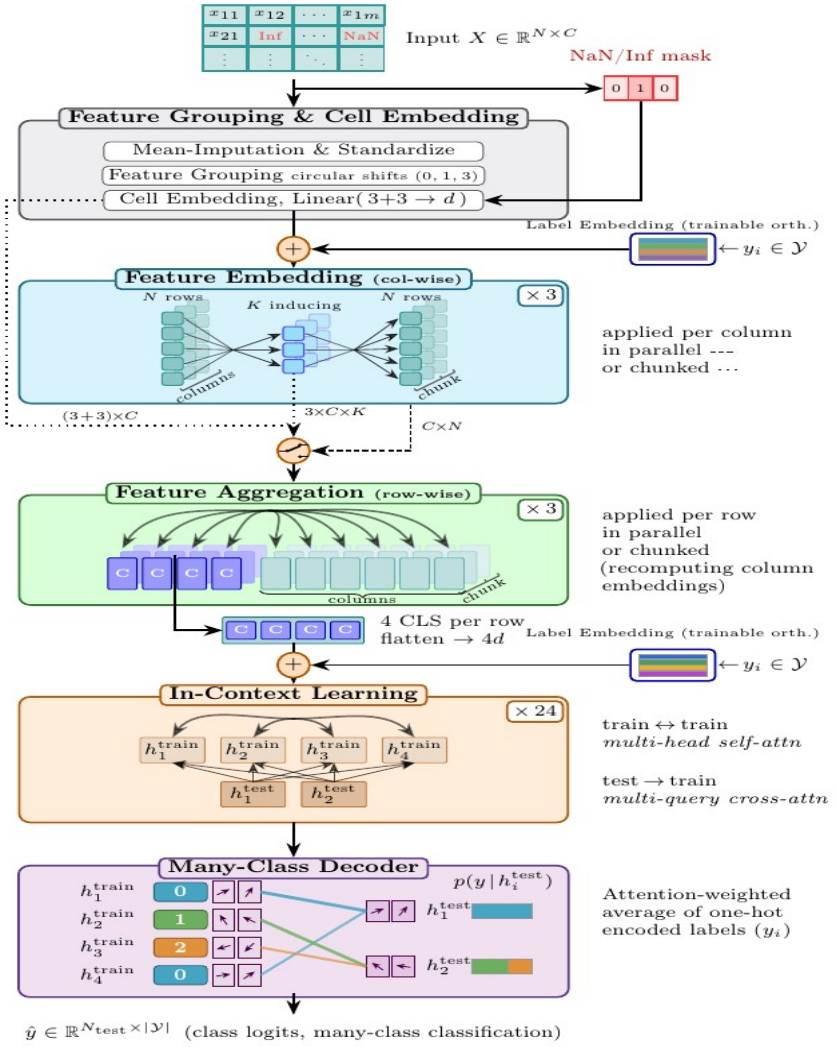
## 현재 관찰과 대응

소규모 PFN 의 갱신 준비 비용 절감
반복 추론 비용의 별도 경량화 필요
유사도 삭제의 정상 오탐 증가 확인
정상 · 기존 클래스 보존 규칙 보강

## 후속 비교

동일 라벨에서 context 규모만 변경
Estimator 수 · 캐시 위치별 품질과 비용
공격별 precision·recall 과 정상 오탐
조건 ·seed 확장 이후 최종 방법 판단

# 부록 · v3 원문의 전체 구조




Feature grouping & cell embedding

열별 분포 embedding

행별 feature aggregation

ICL transformer

Many-class decoder

원문 Figure 5 · PDF 6 쪽

세부 hyperparameter 는 Appendix C

# 부록 · v3 fine-tuning 코드 예시

```
from tabpfn.finetuning import FinetunedTabPFNClassifier

ft = FinetunedTabPFNClassifier(
    device="cuda", epochs=10, learning_rate=1e-5,
    n_finetune_ctx_plus_query_samples=1024,
    finetune_ctx_query_split_ratio=0.2,
    n_estimators_finetune=1,
    n_estimators_validation=1,
    n_estimators_final_inference=1,
    eval_metric="log_loss", random_state=43,
    extra_classifier_kwargs={"model_path": checkpoint_path},
)
ft.fit(X_train, y_train, X_val=X_val, y_val=y_val)
p = ft.predict_proba(X_test)
```

학습 설정 예시 · 이번 context 정책 실험의 실행 코드와 구분