고정된 환경의 분류 정확도를 넘어
변화하는 네트워크에서의 적응성 평가

사전학습 TabPFN 을 활용한
소량 라벨 · 저비용 탐지 모델 갱신

TabPFN · 표 데이터 예측 규칙을 사전학습한 모델 (v3: arXiv, 2026)

사전학습

합성 표 데이터의 8 조 개 이상 토큰으로 학습
일부 행의 정답을 맞히며 표 데이터의 예측 규칙 습득

In-context learning

라벨된 사례 (context) 를 참고해 새 flow(query) 의 라벨 예측
추론 중 모델 가중치는 그대로 유지

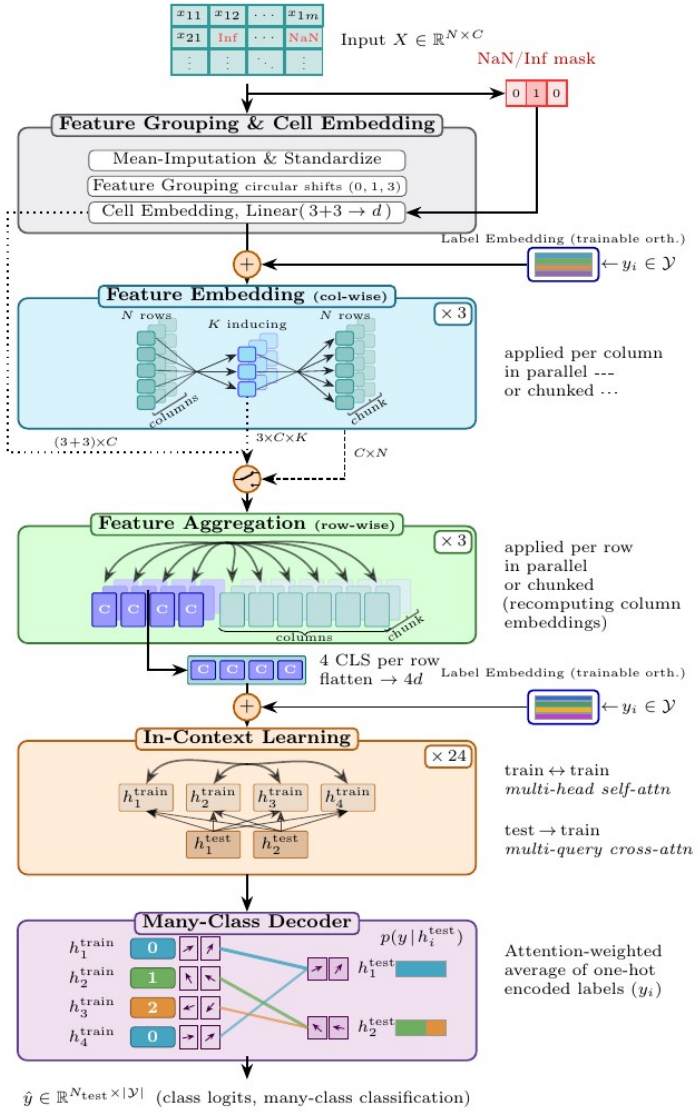
Fine-tuning

초기 IDS 를 context 와 query 로 나눠 query 의 정답 예측
예측 오류를 역전파해 모델 가중치를 IDS 에 맞게 조정

갱신 : 사전학습 가중치 유지 → 기존 클래스 사례 보존 + 신규 사례 누적

기대 : 반복 재학습과 비슷한 탐지 품질을 더 적은 데이터 · 갱신 비용으로 달성

v3 구조



① 입력 변환 · Cell embedding

패킷 길이 · 지속시간 등의 값을 숫자 벡터로 변환
값이 비어 있는 위치도 함께 표시

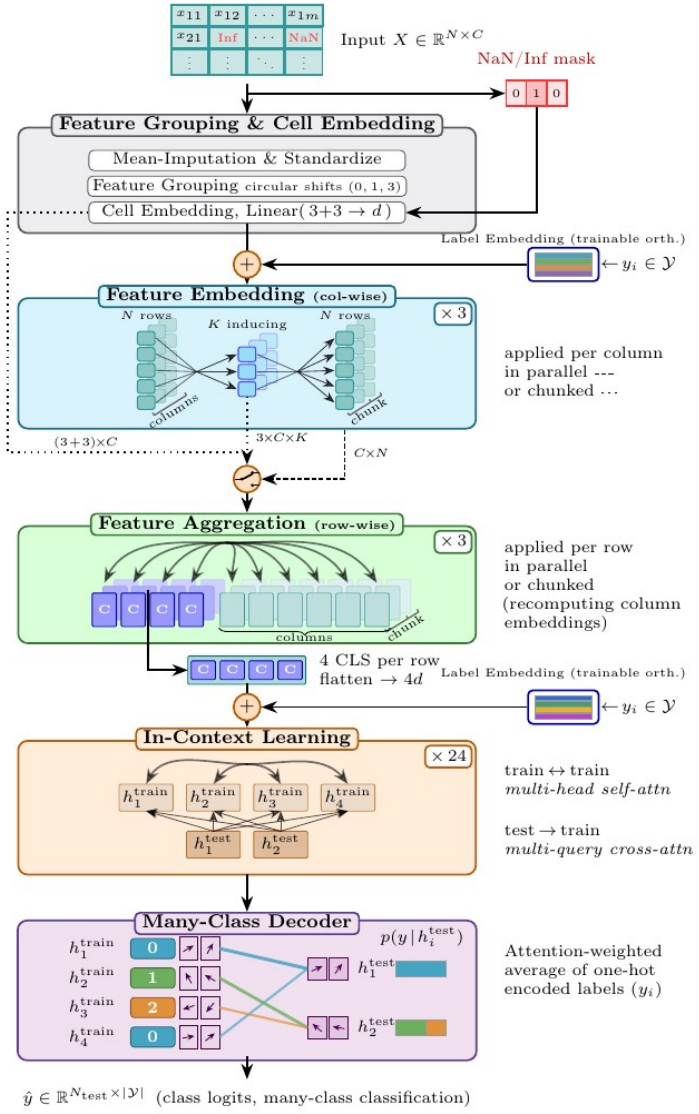
② 특징별 분포 파악 · Feature embedding

여러 flow 를 살펴 각 특징의 값 분포를 요약
Context 의 정상 · 공격 라벨도 함께 반영

③ Flow 별 정보 통합 · Feature aggregation

한 flow 의 여러 특징을 하나의 표현으로 통합
이 표현을 이용해 flow 사이의 관계 비교

v3 구조



④ 사례 참조 · In-context learning

새 flow(query) 가 라벨된 기존 사례 (context) 를 참조
어떤 사례가 예측에 도움이 되는지 attention 으로 계산

⑤ 확률 출력 · Many-class decoder

관련성이 큰 사례의 라벨에 더 큰 가중치 부여
참고한 라벨을 모아 정상 · 공격별 확률 계산

기존 클래스도 분류하려면
해당 라벨의 context 유지 필요

평가시나리오

초기 1,000 개 · 신규 공격당 100 개 누적 · 단계순 , 단계 내 표본 수 내림차순

CIC2018

단계	신규 공개 클래스	클래스별 수	누적 수
1	Benign Brute force DoS	750 125 125	1,000
2	DDoS	100	1,100
3	Web attacks	100	1,200
4	Infiltration	100	1,300
5	Bot	100	1,400

ToN

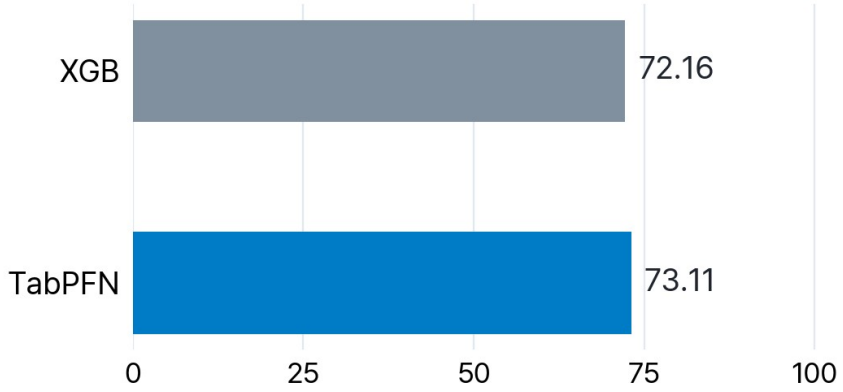
단계	신규 공개 클래스	클래스별 수	누적 수
1	Benign DoS Scanning	750 125 125	1,000
2	DDoS Injection	100 100	1,200
3	Password	100	1,300
4	XSS	100	1,400
5	Backdoor Ransomware	100 100	1,600
6	MitM	100	1,700

전체 test: CIC2018 3,042,473 개 / ToN 2,271,723 개 · 최종 모델 · seed 43 혼합 순서

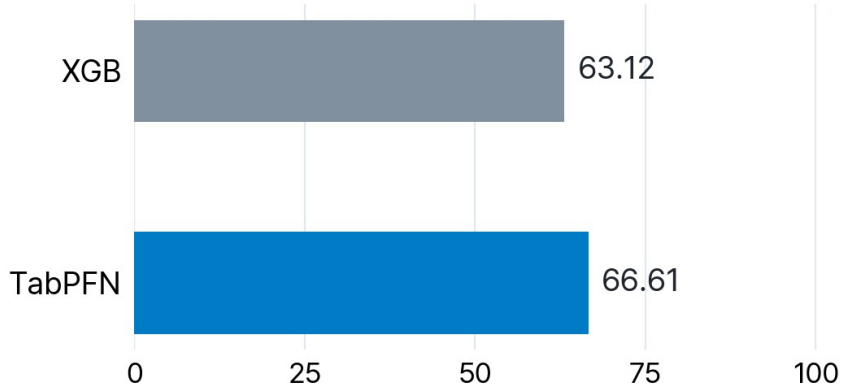
결과

최종 상태 전체 test 평가 · XGB: 누적 재학습 · TabPFN: FT 없이 누적 context 갱신

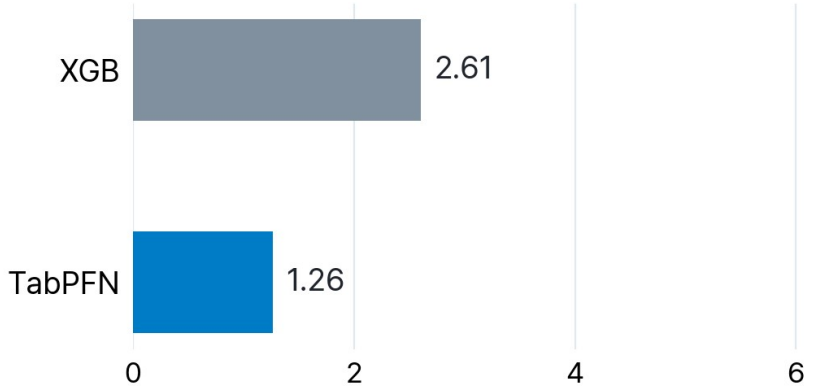
CIC2018 · 최종 Macro-F1 (%)



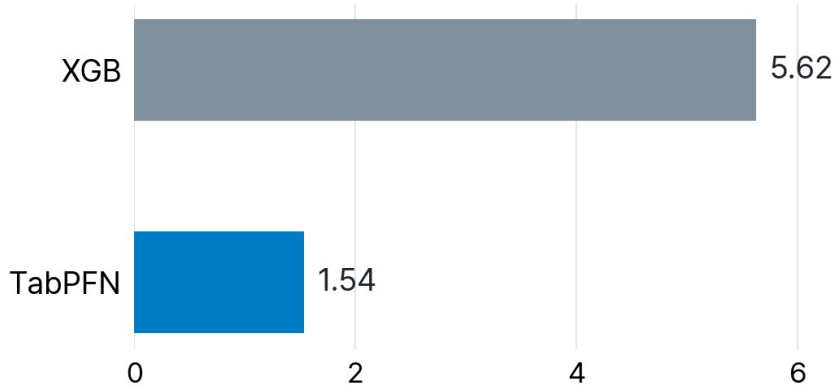
ToN · 최종 Macro-F1 (%)



CIC2018 · 후속 갱신 합계 (초)



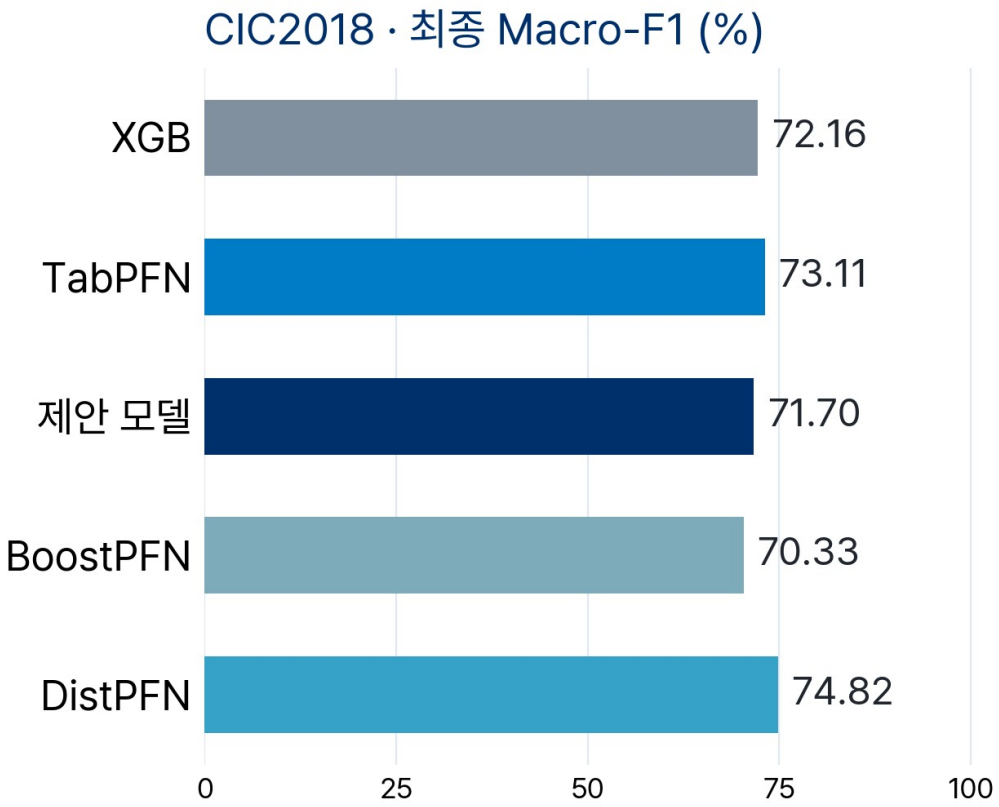
ToN · 후속 갱신 합계 (초)

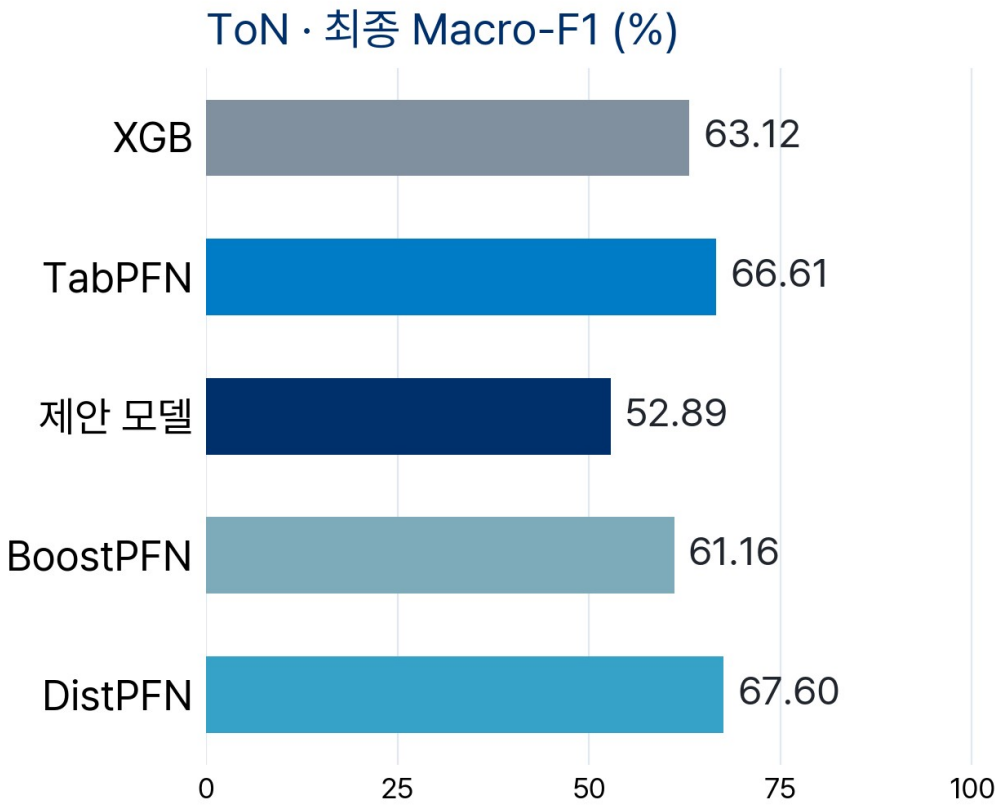


비용 : 2 단계 이후 갱신 합계 · 초기 준비 · 추론 제외 · 두 데이터셋 동일 비용 눈금

제안 모델 ·SOTA 성능 비교

동일 라벨 예산 : CIC2018 1,400 개 / ToN 1,700 개 · 최종 상태 전체 test 평가

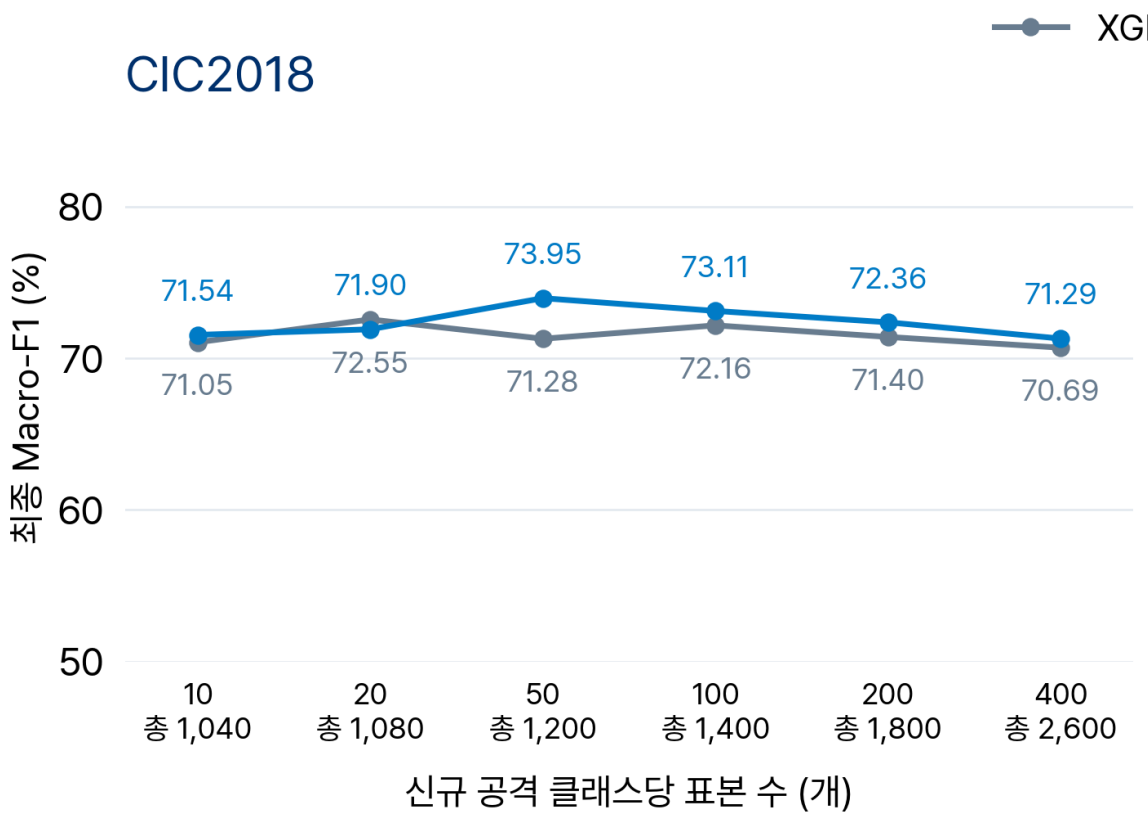


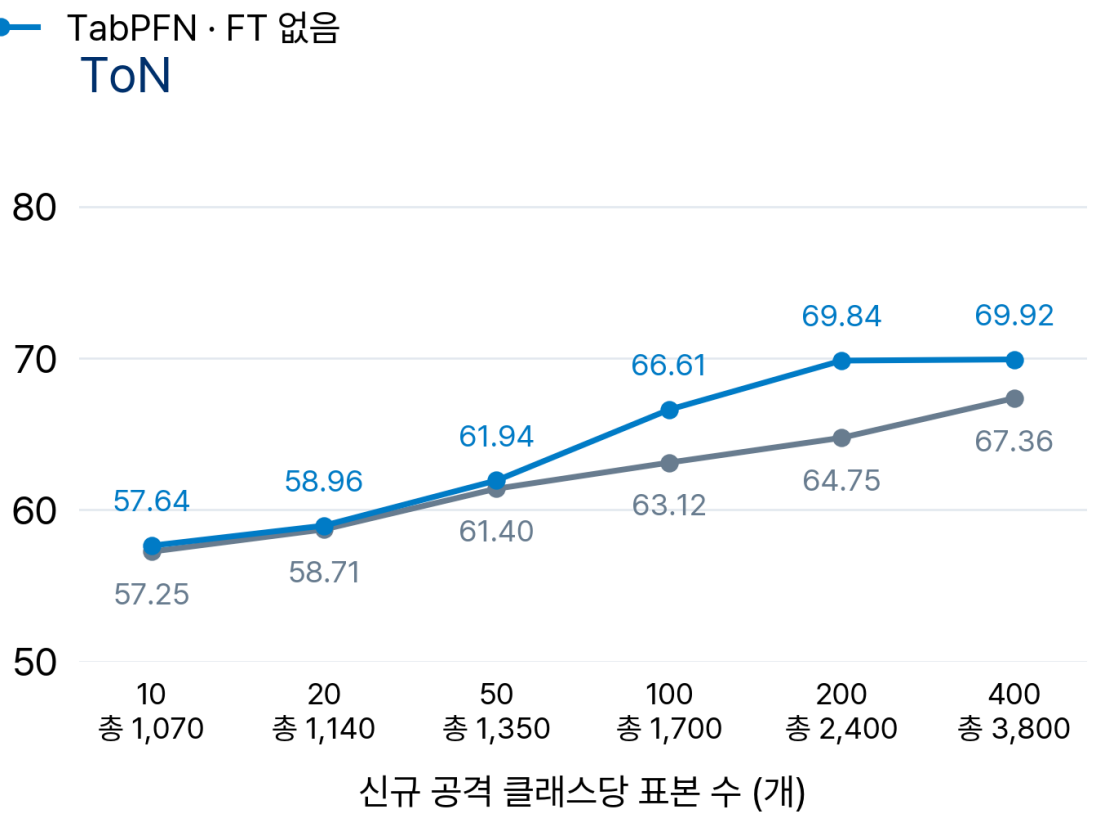


TabPFN·DistPFN: FT 없음 · test 를 8,192 개씩 혼합 평가 · 제안 모델 expert 호출 0 건

신규 공격 표본 수에 따른 성능

초기 1,000 개 고정 · 신규 공격당 10·20·50·100·200·400 개 · 최종 상태 전체 test · seed 43





신규 공격 400 개 · XGB 대비 TabPFN 차이 : CIC2018 +0.60%p · ToN +2.56%p

부록 · 학습 10 만 개 시나리오 · CIC2018

동일 공격 순서 · 소규모 : 신규 공격당 100 개 · 대규모 : Benign 매 단계 15,000 개 추가

		이번 단계 추가 수 (개)			누적 수 (개)		
단계	추가 클래스	소규모	10 만 자연	10 만 균등	소규모	10 만 자연	10 만 균등
1	Benign DoS Brute force	750 125 125	15,000 2,518 2,403	15,000 4,910 4,910	1,000	19,921	24,820
2	DDoS Benign	100 0	16,780 15,000	4,910 15,000	1,100	51,701	44,730
3	Benign Web attacks	0 100	15,000 9	15,000 450	1,200	66,710	60,180
4	Benign Infiltration	0 100	15,000 641	15,000 4,910	1,300	82,351	80,090
5	Benign Bot	0 100	15,000 2,649	15,000 4,910	1,400	100,000	100,000
	별도 검증				0	8,211	8,047

별도 검증 : 제안 모델의 잔차 확률 보정 ·expert 채택 기준 선택 · 소규모는 전체 예산 내 분할

자연 : 학습 공격 비율 · 균등 : 공격별 균등 , 표본 상한 반영 · 단계순 , 단계 내 자연 추가 수 내림차순

부록 · 학습 10 만 개 시나리오 · ToN

동일 공격 순서 · 소규모 : 신규 공격당 100 개 · 대규모 : Benign 매 단계 12,500 개 추가

		이번 단계 추가 수 (개)			누적 수 (개)		
단계	추가 클래스	소규모	10 만 자연	10 만 균등	소규모	10 만 자연	10 만 균등
1	Benign DoS Scanning	750 125 125	12,500 644 168	12,500 2,856 2,856	1,000	13,312	18,212
2	Benign DDoS Injection	0 100 100	12,500 5,785 1,899	12,500 2,856 2,856	1,200	33,496	36,424
3	Benign Password	0 100	12,500 6,009	12,500 2,856	1,300	52,005	51,780
4	Benign XSS	0 100	12,500 9,308	12,500 2,856	1,400	73,813	67,136
5	Benign Backdoor Ransomware	0 100 100	12,500 1,136 20	12,500 2,857 2,151	1,600	87,469	84,644
6	Benign MitM	0 100	12,500 31	12,500 2,856	1,700	100,000	100,000
	별도 검증				0	8,668	8,605

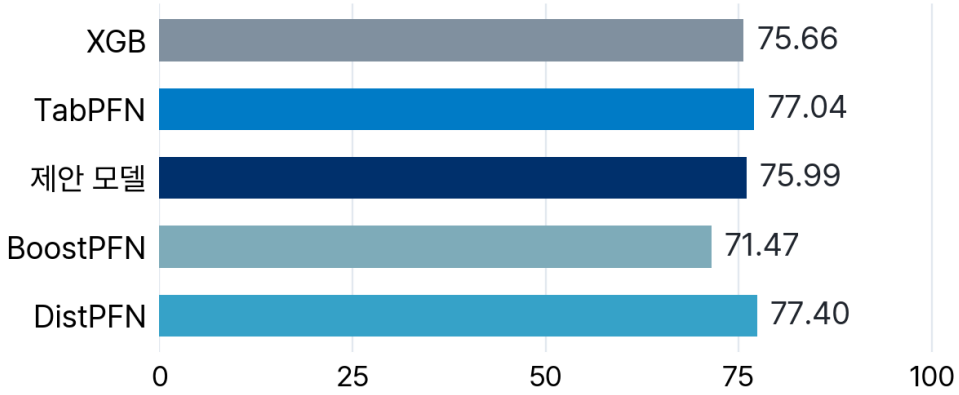
별도 검증 : 제안 모델의 잔차 확률 보정 ·expert 채택 기준 선택 · 소규모는 전체 예산 내 분할

자연 : 학습 공격 비율 · 균등 : 공격별 균등 , 표본 상한 반영 · 단계순 , 단계 내 자연 추가 수 내림차순

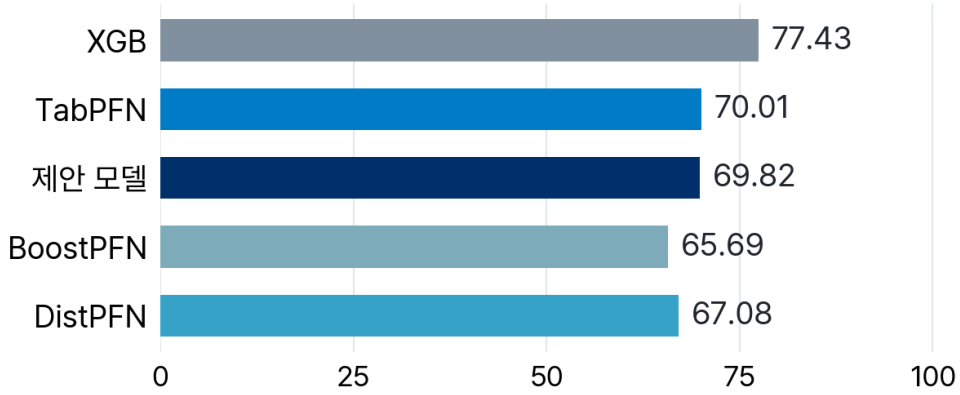
부록 · 학습 10 만 개의 최종 성능

최종 모델로 전체 test 평가 · Macro-F1 (%) · 학습 10 만 개 + 별도 검증

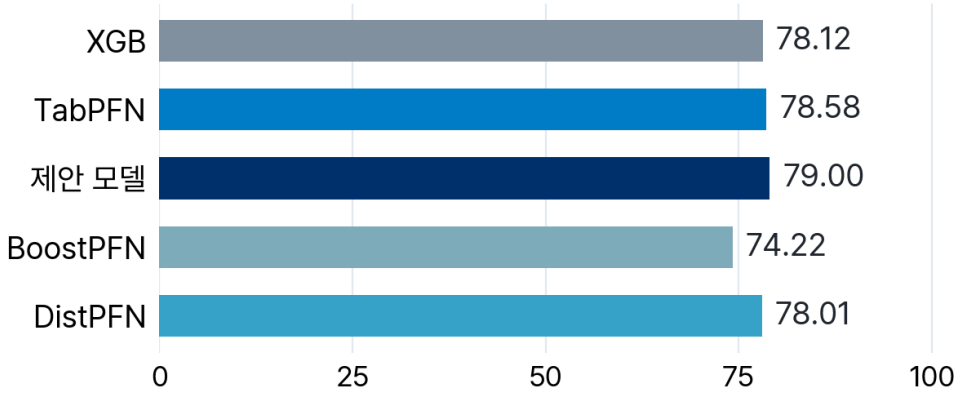
CIC2018 · 자연비율



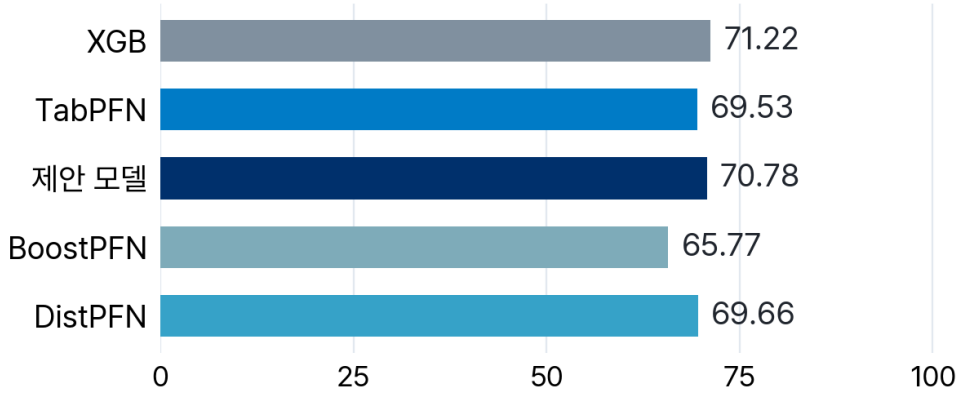
ToN · 자연비율



CIC2018 · 균등 배분



ToN · 균등 배분



본문과 동일 test· 혼합 순서 · 최종 상태 평가 · 학습 · 검증 예산 상이 · BoostPFN v1, 나머지 PFN v3