고정된 환경의 분류 정확도를 넘어
변화하는 네트워크에서의 적응성 평가

사전학습 TabPFN 을 활용한
소량 라벨 · 저비용 탐지 모델 갱신

TabPFN · 표 데이터 예측 규칙을 사전학습한 모델 (v3: arXiv, 2026)

사전학습

합성 표 데이터의 8 조 개 이상 토큰으로 학습
일부 행의 정답을 맞히며 표 데이터의 예측 규칙 습득

In-context learning

라벨된 사례 (context) 를 참고해 새 flow(query) 의 라벨 예측
추론 중 모델 가중치는 그대로 유지

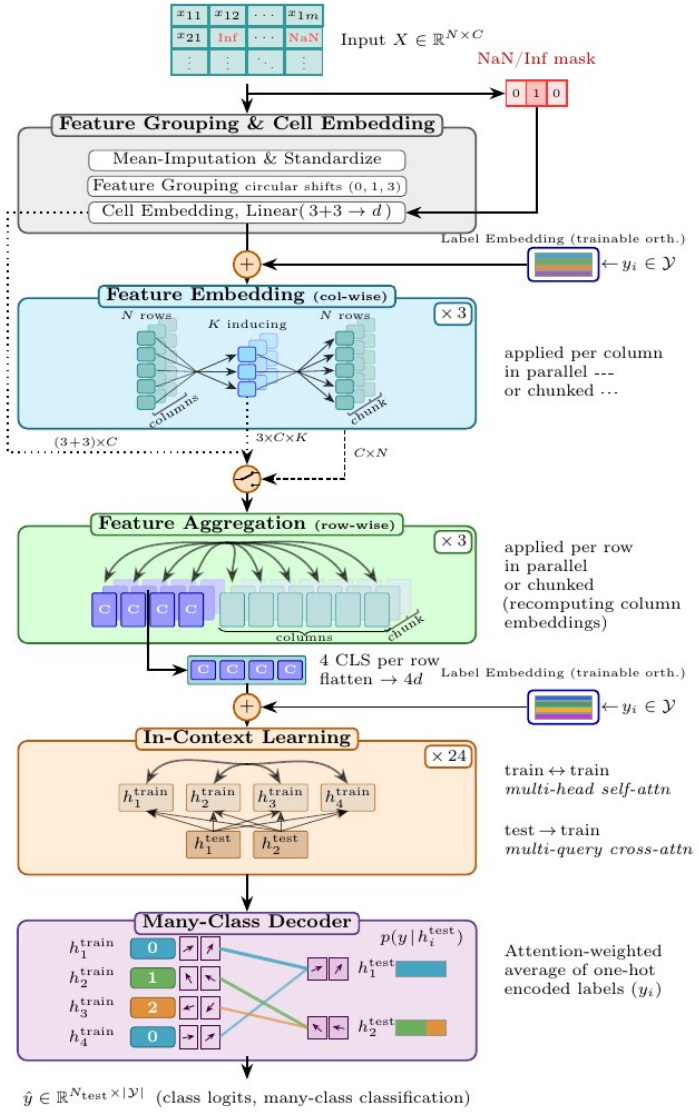
Fine-tuning

초기 IDS 를 context 와 query 로 나눠 query 의 정답 예측
예측 오류를 역전파해 모델 가중치를 IDS 에 맞게 조정

초기 IDS 로 1 회 fine-tuning → 가중치 고정 → 기존 클래스 유지 + 신규 사례 반영

기대 : 반복 재학습과 비슷한 탐지 품질을 더 적은 데이터 · 갱신 비용으로 달성

v3 구조



① 입력 변환 · Cell embedding

패킷 길이 · 지속시간 등의 값을 숫자 벡터로 변환
값이 비어 있는 위치도 함께 표시

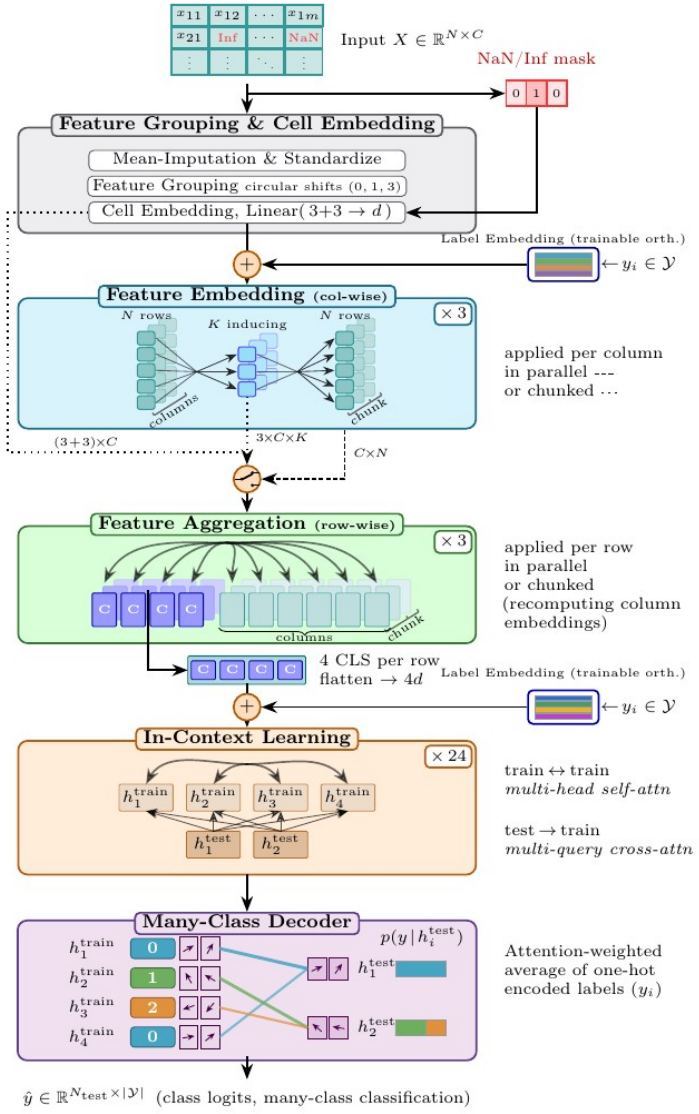
② 특징별 분포 파악 · Feature embedding

여러 flow 를 살펴 각 특징의 값 분포를 요약
Context 의 정상 · 공격 라벨도 함께 반영

③ Flow 별 정보 통합 · Feature aggregation

한 flow 의 여러 특징을 하나의 표현으로 통합
이 표현을 이용해 flow 사이의 관계 비교

v3 구조



④ 사례 참조 · In-context learning

새 flow(query) 가 라벨된 기존 사례 (context) 를 참조
어떤 사례가 예측에 도움이 되는지 attention 으로 계산

⑤ 확률 출력 · Many-class decoder

관련성이 큰 사례의 라벨에 더 큰 가중치 부여
참고한 라벨을 모아 정상 · 공격별 확률 계산

기존 클래스도 분류하려면
해당 라벨의 context 유지 필요

평가시나리오

1 단계 : 본체 10 epoch FT · 이후 context 갱신 · 단계순 , 같은 단계 안에서는 표본 수 내림차순

CIC2018

단계	신규 공개 클래스	클래스별 수	누적 수
1	Benign Brute force DoS	750 125 125	1,000
2	DDoS	100	1,100
3	Web attacks	100	1,200
4	Infiltration	100	1,300
5	Bot	100	1,400

ToN

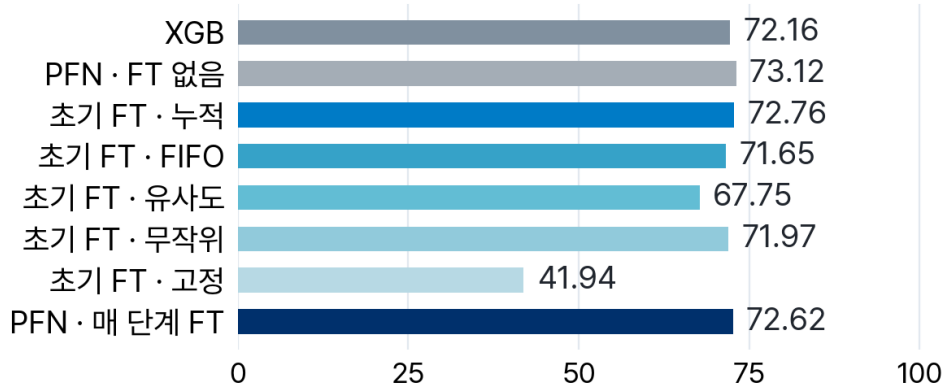
단계	신규 공개 클래스	클래스별 수	누적 수
1	Benign DoS Scanning	750 125 125	1,000
2	DDoS Injection	100 100	1,200
3	Password	100	1,300
4	XSS	100	1,400
5	Backdoor Ransomware	100 100	1,600
6	MitM	100	1,700

최종 상태로 전체 test 평가 · CIC2018 3,042,473 개 / ToN 2,271,723 개 · 고정 버퍼 1,000 개

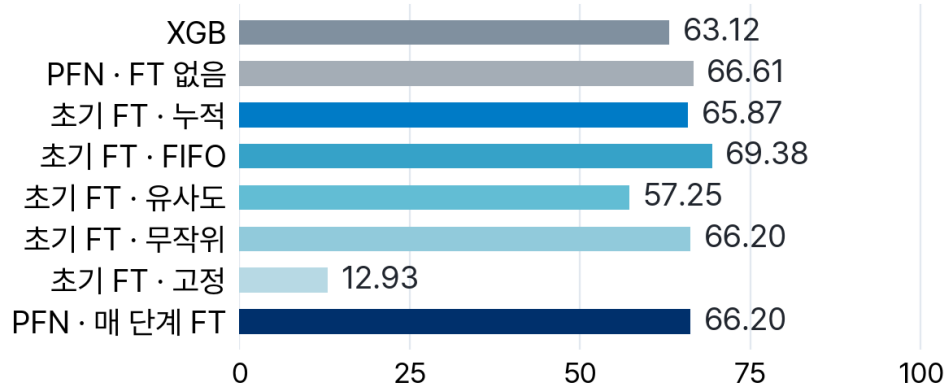
결과

모든 클래스 도입 후 최종 상태 평가 · 초기 FT 후 가중치 고정 · 매 단계 FT 는 별도 비교군

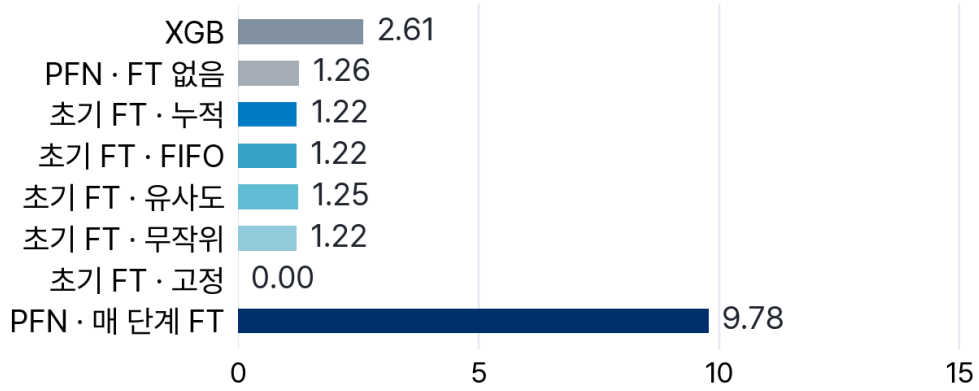
CIC2018 · 최종 Macro-F1 (%)



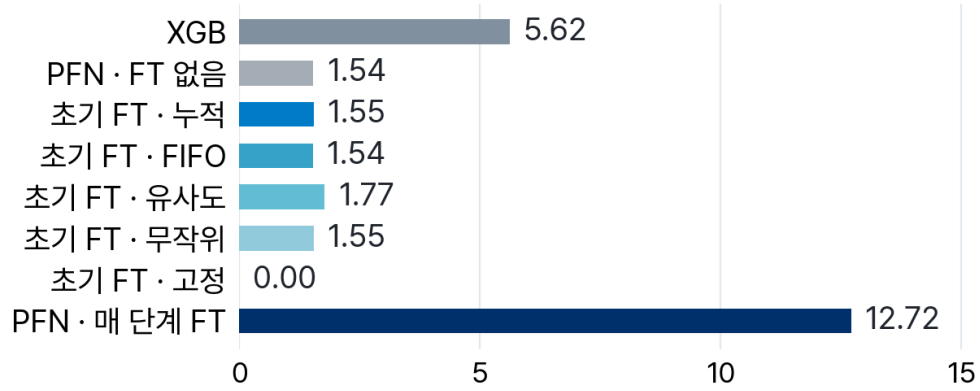
ToN · 최종 Macro-F1 (%)



CIC2018 · 후속 갱신 합계 (초)



ToN · 후속 갱신 합계 (초)

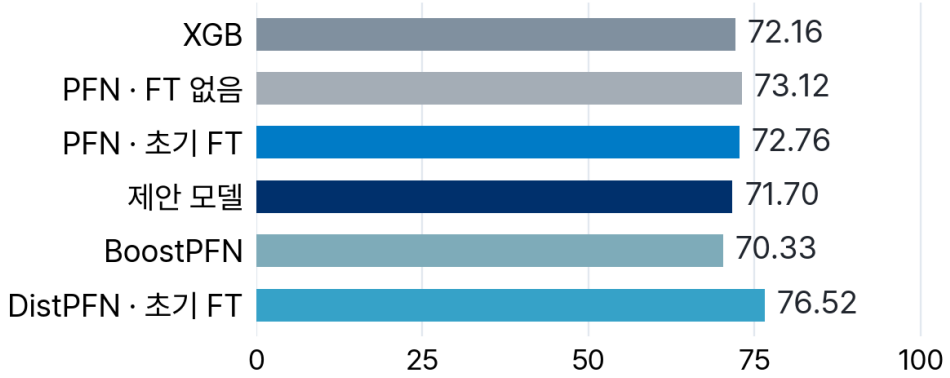


초기 FT 별도 : 2.76 / 2.01 초 (CIC2018 / ToN) · 고정 context 는 신규 클래스 라벨 부재

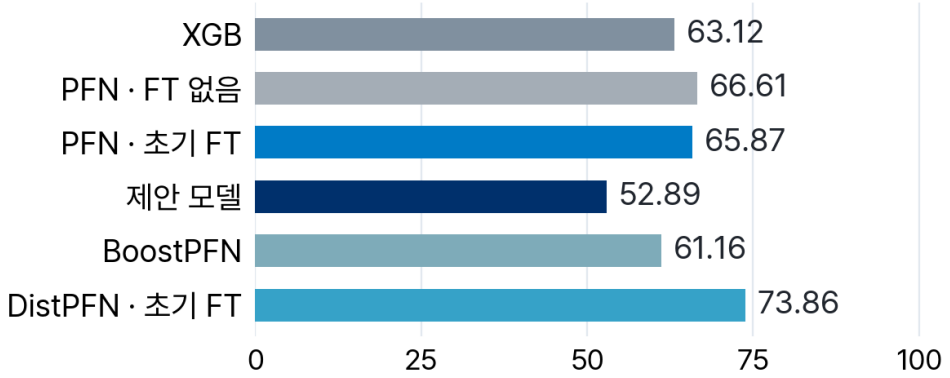
제안 모델 ·SOTA 비교

동일 라벨 예산 1,400 / 1,700 개 · 검증 · 보정 라벨 포함 · 비용 : 초기 준비 + 후속 갱신 + 전체 추론

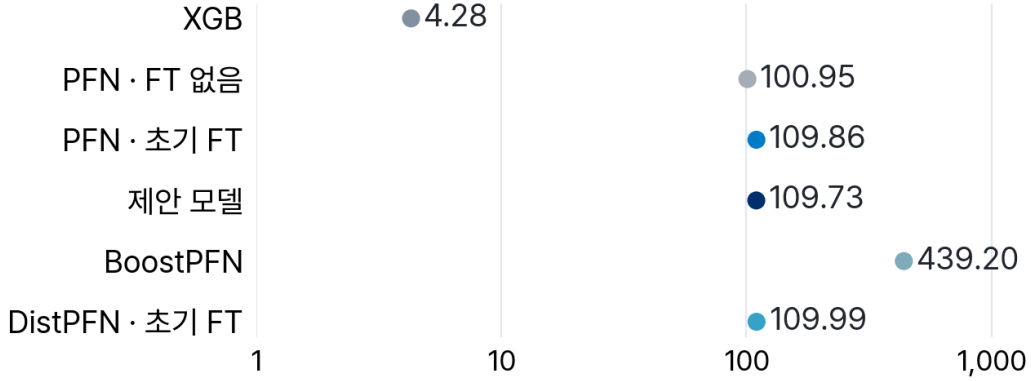
CIC2018 · 최종 Macro-F1 (%)



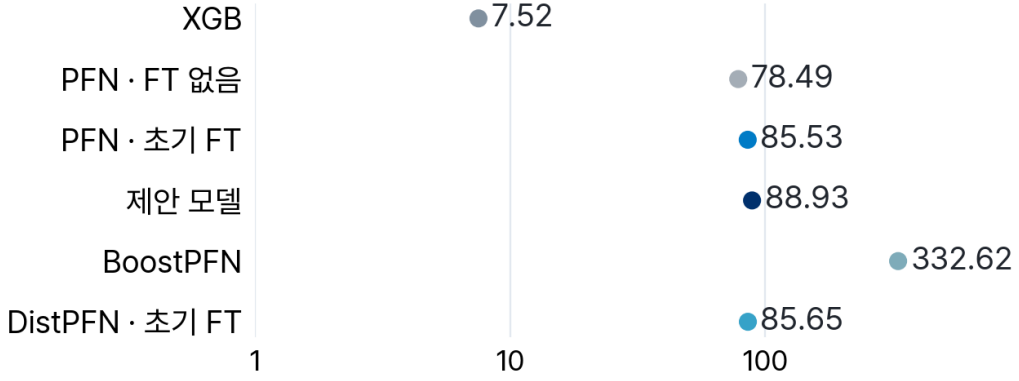
ToN · 최종 Macro-F1 (%)



CIC2018 · 준비 + 전체 추론 (초)



ToN · 준비 + 전체 추론 (초)



제안 모델 : 두 데이터 모두 Global 유지 선택 · DistPFN: 초기 FT PFN 에 확률 보정 · 비용은 로그눈금