기존 IDS의 한계 · 새 공격과 제한된 라벨

침입 탐지 시스템 (IDS) · 통신 기록의 특징으로 정상·공격 유형을 구분하는 시스템

운영 시작 시 확보한 공격 라벨만으로 이후 등장하는 공격까지 대응하기 어려운 문제

입력의 변화

네트워크·서비스·공격의 다양성
학습 시점과 다른 트래픽의 등장

제한된 공격 라벨

새 공격 조사 후 확보하는 사례
충분한 학습 자료 확보의 어려움

오탐과 갱신 부담

정상 트래픽에 대한 잘못된 경보
새 사례 반영에 필요한 추가 계산

고정된 클래스의 한 번의 점수에 더해, 새 라벨을 반영한 뒤의 탐지 품질과 비용 확인

Sommer · Paxson, Outside the Closed World: On Using Machine Learning for Network Intrusion Detection, IEEE S&P 2010 · 학습 자료 부족·입력 변동성·오류 비용

공격 변화의 수집 사례 · 공식 벤치마크

CSE-CIC-IDS2018 · AWS 시험망에서 정상 동작과 계획된 공격을 실행·수집

CSE · UNB CIC, CSE-CIC-IDS2018 on AWS, 2018 · 공식 문서의 공격 일정 Table 2

2/14	2/15·16	2/20·21	2/22·23	2/28·3/1	3/2
Brute force	DoS	DDoS	Web attacks	Infiltration	Bot

수집 기간에 따라 달라지는 공격 유형
패킷에서 추출한 통신량·지속시간 등의 표 특징과 공격 라벨

이번 실험에서 설계한 부분 · 확보되는 공격 라벨의 순서와 개수
원본 날짜별 전체 트래픽 재생과 구별되는 단계적 라벨 제공

ToN-IoT도 별도 시험망에서 수집된 네트워크 자료 사용 · UNSW Canberra, The TON_IoT Datasets

TabPFN의 in-context learning

TabPFN · 표 데이터의 사례와 정답으로부터 예측하는 방법을 사전학습한 모델

Grinsztajn et al., TabPFN-3: Technical Report, arXiv 2026 · 합성 표 과제로 사전학습

Context · 라벨 사례

기존 정상·공격 + 신규 공격
특징과 정답을 함께 입력

Query · 분류할 통신 기록

특징만 입력 · 정답은 평가에 사용

→

TabPFN v3

사전학습 가중치 고정

→

정상·공격별 확률

context를 참조한 추론

In-context learning 입력 사례를 바꾸어 현재 분류 문제에 적응
가중치에 사례를 저장하거나 역전파하는 과정 없음

Fine-tuning 오차를 역전파해 가중치를 바꾸는 별도 절차 · 이번 실험은 미수행

평가 목적 · 누적과 고정 버퍼의 품질·비용

새 공격의 라벨 사례가 소량 확보될 때
누적 재학습과 context 갱신의 탐지 품질·계산 비용 비교

공통 입력 · 초기 1,000개 + 단계별 신규 공격 라벨 / 모든 방법에 동일 사례 제공

XGB 누적 재학습	PFN 누적 context	PFN 고정 버퍼
지금까지 제공한 사례 전부 가중치 재학습	지금까지 제공한 사례 전부 고정 가중치 · context 갱신	기존 삭제 + 신규 전량 편입 1,000개 유지 · context 갱신

탐지 품질

전체·신규 공격별 F1

기존 클래스 유지

동일 평가 사례의 갱신 전후 변화

갱신 비용

초기 준비·추론과 분리한 시간

평가 범위 · 신규 공격의 라벨 확보 후 분류 / 라벨 없는 미지 공격 탐지와 네트워크 간 전이는 별도 과제

평가 방법 · 데이터 출처와 사례 선택

각 벤치마크 안에서 train의 행을 선택 · CIC와 ToN 사이의 행 결합 없음

CIC2018

수집 벤치마크

정제 후 train / test 분리

상충 라벨 제거
학습·평가 행 분리

Train → 초기 1,000개 + 신규 공격당 n개 선택

Test → 고정 3,042,473개 · 학습/context에 미사용

ToN-IoT

수집 벤치마크

정제 후 train / test 분리

상충 라벨 제거
학습·평가 행 분리

Train → 초기 1,000개 + 신규 공격당 n개 선택

Test → 고정 2,271,723개 · 학습/context에 미사용

제공 사례 · 같은 train에서 단계별로 선택한 라벨 사례 / 별도 출처의 데이터셋 생성 없음

실제 사용 사례 · 누적은 지금까지 제공한 전부 / 버퍼는 삭제 후 남긴 사례와 신규 사례 1,000개

평가 방법 · 단계별 공급량과 실제 보유량

n = 5 · 10 · 20 · 30 · 50 · 100개 / 신규 공격 클래스 · seed 43 한 번

n은 확보 가능한 라벨 수의 실험 조건 · 하루 공격량이나 최적 표본 수를 뜻하지 않는 값

CIC2018

단계	제공 클래스	제공 수	누적 보유	버퍼
1	Benign Brute force DoS	750 125 125	1,000	1,000
2	DDoS	n	1,000+n	1,000
3	Web attacks	n	1,000+2n	1,000
4	Infiltration	n	1,000+3n	1,000
5	Bot	n	1,000+4n	1,000

ToN-IoT

단계	제공 클래스	제공 수	누적 보유	버퍼
1	Benign DoS Scanning	750 125 125	1,000	1,000
2	DDoS Injection	n n	1,000+2n	1,000
3	Password	n	1,000+3n	1,000
4	XSS	n	1,000+4n	1,000
5	Backdoor Ransomware	n n	1,000+6n	1,000
6	MITM	n	1,000+7n	1,000

제공 수는 클래스당 사례 수 · 누적 보유는 XGB/PFN 공통 · 버퍼는 PFN의 매 단계 실제 context 크기

평가 방법 · 누적 편입과 기존 사례 교체

CIC 2단계 · n = 20 예시 · 같은 train에서 선택한 DDoS 20개를 전량 제공

누적

XGB / PFN

기존 1,000개

전부 유지

+

신규 20개

전량 편입

→

1,000 + 20 = 1,020개

누적 사례 전체 보유

XGB · 누적 사례로 재학습 / PFN · 누적 사례로 context/cache 갱신

고정 버퍼

PFN 3개 삭제 정책

기존 1,000개

20개 삭제 → 980개

+

신규 20개

전량 편입

→

980 + 20 = 1,000개

context 1,000개 유지

PFN · 가중치 고정 / 남은 기존 사례와 신규 사례로 context/cache 갱신

FIFO · 먼저 들어온 기존 사례 삭제

무작위 · 기존 사례 무작위 삭제

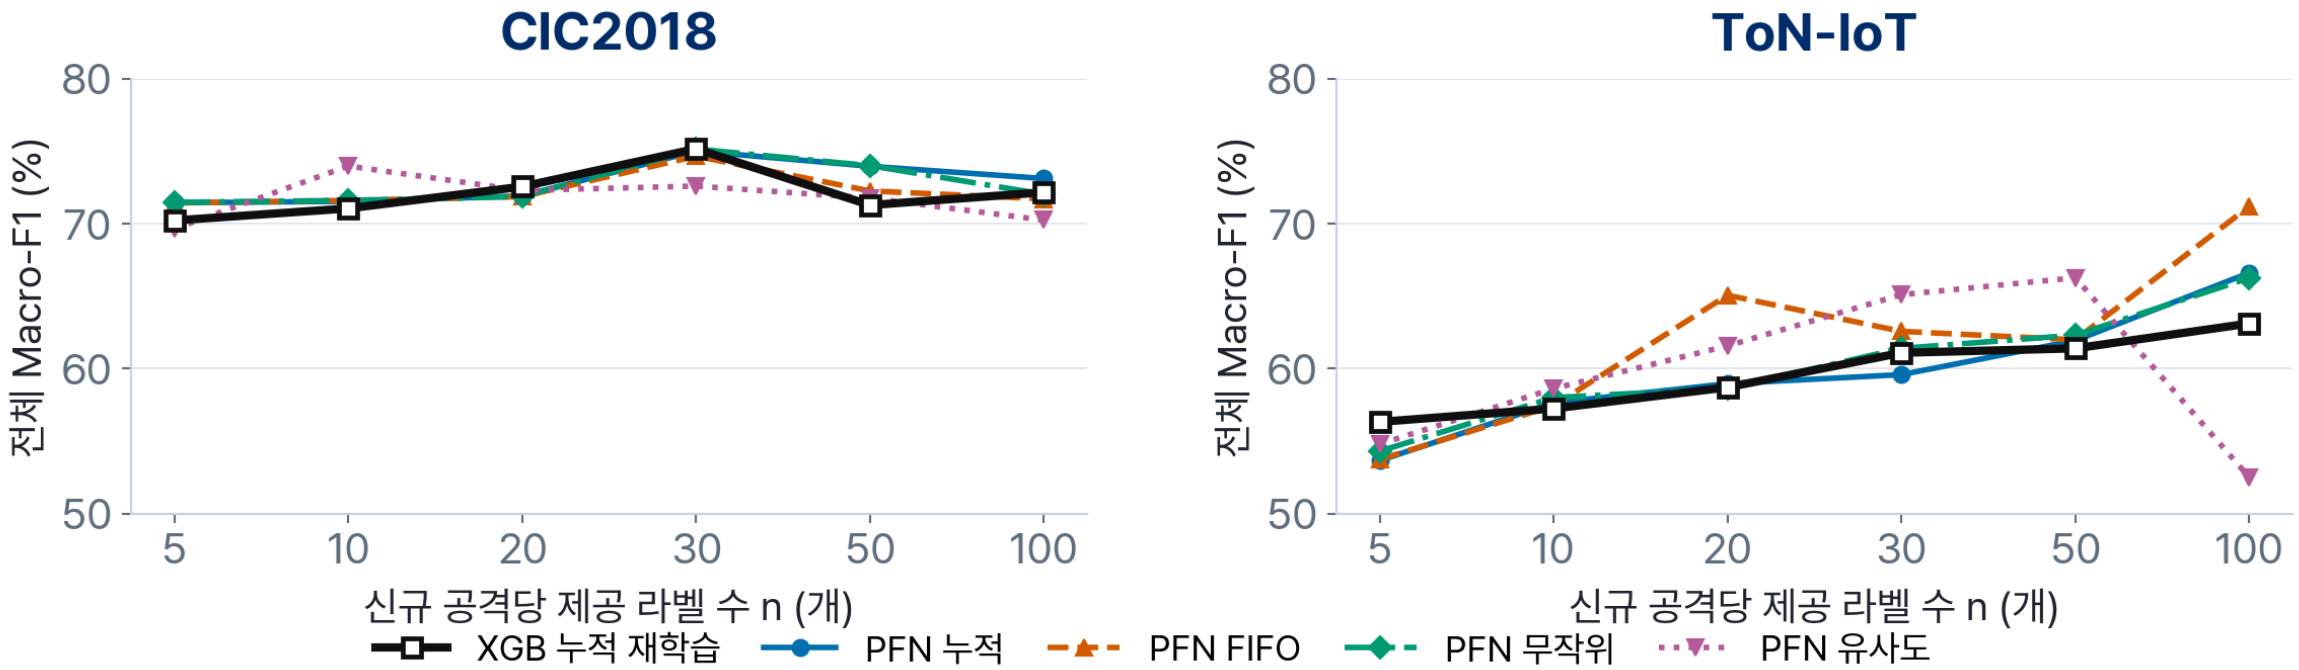
유사도 · 신규와 가까운 기존 삭제

기존 클래스별 최소 1개 보존 · 신규 사례 편입 상한 없음 · 갱신 비용은 2단계 이후 선택·삭제·fit/cache 합계

결과 · 전체 클래스의 최종 분류 성능

모든 갱신을 마친 모델 · 전체 고정 test에서 모든 클래스 F1의 산술평균

CIC 7개 클래스 / ToN 10개 클래스 · 정상·초기 공격·신규 공격 모두 포함 · seed 43 한 번

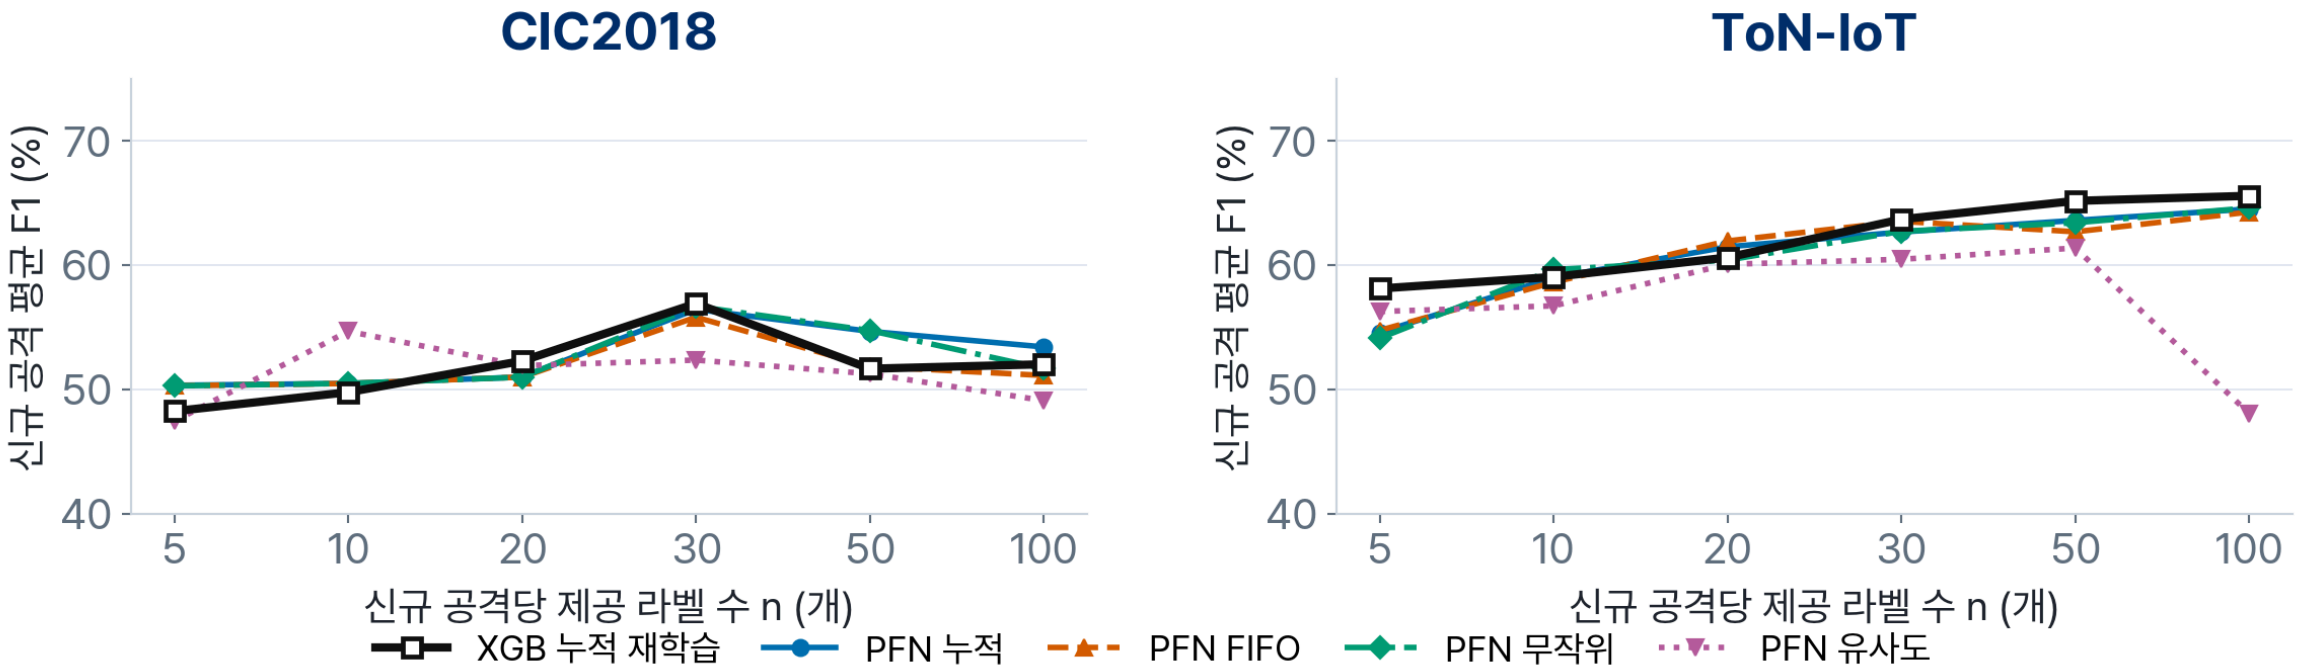


n = 100 값	XGB 누적 재학습		PFN 누적		PFN FIFO		PFN 무작위		PFN 유사도	
	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN
단위 %	72.16	63.12	73.11	66.61	71.71	71.19	72.03	66.26	70.25	52.50

결과 · 신규 공격 라벨 수에 따른 탐지 품질

최종 모델 · 전체 test에서 계산한 신규 공격 클래스별 F1의 산술평균

CIC 4개 · ToN 7개 신규 공격 / 정상·초기 공격은 평균에서 제외, 이들에서 발생한 오탐은 F1에 포함

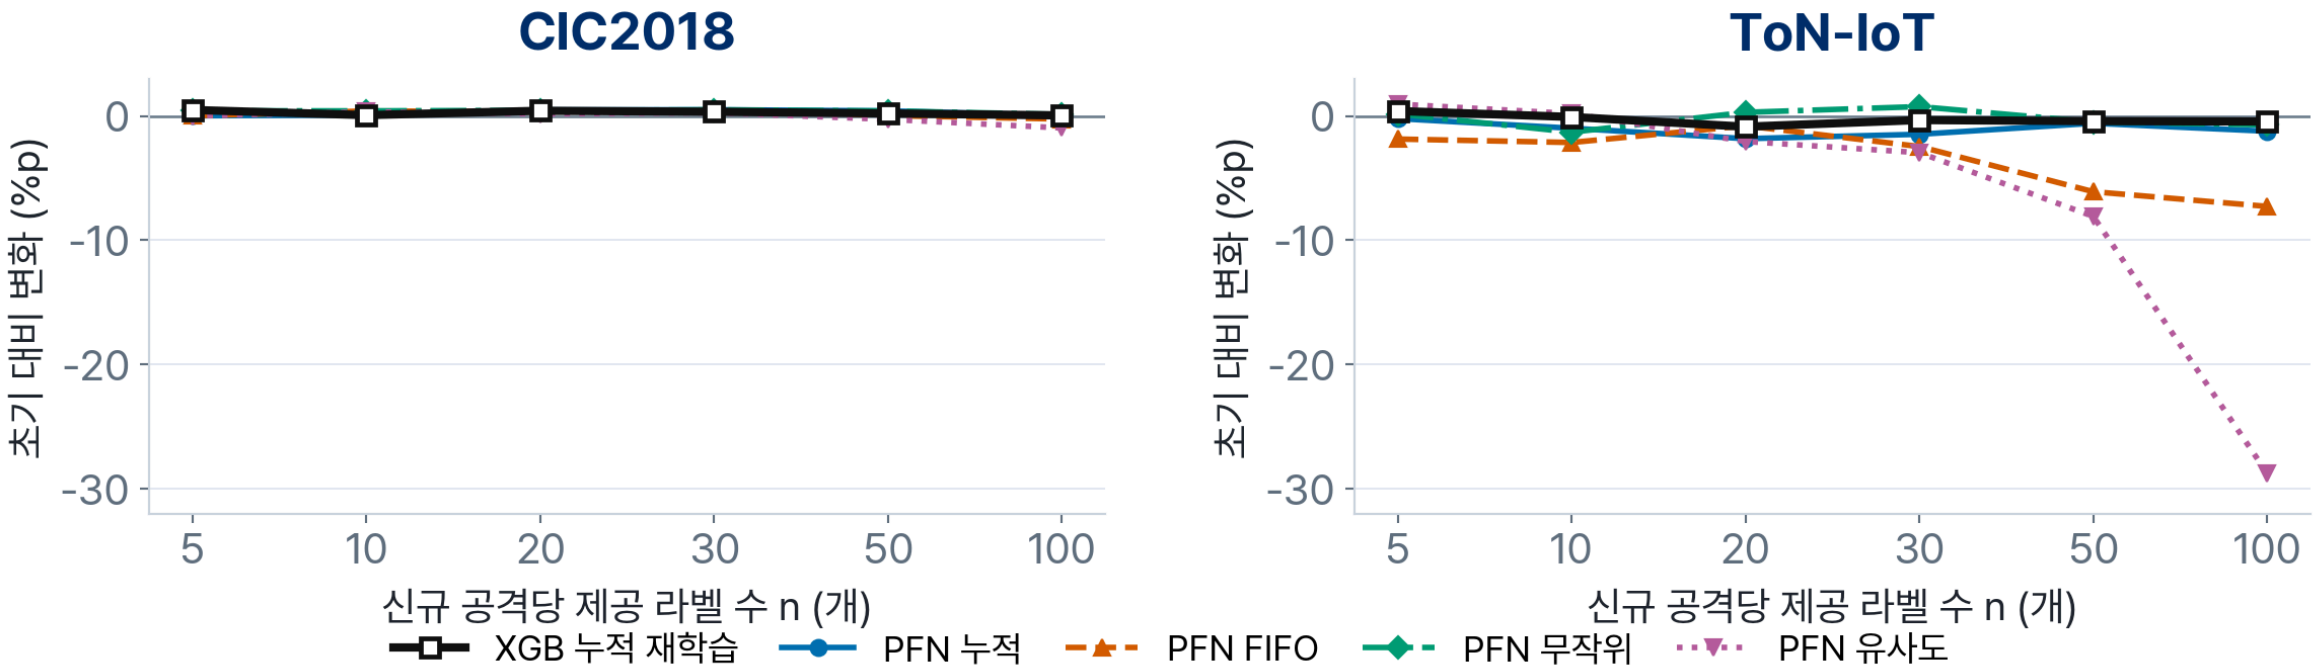


n = 100 값	XGB 누적 재학습		PFN 누적		PFN FIFO		PFN 무작위		PFN 유사도	
	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN
단위 %	52.02	65.57	53.41	64.52	51.12	64.27	51.66	64.61	49.09	48.04

결과 · 갱신 이후 초기 클래스 성능 변화

초기 정상·공격 2종의 같은 평가 표본 · 최종 − 초기 Macro-F1 (%p)

클래스당 최대 2,000개 고정 test 표본 / 같은 query 구성 / 0 아래는 초기보다 성능 하락

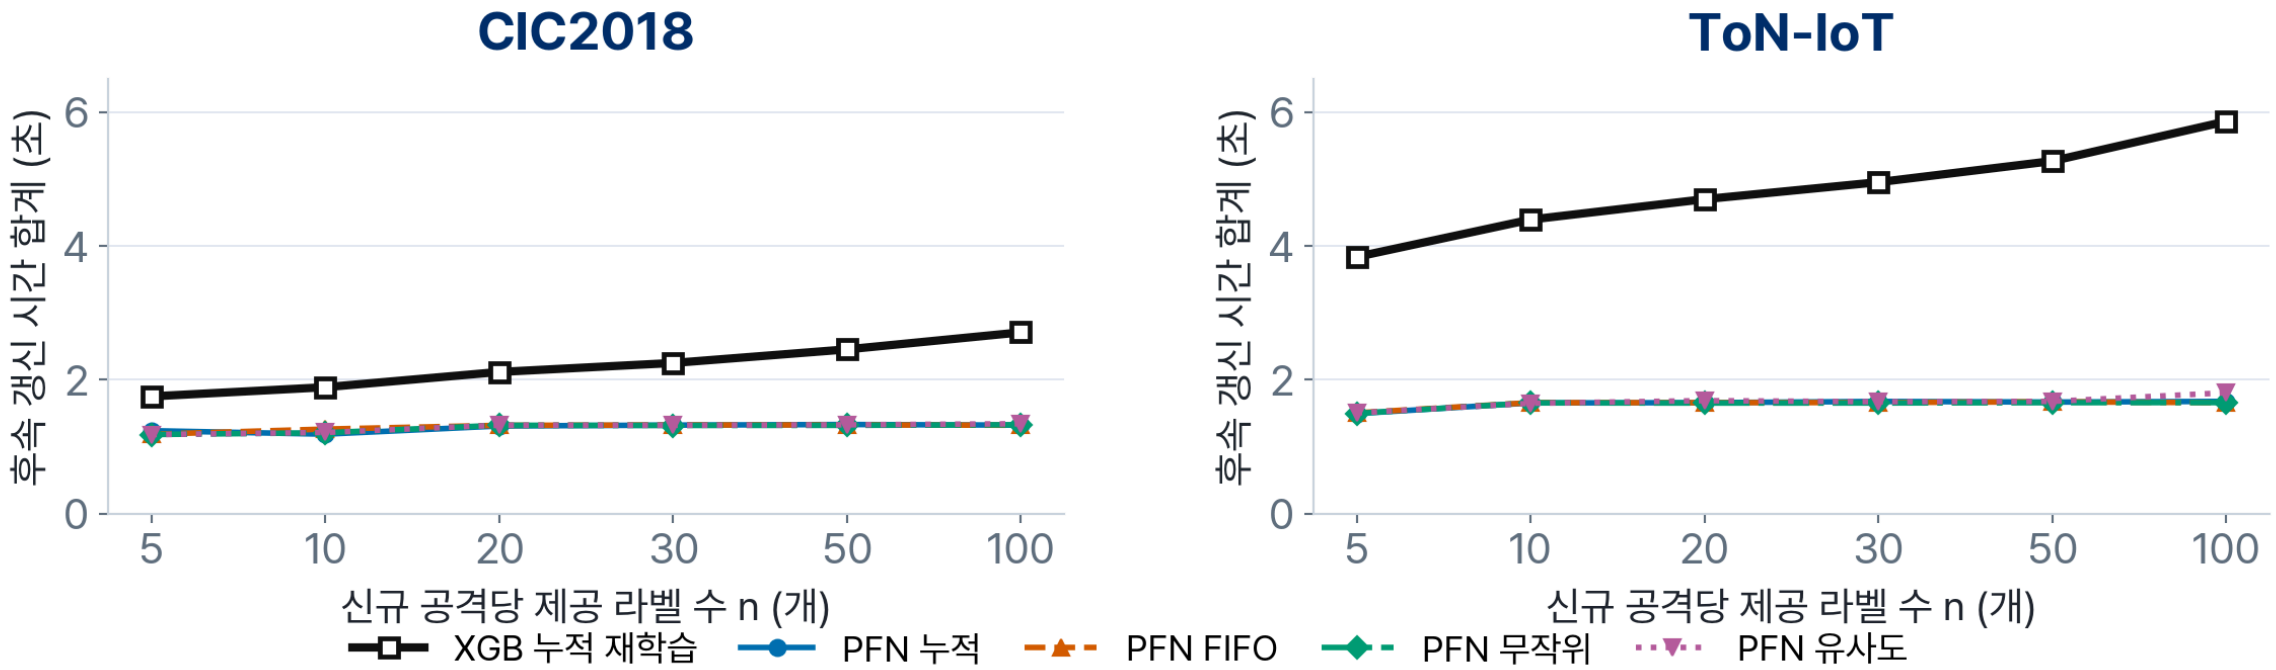


n = 100 값	XGB 누적 재학습		PFN 누적		PFN FIFO		PFN 무작위		PFN 유사도	
	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN
단위 %p	0.04	-0.44	0.05	-1.23	-0.25	-7.28	0.13	-0.72	-0.96	-28.76

결과 · 소규모 context의 후속 갱신 비용

2단계 이후 갱신 시간 합계 · 초기 준비와 모든 추론 제외

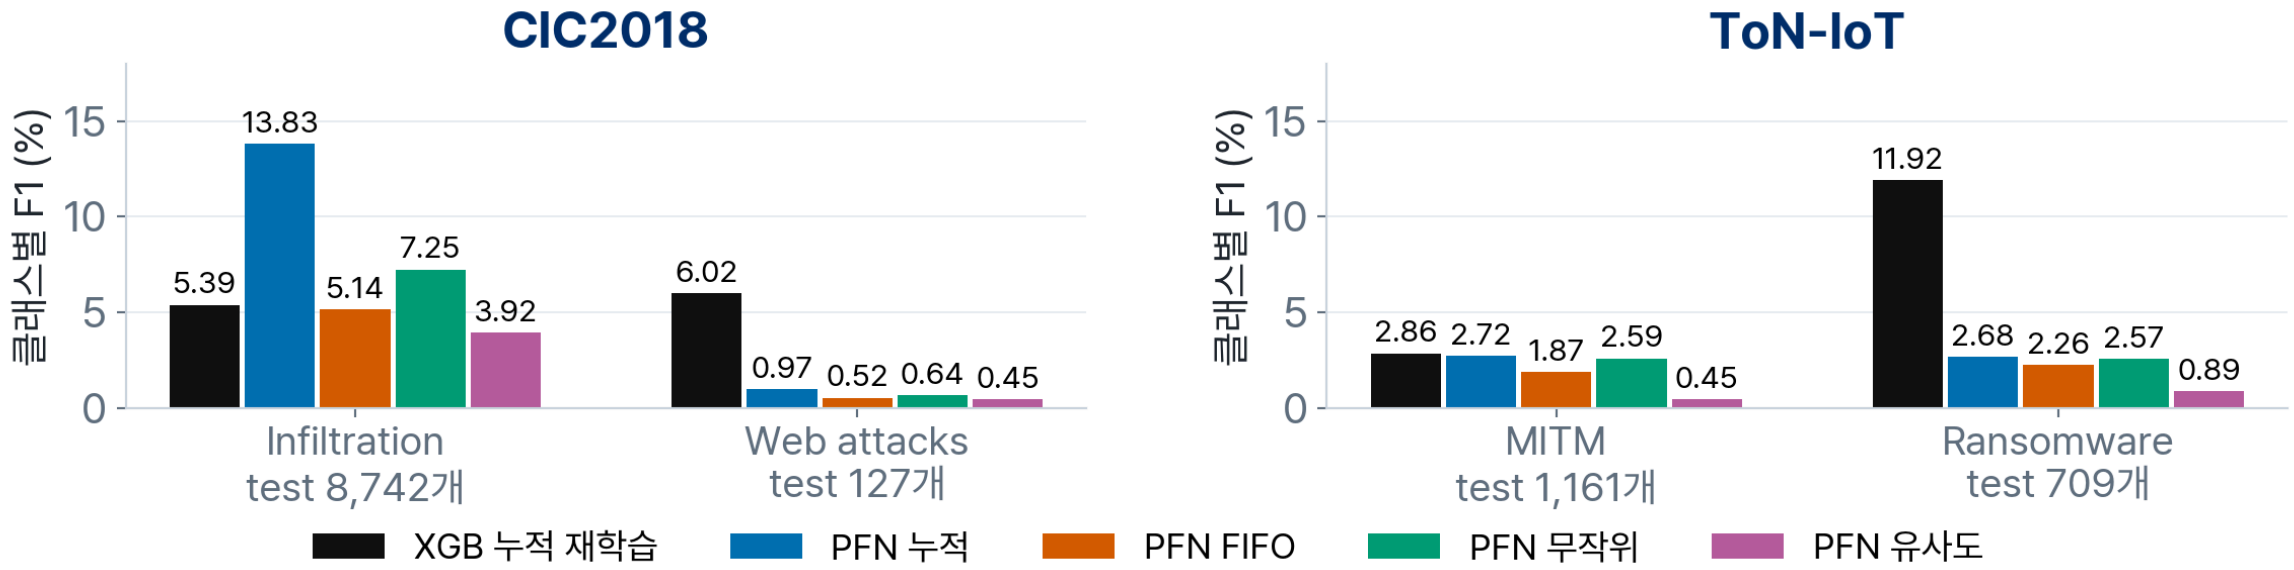
XGB 누적 재학습 / PFN 가중치 고정 후 context 선택·전처리·캐시 준비 · 동일 실행 환경에서 측정



n = 100 값	XGB 누적 재학습		PFN 누적		PFN FIFO		PFN 무작위		PFN 유사도	
	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN	CIC	ToN
단위 초	2.71	5.86	1.32	1.68	1.32	1.66	1.33	1.66	1.34	1.81

결과 해석 · 낮은 갱신 비용과 남은 Tail 문제

n = 100 · 각 데이터셋 test에서 가장 희소한 공격 2종 · test 수 내림차순



ToN Ransomware · PFN 무작위의 재현율 95.20% / 정밀도 1.30%

삭제 없는 PFN 누적에서도 낮은 Tail F1 → 버퍼만으로 설명되지 않는 한계
다음 확인 · 기존 대규모 결과와 클래스별 비교 후 가중치 적응·오탐 억제 효과 분리

부록 · CIC2018 클래스별 성능

n = 100 · 마지막 모델 전체 test · F1 (%) · 평가 표본 수 내림차순

클래스	test 수	XGB	PFN 누적	FIFO	무작위	유사도
Benign	2,652,203	97.79	99.02	98.38	98.86	96.04
DDoS	262,680	99.71	99.71	99.71	99.70	93.18
Bot	41,542	96.96	99.14	99.10	99.04	98.82
DoS	39,483	99.29	99.16	99.15	98.75	99.35
Brute force	37,696	99.98	99.97	99.97	99.97	99.97
Infiltration	8,742	5.39	13.83	5.14	7.25	3.92
Web attacks	127	6.02	0.97	0.52	0.64	0.45

각 방법은 동일한 초기·신규 사례 사용 · 전체 n의 precision·recall·F1은 실험 보고서에 수록

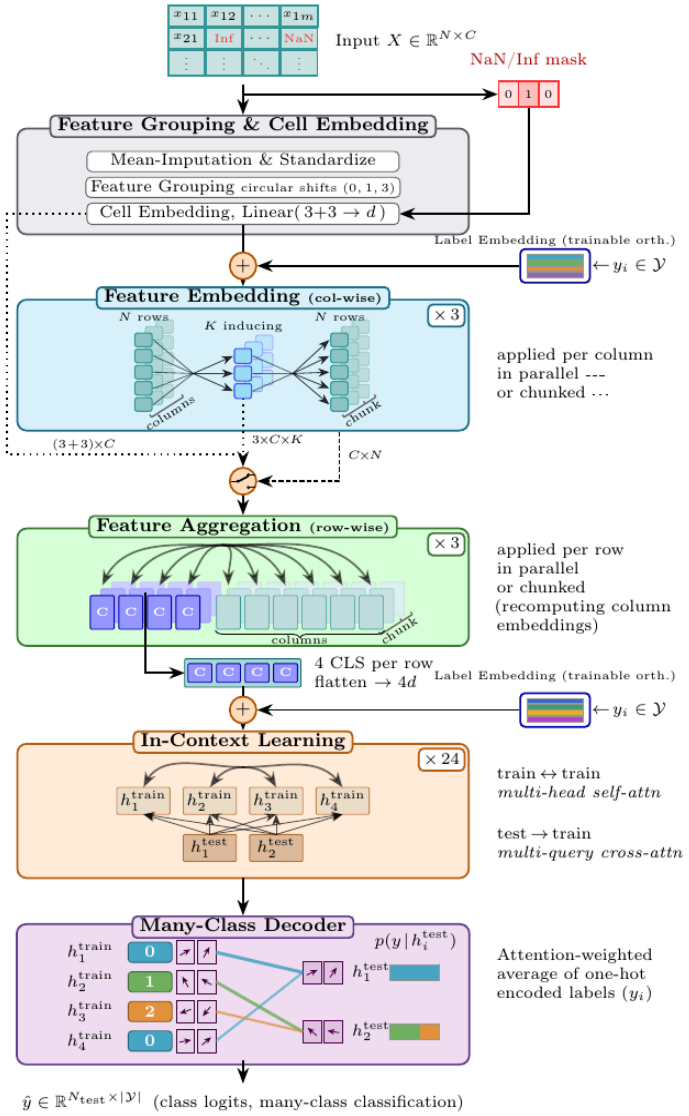
부록 · ToN-IoT 클래스별 성능

n = 100 · 마지막 모델 전체 test · F1 (%) · 평가 표본 수 내림차순

클래스	test 수	XGB	PFN 누적	FIFO	무작위	유사도
Benign	1,474,302	91.37	90.08	87.71	89.61	66.22
XSS	343,854	82.10	82.39	84.99	83.93	73.59
Password	210,951	88.60	88.31	89.03	88.18	73.88
DDoS	103,338	94.14	95.01	94.47	94.21	37.97
Injection	68,891	80.53	80.71	78.45	80.98	52.11
Backdoor	40,030	98.87	99.80	98.79	99.77	97.40
DoS	22,458	60.20	67.02	94.65	78.94	89.97
Scanning	6,029	20.57	57.37	79.68	41.78	32.51
MITM	1,161	2.86	2.72	1.87	2.59	0.45
Ransomware	709	11.92	2.68	2.26	2.57	0.89

각 방법은 동일한 초기·신규 사례 사용 · 전체 n의 precision·recall·F1은 실험 보고서에 수록

부록 · TabPFN v3의 기록 표현



1 입력값 표현

통신 기록의 각 값을 벡터로 변환
결측 표시와 context 라벨 정보 반영

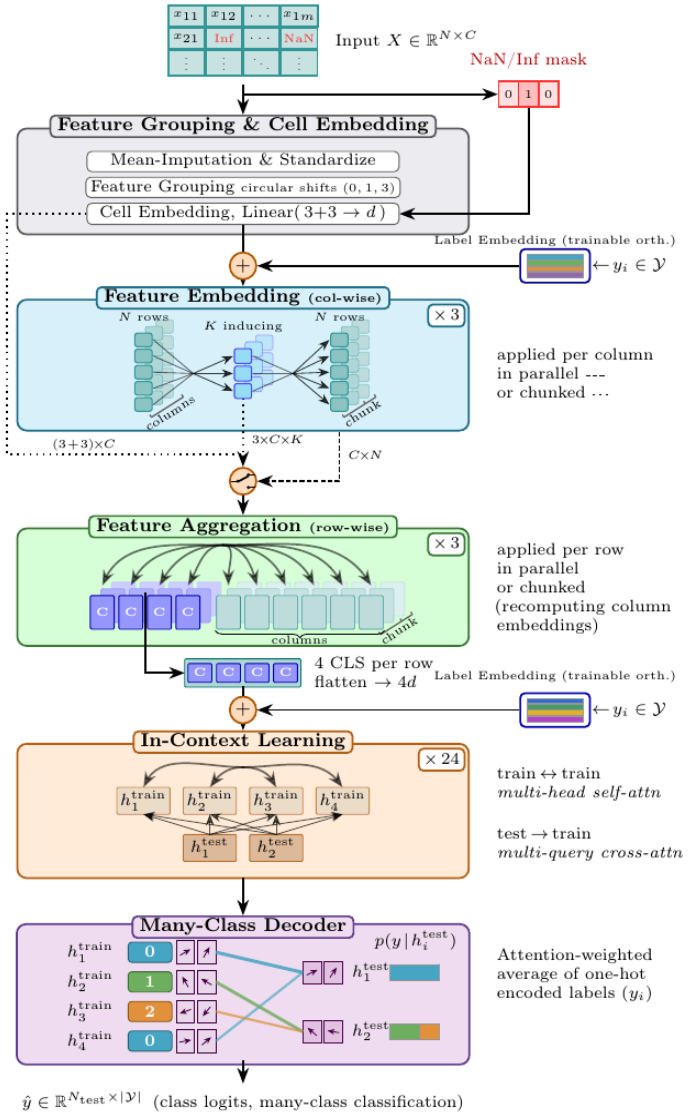
2 열의 분포 요약

여러 기록에서 같은 특징을 살펴
그 특징의 분포를 표현

3 한 기록의 특징 통합

여러 열을 행 단위 표현으로 압축
다음 단계에서 사례끼리 비교

부록 · TabPFN v3의 추론과 fine-tuning



4 Context를 참조한 예측

query가 라벨이 있는 기록을 참조
attention으로 참고 비중 계산

5 라벨을 이용한 확률 출력

context 라벨을 가중합하는 decoder
기존·신규 클래스 사례 모두 필요

별도의 가중치 fine-tuning

라벨 사례를 context와 query로 나눠 query 오차 역전파
이번 실험은 미수행 · context/cache 갱신만 사용