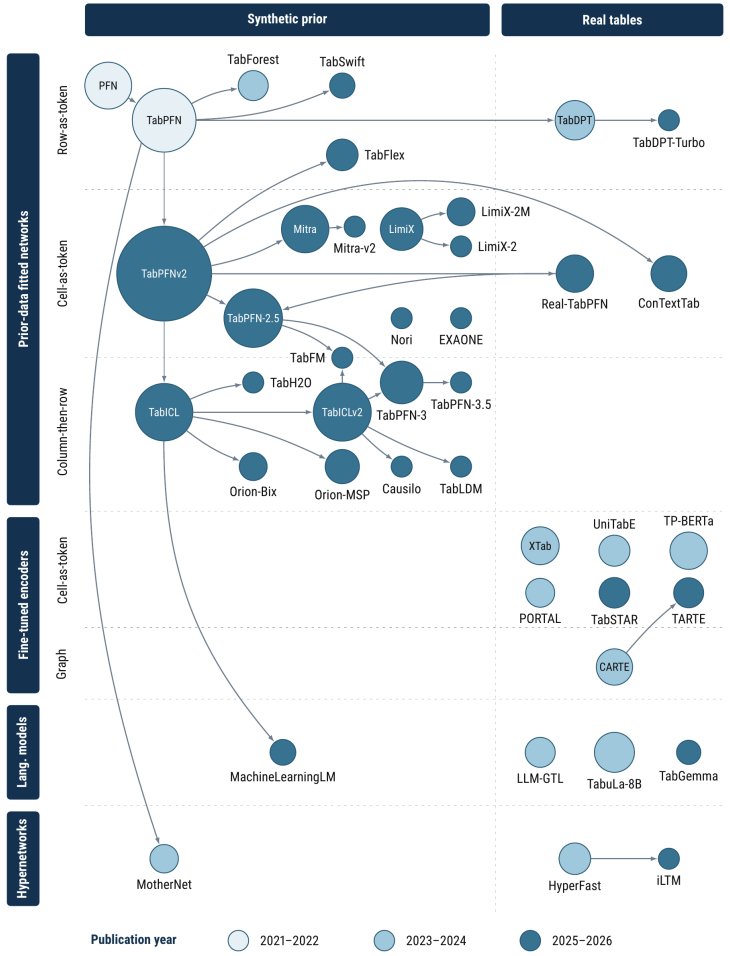
Tabular foundation model의 분류와 적용 방식

Tabular Foundation Models: A Systematic Survey · 2026



원문 Figure 3 · 기반 모델 42개

두 분류 축

사전학습 자료 합성 prior / 실제 표
전이 방식 ICL / 가중치 FT / 텍스트 생성 /
작은 모델의 가중치 생성

TabPFN · 라벨 사례를 입력으로 받는 Transformer

Context + query	사전학습 모델	예측
사례 (x, y) + 새 x	가중치 θ 고정	클래스 확률

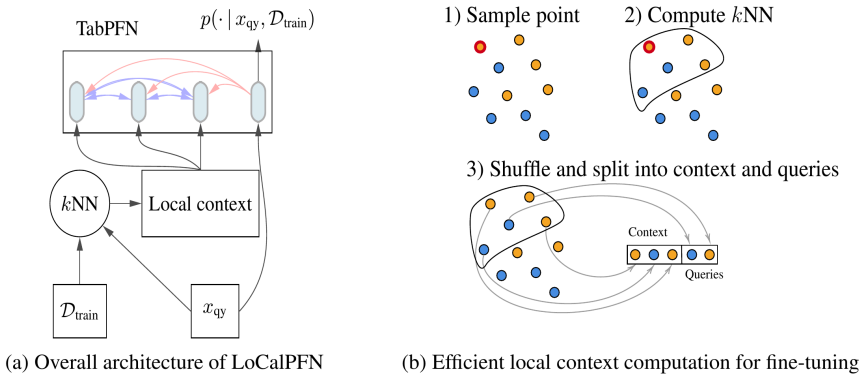
In-context learning (ICL)
입력 사례를 참고하는 예측 · 가중치 학습과 구별

v3.5의 변화 수치 표현·용량 확장 · 현재 실험은 v3

ICL에서는 사전학습 가중치와 현재 문제의 라벨 사례가 서로 다른 역할

Context 적응 · 지역 검색과 오류 기반 선택

LoCalPFN · NeurIPS 2024



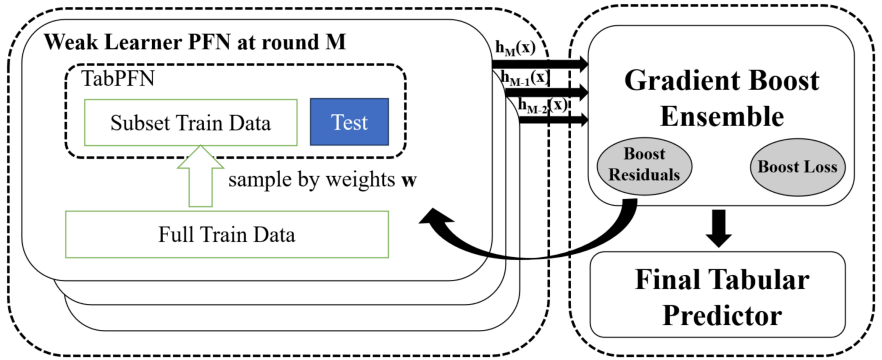
(a) Overall architecture of LoCalPFN (b) Efficient local context computation for fine-tuning

Query별 이웃 검색과 지역 context를 이용한 FT

① Query와 가까운 사례 검색
② 지역 context로 TabPFN 예측
③ 지역 배치로 가중치 FT 추가

참고점 검색 효과와 FT 효과의 분리

BoostPFN · AISTATS 2025



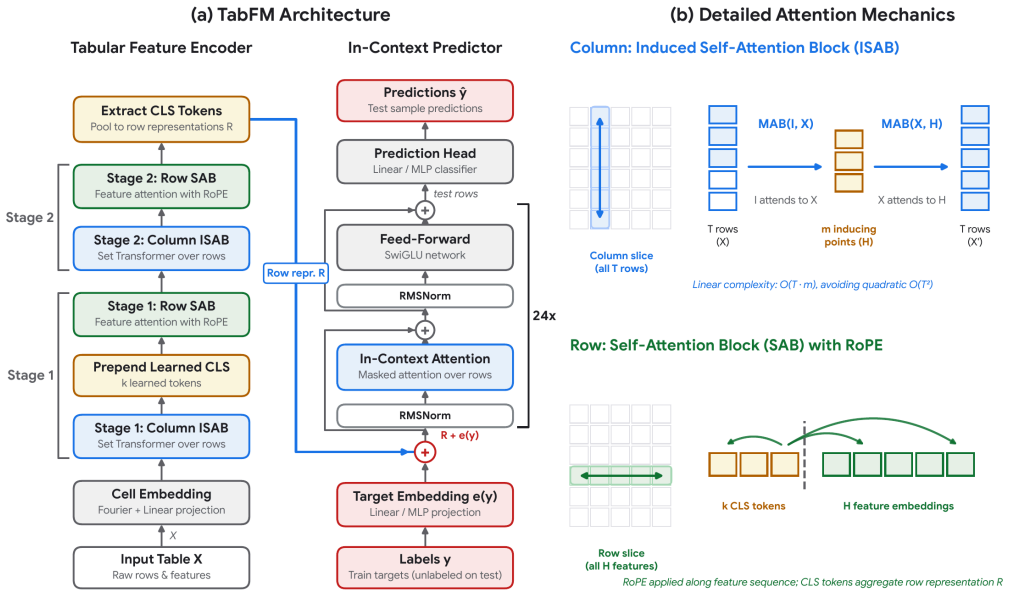
오류를 반영한 context 선택과 예측 결합

① 일부 사례로 PFN 약한 예측기 구성
② 이전 오류에 따라 표본 가중치 변경
③ 여러 예측기의 출력을 결합

참고점 실패 사례를 반영한 expert 구성

TabFM+ · 같은 모델의 여러 입력 view 결합

TabFM: A Zero-Shot Foundation Model for Tabular Data · arXiv 2026



셀 표현 → 행 표현 → context 기반 예측

TabFM+ = 고정 TabFM + 입력 view 앙상블

1 같은 모델에 다른 입력 view 제공

특징 변환·순열·교차 특징 등
32개 view에서 반복 예측

2 Validation으로 결합 가중치 학습

비음수 최소제곱으로 가중치 선택
학습 가중치 75% + 균등 가중치 25%

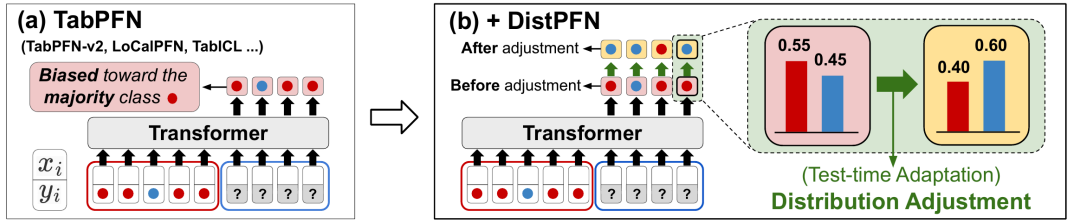
3 결합 확률의 사후 보정

본체 가중치는 고정
결합·보정에는 validation 라벨 사용

여러 예측을 얻는 비용과 결합기를 학습할 validation 라벨까지 비교에 포함

불균형 적응 · 확률 보정과 판정 기준 조절

DistPFN · ICML 2026



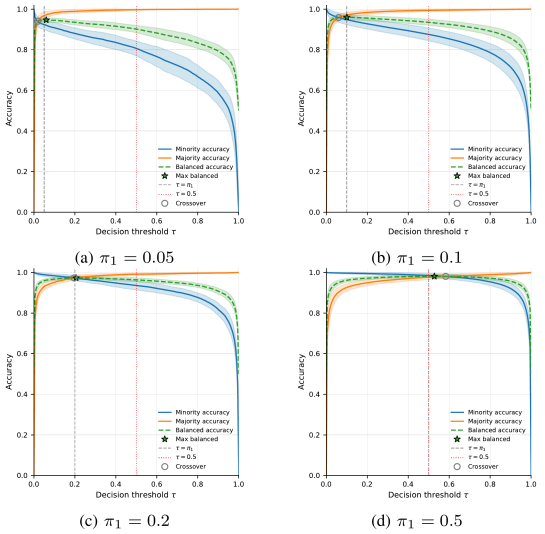
Context 클래스 비율과
예측 분포의 비로 출력 확률 보정

추가 가중치 FT 없음
원문 기본값은 query 배치 평균 분포

확인 대상
Context와 test의 클래스 비율 차이

우리 연구 prior 편향과 특징 구분 실패를 분리한 대조 실험

클래스 불균형 보정 · ITW 표기 2026



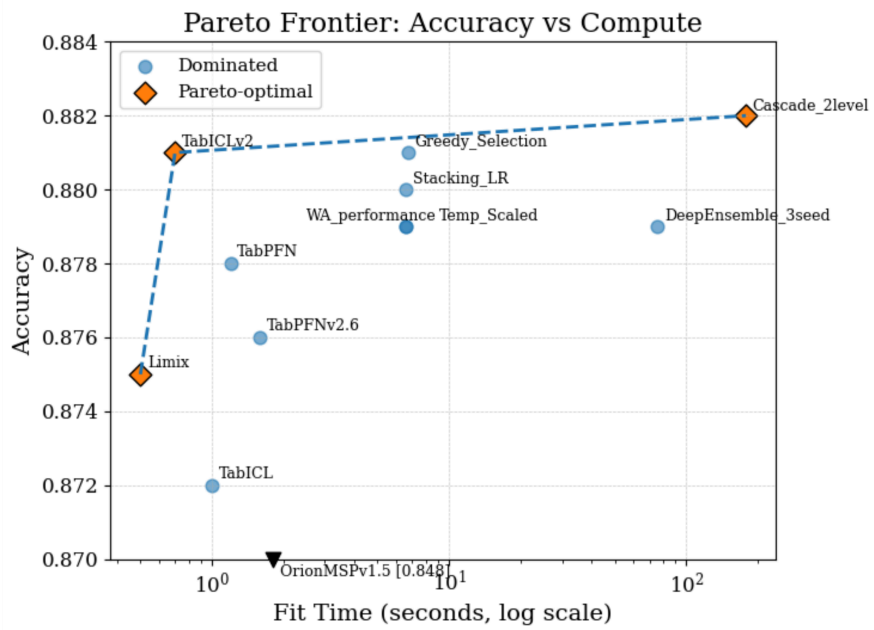
임계값에 따른 다수·소수 클래스 정확도 변화

비교 대상
임계값 조절 / 다수 클래스 축소

분포 보정의 이득은 클래스별 precision·recall과 정상 오탐으로 확인

앙상블 설계 · 모델 수보다 오류의 상호 보완

Ensembling Tabular Foundation Models · arXiv 2026



153개 분류 과제 · 평균 정확도와 준비 비용

IoT 포렌식 응용 PFN 선별 → 트리 앙상블
개별 모델 점수와 전체 pipeline 효과의 구분

1 **같은 오분류의 반복 여부 확인**

Expert를 늘려도 같은 사례를 틀리면 복구 가능한 오류의 증가 제한

2 **결합기보다 oracle 여지부터 확인**

어느 expert라도 맞힌 사례의 상한과 단일 모델의 차이 비교

3 **이득이 있을 때 선택·보정 개선**

정답으로 고친 사례와 새 오분류 분리
같은 라벨·보존량·추론 예산으로 비교

단일 expert의 구분 능력과 결합 정책의 효과를 분리한 검증 필요

LotBoNC · 원본 트래픽에서 평가 조건을 만드는 과정

LotBoNC: Novel Botnet Traffic Classification under Long-tailed Distributions · ASIA CCS 2026

각 벤치마크에서 독립 적용

실제 트래픽	입력 전처리	평가 집합 구성
IoT-23 / ISCX-Bot / CTU-13	PCAP → flow → burst / token	같은 출처 안에서 사례·라벨 분리

실험자가 조절한 부분 라벨 공개 대상과 클래스별 표본 수

라벨 집합 L	비라벨 집합 U
알려진 공격만 포함 클래스별 같은 수의 사례	알려진 공격 + 새로운 공격 불균형 구성 · 정답은 학습에서 비공개



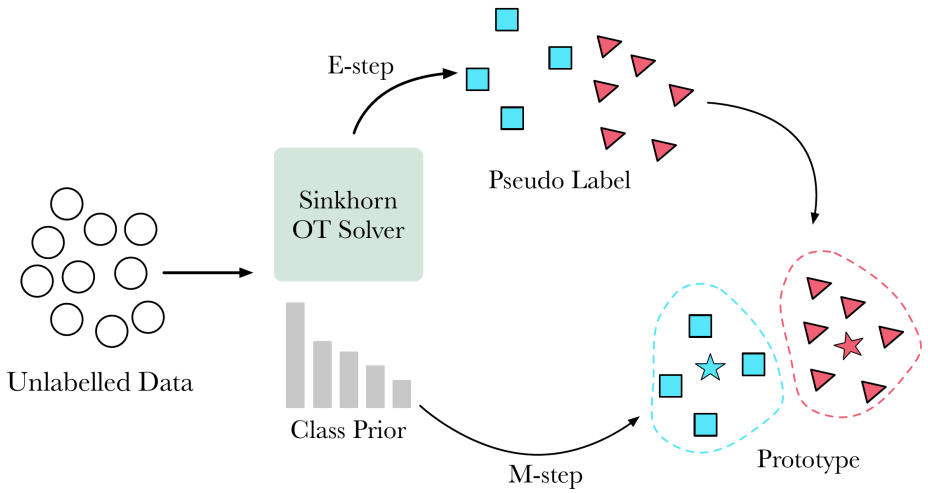
구성 예시 · 파랑·청록 = known / 주황 = novel

블록 수는 설명용 예시 · 실제 표본 수와 별개



Known / novel 총량 비 γ = 1, 5, 10

LotBoNC · 임시 정답과 클래스 표현의 반복 갱신



원문 Figure 4 · 임시 정답 배정과 표현 학습의 반복

E-step의 배정 기준

예측과 맞는 배정 + 추정 클래스 비율 유지
예시 10개 사례 · prior 0.6 : 0.3 : 0.1

1 E-step · batch 전체의 임시 정답

높은 예측 확률을 우선하되
클래스별 총량을 추정 prior에 맞춤

2 M-step · 클래스 대표 표현 갱신

배정된 사례로 prototype과 prior 수정
이전 값과 새 값을 이동평균으로 결합

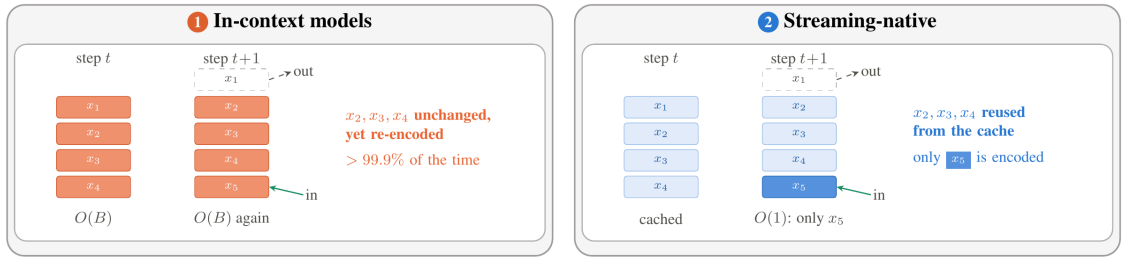
3 표현이 좋아지도록 가중치 학습

대조 손실 + prototype 손실
Encoder 가중치 θ 갱신 후 반복

데이터 스트림 · 예측 순서와 context 비용의 분리

Rethinking Tabular Foundation Models On Data Streams · arXiv 2026

새 사례 도착	→	먼저 예측	→	정답 도착	→	그다음 갱신
x_t		현재 memory 사용		d개 사례 뒤		Memory M 변경



매번 context 재계산 / 저장된 표현 재사용

기본 조건 메모리 1,000행 · 즉시 라벨
실제 stream 5개 + 합성 drift stream 4개

1 메모리 정책과 backbone을 분리

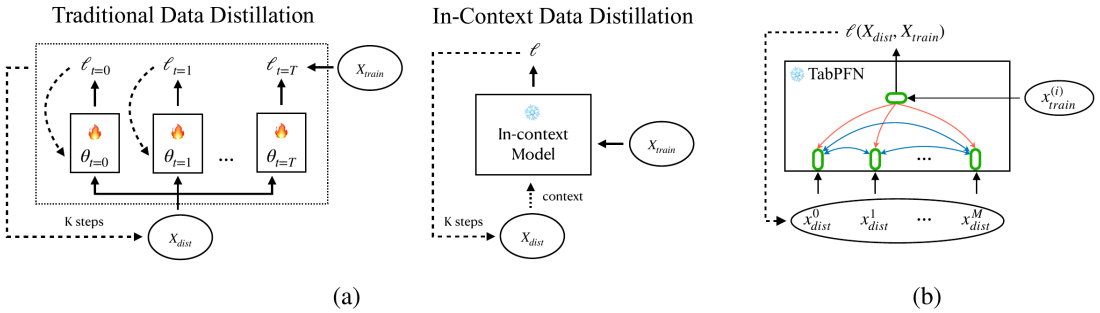
같은 모델에서 FIFO와 선택 정책 비교
단순 FIFO도 강한 기준선

2 행 교체와 context encoding 구분

갱신 빈도를 줄여도 예측마다 재계산하면
큰 비용은 계속 발생

ICD · 모델 대신 context의 특징값 학습

In-Context Data Distillation with TabPFN · ICLR ME-FoMo Workshop 2024



왼쪽 모델 학습을 포함한 증류 / 오른쪽 context 직접 최적화

고정하는 것 모델 가중치 θ, context 라벨 y

바꾸는 것 context의 특징값 X

$$X \leftarrow X - \alpha \cdot \partial Loss/\partial X$$

1 작은 합성 context 준비

클래스별 같은 수의 라벨 고정
특징값은 최적화 가능한 변수

2 실제 train 사례를 query로 예측

현재 합성 context + 고정 TabPFN
실제 정답과의 오차 계산

3 오차로 context 특징값 수정

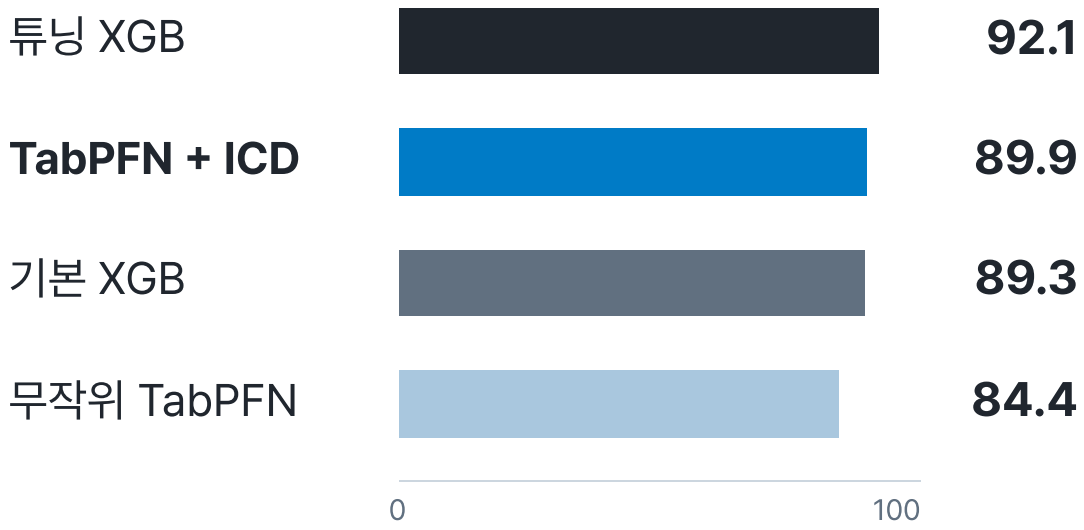
Gradient를 입력 X까지 전달
가중치 θ를 바꾸지 않고 반복

ICD의 적용 조건 · 확보 라벨과 보존 예산

원문 실험 큰 라벨 집합 → 1,000개 context

48개 표 분류 과제 · 전체 2,000~200,000행
Train / validation / test = 80 / 10 / 10

F1 중앙값 (%)



같은 48개 자료의 중앙값 · IDS Macro-F1과 별개

1 압축에 쓴 라벨 수와 보관량 구분

큰 train 전체로 context를 최적화
Context 1,000개 ≠ 확보 라벨 1,000개

2 반복 최적화 비용까지 포함

Context 증류 + validation 선택
최종 cache 준비 + query 추론

3 우리 연구의 적용 순서

극소수 신규 라벨의 단계 평가부터
라벨 이력 증가 시 압축 방법 비교