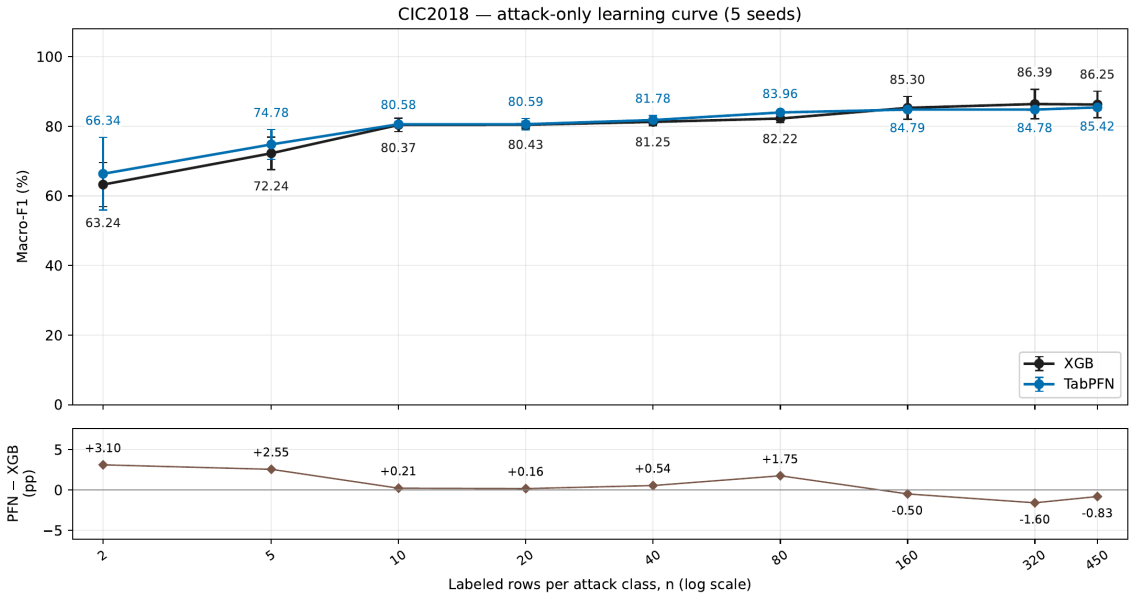
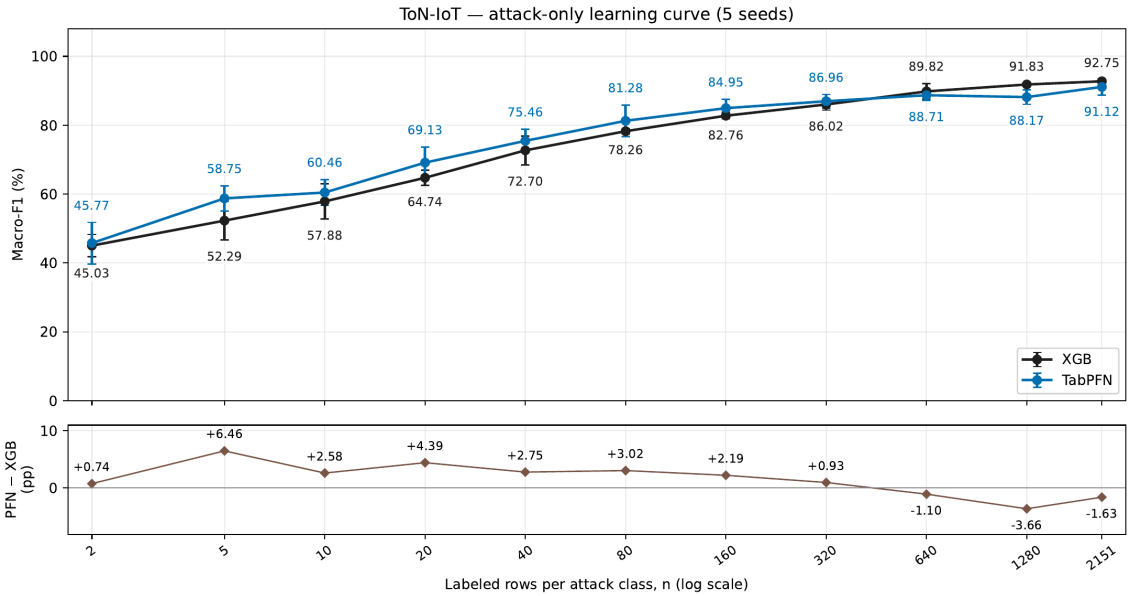
극소수 공격 사례의 분류 가능성과 모델 차이

공격 클래스만 평가 · 정상 제외 · 클래스별 같은 n개 학습 · 고정 attack test · 5 seeds



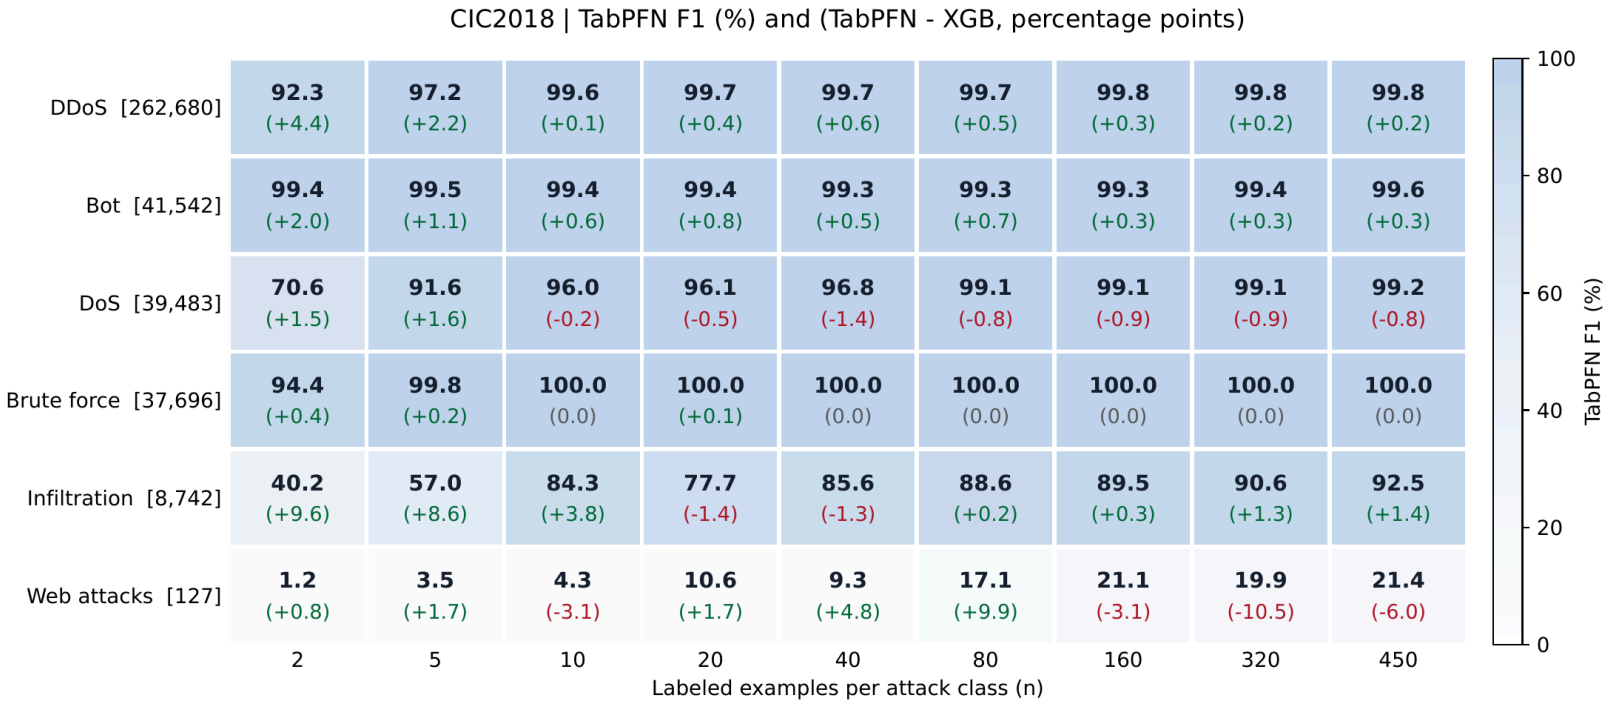


CIC2018 n=5 +2.55%p
n=10 +0.21%p

ToN-IoT n=5 +6.46%p
n=10 +2.58%p

공격 종류를 구분하는 성능은 형성 · 모델 격차는 데이터와 n에 따라 축소·역전

CIC2018 · 평균 점수가 가리는 공격별 난이도



Mean over seeds 43-47 | Rows: test support descending [count] | Green: PFN higher; red: XGB higher

n=10의 TabPFN F1

DDoS 99.6
Bot 99.4
Brute force 100.0

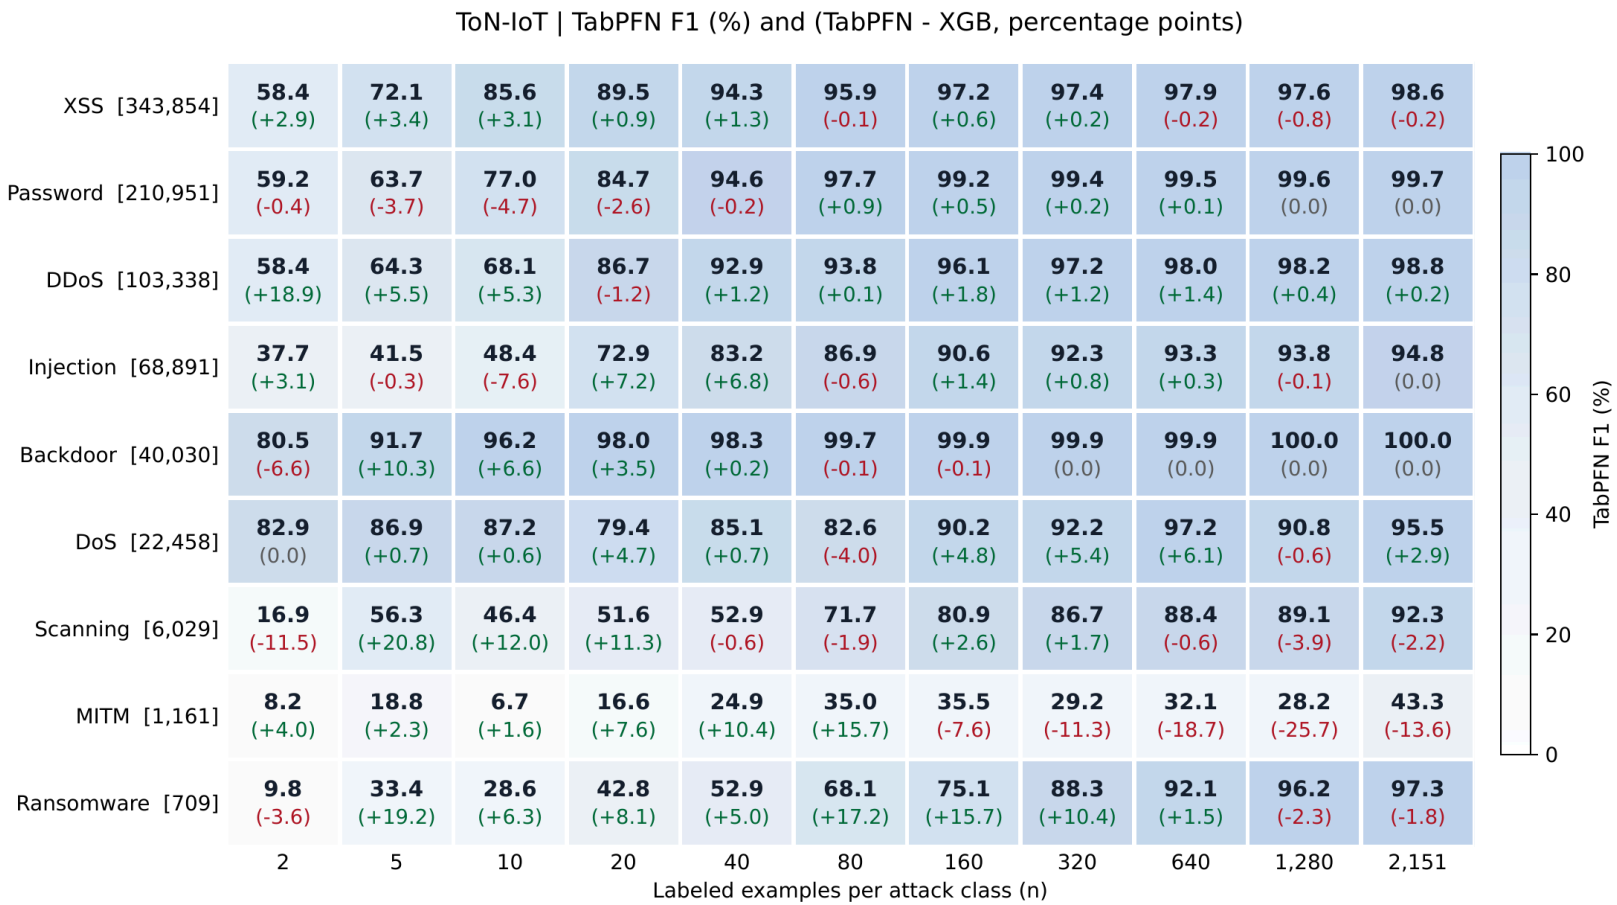
어려운 공격

Infiltration 84.3
Web attacks 4.3

PFN−XGB

+3.8%p / −3.1%p

ToN-IoT · 소수 사례의 효과도 공격마다 다름



Mean over seeds 43-47 | Rows: test support descending [count] | Green: PFN higher; red: XGB higher

n=10의 TabPFN F1

Backdoor 96.2
DoS 87.2
XSS 85.6

어려운 공격

Scanning 46.4
Ransomware 28.6
MITM 6.7

PFN−XGB

+12.0 / +6.3 / +1.6%p

일부 공격은 TabPFN 이득 · MITM 등은 두 모델의 절대 성능이 계속 낮음

LotBoNC · 원본 트래픽에서 평가 조건을 만드는 과정

LotBoNC: Novel Botnet Traffic Classification under Long-tailed Distributions · ASIA CCS 2026

각 벤치마크에서 독립 적용

실제 트래픽	입력 전처리	평가 집합 구성
IoT-23 / ISCX-Bot / CTU-13	PCAP → flow → burst / token	같은 출처 안에서 사례·라벨 분리

실험자가 조절한 부분 라벨 공개 대상과 클래스별 표본 수

라벨 집합 L	비라벨 집합 U
알려진 공격만 포함 클래스별 같은 수의 사례	알려진 공격 + 새로운 공격 불균형 구성 · 정답은 학습에서 비공개



구성 예시 · 파랑·청록 = known / 주황 = novel

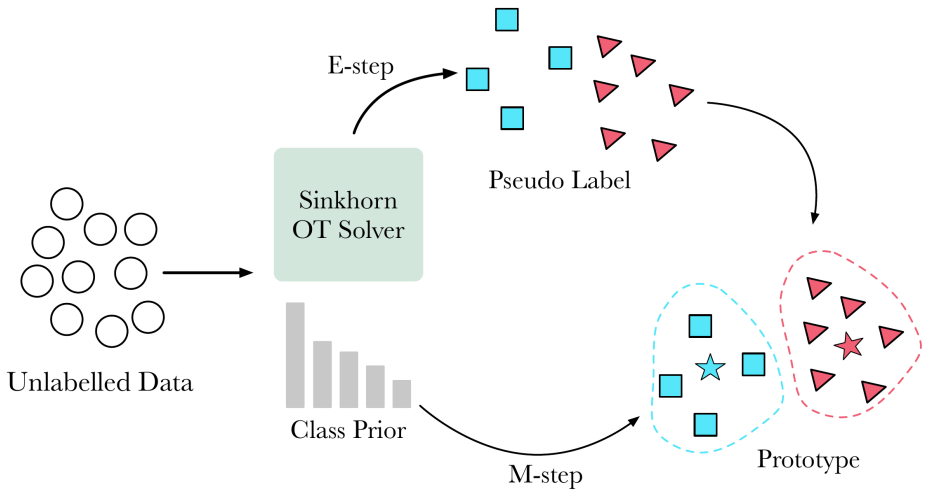
블록 수는 설명용 예시 · 실제 표본 수와 별개



Known / novel 총량 비 γ = 1, 5, 10

참고점 같은 출처에서 known·novel과 라벨 공개 범위를 명시 · 스트림 재현과 구분

LotBoNC · 임시 정답과 클래스 표현의 반복 갱신



원문 Figure 4 · 임시 정답 배정과 표현 학습의 반복

E-step의 배정 기준

예측과 맞는 배정 + 추정 클래스 비율 유지
예시 10개 사례 · prior 0.6 : 0.3 : 0.1

1 E-step · batch 전체의 임시 정답

높은 예측 확률을 우선하되
클래스별 총량을 추정 prior에 맞춤

2 M-step · 클래스 대표 표현 갱신

Prototype(클래스 중심)·prior(빈도) 갱신
이전 값과 새 값을 이동평균으로 결합

3 표현이 좋아지도록 가중치 학습

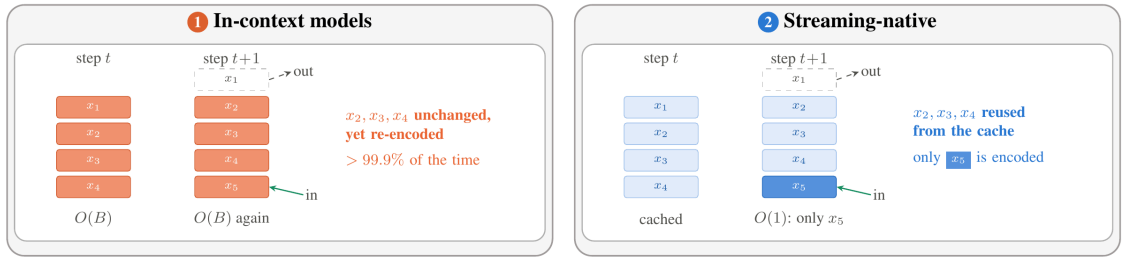
대조 손실 + prototype 손실
Encoder 가중치 θ 갱신 후 반복

참고점 라벨 없는 novel·긴 꼬리 학습 방식 · 우리 감독 분류 모델로 직접 채택하지 않음

데이터 스트림 · 예측 순서와 context 비용의 분리

Rethinking Tabular Foundation Models On Data Streams · arXiv 2026

새 사례 도착	→	먼저 예측	→	정답 도착	→	그다음 갱신
x_t		현재 memory 사용		d개 사례 뒤		Memory M 변경



매번 context 재계산 / 저장된 표현 재사용

기본 조건 메모리 1,000행 · 즉시 라벨
실제 stream 5개 + 합성 drift stream 4개

1 메모리 정책과 backbone을 분리

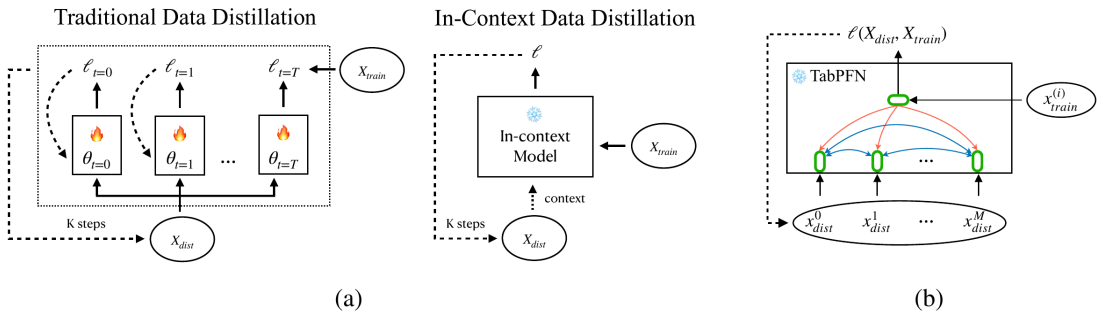
같은 모델에서 FIFO와 선택 정책 비교
단순 FIFO도 강한 기준선

2 행 교체와 context encoding 구분

갱신 빈도를 줄여도 예측마다 재계산하면
큰 비용은 계속 발생

ICD · 모델 대신 context의 특징값 학습

In-Context Data Distillation with TabPFN · ICLR ME-FoMo Workshop 2024



왼쪽 모델 학습을 포함한 증류 / 오른쪽 context 직접 최적화

고정하는 것 모델 가중치 θ, context 라벨 y

바꾸는 것 context의 특징값 X

$$X \leftarrow X - \alpha \cdot \partial Loss/\partial X$$

1 작은 합성 context 준비

클래스별 같은 수의 라벨 고정
특징값은 최적화 가능한 변수

2 실제 train 사례를 query로 예측

현재 합성 context + 고정 TabPFN
실제 정답과의 오차 계산

3 오차로 context 특징값 수정

Gradient를 입력 X까지 전달
가중치 θ를 바꾸지 않고 반복