

동일 feature 를 공유하는 클래스

행 : 원래 라벨 · 열 : 동일 feature 의 다른 라벨 · 셀 : 행 클래스 대비 비율 (%) · 정제 전 표본 수 내림차순

CIC2018

전체 상충 행 26.65%

	Ben	DDoS	Brute	DoS	Bot	Inf	Web
Benign		.		.		26.7	.
DDoS	.						
Brute force				67.2			
DoS	.		34.8				
Bot							
Infiltration	75.1						.
Web attack	69.5					17.0	

ToN-IoT

전체 상충 행 60.73%

	Ben	DDoS	XSS	Pass	Scan	Inj	DoS	Back	MitM	Ran
Benign		13.7	3.3	.	49.9	.	8.6	2.3	8.2	2.4
DDoS	76.3		69.1	22.4	1.4	75.0	.	.	.	.
XSS	37.0	12.2		15.4	.	29.4	6.8	.	.	.
Password	33.3	.	.		.	.	.	.	.	.
Scanning	97.1	.	.	.		.	.	.	.	3.6
Injection	7.5	3.4	9.0	2.1	2.0		2.0	.	.	.
DoS	33.1	12.8	26.3	.	9.1	12.2		.	1.6	
Backdoor	1.3	.	.	.	.	.	.			.
MitM	8.5	3.1	7.2	2.1	2.8	5.3	7.5			
Ransomware	9.2	.	1.0		1.9	.		.		

BoT-IoT

전체 상충 행 6.11%

	DoS	DDoS	Recon	Ben	Theft
DoS		2.0	1.2	1.2	
DDoS	1.6		.	.	
Recon	2.5	.		35.6	1.4
Benign	7.7	.	63.8		
Theft			67.6		

UNSW-NB15

전체 상충 행 1.33%

	Ben	Expl	Fuzz	Gen	Recon	DoS	Back	Shell	Anal	Worm
Benign										
Exploits			6.0	4.6	4.7	3.9	4.0	3.6		.
Fuzzers		18.0		15.2	15.8	13.4	14.0	13.0		.
Generic		4.6	1.4		.	.	66.6	.		.
Recon		30.5	31.0	3.9		29.4	29.6	3.4		
DoS		9.2	9.1	8.4	8.6		8.6	7.5		
Backdoor		18.1	18.7	19.1	17.1	16.7		13.7		.
Shellcode		5.8	6.6	3.5	3.7	3.3	11.8			
Analysis										
Worms		.	.	4.4			4.4			

빈칸 : 0% · ∴ 1% 미만 회색 : 동일 클래스 같은 행의 중복 집계로 합산 불가



Web attack: 1,764 + 432 - 중복 429 = 1,767 행 제거 · 771 행 잔존

정제 이후 클래스 분포

전체 데이터 기준 (train + validation + test) · 정제 후 표본 수 내림차순 · 비중 단위 %

CIC2018

클래스	정제 전	정제 후	비중 전	비중 후
Benign	17,514,626	12,798,328	87.070	86.736
DDoS	1,324,350	1,316,025	6.584	8.919
Bot	207,703	207,703	1.033	1.408
DoS	302,966	197,415	1.506	1.338
Brute force	575,194	188,414	2.859	1.277
Infiltration	188,152	46,761	0.935	0.317
Web attack	2,538	771	0.013	0.005
합계	20,115,529	14,755,417	100.000	100.000

Infiltration 75.1% 감소
Web attack 69.6% 감소 · 정제 후 771 행

ToN-IoT

클래스	정제 전	정제 후	비중 전	비중 후
Benign	16,792,214	6,446,120	61.018	59.646
XSS	2,834,435	1,670,497	10.299	15.457
Password	1,594,777	1,061,699	5.795	9.824
DDoS	4,141,256	925,247	15.048	8.561
Injection	381,777	341,263	1.387	3.158
Backdoor	203,384	200,688	0.739	1.857
DoS	203,456	113,655	0.739	1.052
Scanning	1,358,977	39,069	4.938	0.362
MitM	6,013	5,446	0.022	0.050
Ransomware	3,971	3,604	0.014	0.033
합계	27,520,260	10,807,288	100.000	100.000

Global 과 residual expert 구조


학습 데이터의 역할 분리 · Global 구성 / Expert 구성 / S·V 학습

Global 풀 · 공통 context


Expert 풀 · residual 과 expert

Route 풀 · S/V 학습

오프라인 · 모델 구성



온라인 · 입력별 예측



첫 context 구성 실험 · 공통 anchor 와 residual block

정제 CIC2018·ToN · seed 43 · Global 고정 · K = 2, 4, 6, 8

각 expert 에 제공하는 context

공통 anchor

모든 클래스의 기본 사례 · 클래스당 최대 2,000 행

+

Residual 군집별 특화 block

Global 오류 양상과 입력 특성을 반영한 표본 선택

같은 TabPFN backbone · 서로 다른 context

K 에 따른 expert 구성과 context 행 수 합계

Expert 수	CIC2018	ToN
K = 2	250,481	231,534
K = 4	277,505	270,546
K = 6	328,037	338,908
K = 8	376,411	421,513

공통 anchor	CIC2018	ToN
행 수	12,224	18,717

합계에 expert 별 anchor 반복 포함 · K 별 총예산 상이

동일 test 에서 비교한 Global 과 expert 의 분류 성능

K = 4 · 클래스별 F1 · test 표본 수 내림차순 · 파란 숫자 : 표시값 기준 Global 대비 개선

CIC2018

클래스	표본 수	Global	e1	e2	e3	e4
Benign	2,652,203	0.996	0.998	0.894	0.795	0.875
DDoS	262,680	0.992	0.992	1.000	1.000	1.000
Bot	41,542	0.998	0.998	0.993	0.998	0.998
DoS	39,483	0.992	0.992	0.986	0.996	0.992
Brute force	37,696	1.000	1.000	1.000	1.000	1.000
Infiltration	8,742	0.288	0.229	0.027	0.018	0.023
Web attack	127	0.210	0.353	0.069	0.077	0.199
Macro-F1		0.782	0.794	0.710	0.698	0.727

Infiltration: 모든 expert 에서 Global 보다 낮은 F1
Web attack: e1 의 test 개선 , validation 확인에서는 미개선

ToN

클래스	표본 수	Global	e1	e2	e3	e4
Benign	1,474,302	0.922	0.912	0.909	0.858	0.920
XSS	343,854	0.830	0.825	0.850	0.834	0.850
Password	210,951	0.892	0.890	0.892	0.891	0.891
DDoS	103,338	0.980	0.975	0.982	0.968	0.971
Injection	68,891	0.903	0.850	0.935	0.460	0.873
Backdoor	40,030	0.999	0.998	0.999	0.997	0.999
DoS	22,458	0.977	0.962	0.954	0.715	0.969
Scanning	6,029	0.039	0.616	0.564	0.761	0.660
MitM	1,161	0.132	0.032	0.039	0.036	0.052
Ransomware	709	0.121	0.094	0.106	0.132	0.117
Macro-F1		0.680	0.715	0.723	0.665	0.730

각 expert 가 같은 전체 test 를 분류 · 다른 클래스에서 발생한 FP 까지 포함한 F1

S/V 적용 결과 · ToN 호출 활성화, CIC2018 호출 0 건

Seed 43 · validation 에서 호출 · 채택 기준 선택 · 전체 test 평가

CIC2018

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.7824	0.00	0.00
K = 2	0.7824	0.00	0.00
K = 4	0.7824	0.00	0.00
K = 6	0.7824	0.00	0.00
K = 8	0.7824	0.00	0.00

K = 2, 4, 6, 8 모두 Global 예측 유지

ToN

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.6796	0.00	0.00
K = 2	0.7636	100.00	5.26
K = 4	0.7617	100.00	1.23
K = 6	0.7677	100.00	4.09
K = 8	0.7463	100.00	0.69

K = 4 Scanning F1 0.0394 → 0.8587

호출률 : 정책상 expert 호출 표본 비율 · 채택률 : expert 출력 수락 표본 비율 · 분모는 전체 test

정제 데이터의 SOTA 와 현재 모델 성능

Seed 43 · 동일 정제 test · 대표 설정 K = 4 · Macro-F1

방법	CIC2018	ToN	학습 정보
Global TabPFN v3	0.7824	0.6796	공통 100,000 행
XGBoost	0.7821	0.6983	공통 100,000 행
BoostPFN	0.7148	0.5866	공통 100,000 행
LoCalPFN · FT	0.7024	0.6462	공통 100,000 행
DistPFN · v3	0.7839	0.6682	공통 100,000 행
XGBoost · 전체 train	0.7795	0.7162	전체 train
현재 모델 · K = 4 · S+V	0.7824	0.7617	Global + Expert·Route 풀

첫 5 개 방법은 같은 100,000 개 train ID 사용 · 전체 train XGB 와 현재 모델은 추가 학습 데이터 사용

Global·DistPFN: v3 · BoostPFN·LoCalPFN: v1 · LoCalPFN 은 미세조정 포함

SOTA 측정 비용과 현재 모델의 호출

RTX 4090 24GB · 최대 2 개 작업 병렬 · 자원 경합을 포함한 경과 시간

방법	CIC 학습 초	CIC 추론 초	ToN 학습 초	ToN 추론 초	CIC GPU GiB	ToN GPU GiB
Global TabPFN v3	36.4	1,099.3	36.7	821.7	2.92	2.94
XGBoost	2.3	1.0	55.4	1.0	0.55	0.53
BoostPFN	98.5	2,308.5	97.8	1,737.6	0.89	0.89
LoCalPFN · FT	3,196.3	17,300.8	5,783.1	11,144.8	7.54	7.54
DistPFN · v3	36.4	1,099.4	36.7	821.9	2.92	2.94
XGBoost · 전체 train	107.8	1.0	143.2	1.1	2.20	1.59

LoCalPFN: 학습에 validation, 추론에 검색 포함 · DistPFN: Global 계산과 prior 보정 포함

현재 모델 K = 4 · 정책상 호출률 CIC2018 0.00%, ToN 100.00% · 조건부 추론 시간 별도 측정 예정

후속 접근 · Benign 다양성과 tail 합성

현재 기준 : anchor + residual block · 제한된 context 에 담을 정보의 확장

1 Benign 을 다양하게 구성

프로토콜 · 통신량 · 시간 특성이 다른
정상 트래픽 패턴을 context 에 포함

프로토콜

TCP · UDP 등

통신량

패킷 수 · 크기

시간 특성

지속시간 · 간격

클래스별 할당량과 context 크기 고정
유사한 정상 사례의 반복 비중 축소
다양한 실측 사례를 선택하는 효과 확인

훈련 데이터에서 구성 · 후속 실험 예정

2 LITO 방식의 tail 합성

Feature 일부를 가린 뒤 tail 조건으로 생성
생성 결과의 클래스 일관성과 유효성 확인

Feature 마스킹

조건부 생성

생성 결과 검증

네트워크 feature 간 관계를 반영한 합성
같은 tail 할당량에서 실측 반복과 비교
실측 validation 에서 분류 성능 확인


[Yang 외 · Language-Interfaced Tabular Oversampling
via Progressive Imputation and Self Authentication · ICLR 2024](#)

후속 접근 · Feature 표현 학습과 context 최적화

훈련 데이터로 사전 학습 · 새 입력의 정답 없이 적용 가능한 구성

3 Feature 학습으로 embedding 추가

정상 · 공격 구분에 유용한 표현을 학습
각 행의 embedding 을 기존 feature 에 추가



학습 시 샘플 · 클래스 관계 활용
Context 와 query 에 동일한 변환 적용
원래 feature 만 사용한 경우와 비교

[Lopez-Martin 외 · Supervised contrastive learning over prototype-label embeddings for network intrusion detection](#)
[Information Fusion 2022 · 공개 코드](#)

4 Context 자체의 최적화

TabPFN 을 고정하고 context 값을 학습
작은 context 로 훈련 풀의 정보를 압축



고정된 context 행 수에서 최적화
원본 표본 선택과 학습된 context 비교
현재 v3 의 gradient · 메모리 조건 확인

[Ma 외 · In-Context Data Distillation with TabPFN](#)
[ICLR 2024 ME-FoMo Workshop](#)

[Valentin Thomas 연구 페이지](#)