

왜 TabPFN 인가 · 재학습 없이 context 로 적응하는 탐지기

같은 100,000 행에서 정확도는 비슷하다 · CIC2018 XGBoost 0.7821 vs TabPFN 0.7824 · ToN 0.6983 vs 0.6796 · 차이는 새 공격이 나타났을 때의 갱신 방식

학습 모델 (XGBoost 등)

새 공격 출현 → 라벨 수집 → 전체 재학습 → 재배포
모델 자체가 바뀌므로 회귀 검증을 다시 한다

전체 train 재학습 108 s / 143 s (CIC / ToN, EXP61)
추론 1,000 행당 0.0003 s · 매우 빠름

TabPFN (backbone 고정)

새 공격 출현 → 소수 라벨을 context 에 추가 → 즉시 추론
모델은 그대로 , 바뀌는 것은 context 행뿐

학습 0 s · context 적재 37 s
추론 1,000 행당 0.36 s · XGBoost 보다 약 1,000 배 느림

연구 질문

제한된 context 예산 (100,000 행 ≪ 보유 train 수백만 행) 에 무엇을 담아야 tail 공격이 회수되는가
평가 기준 : 전체 macro-F1 경쟁이 아니라 tail 클래스 회수 · benign 오탐 · 갱신에 드는 라벨과 시간

목표는 tail 회수 · benign 혼동의 원인은 클래스마다 다르다

benign 과 공격이 시간순으로 공존하는 window 라벨 → 혼동은 피할 수 없다 · 10-01 진단 : Global 이 틀린 행과 train 의 최근접 거리 (표준화 46 차원 L2, 참조 benign 은 0.01)

클래스	Global F1	→ train 해당 클래스	→ train benign	원인	context 로 고칠 수 있나
ToN scanning	0.039	0.60	2.92	context 안 benign:scanning 27:1 (prior)	가능 · expert+V 0.90
CIC infiltration	0.288	0.11	0.17	benign 과 겹치는 영역	불가 · feature 한계
ToN ransomware	0.121	0.12	2.84	benign 라벨 행이 ransomware 근사 복제	불가 · 라벨 모순
ToN mitm	0.132	9.76	11.40	train 에 없는 새 benign 블록 (drift)	시간순 갱신 · novelty 거부
CIC web attack	0.210	2.23	1.79	양성 127 행 · dos 와 오인	부분 · 양성 비율 +0.11

거리 열 : scanning 은 Global 이 놓친 (FN) 행 , 나머지는 benign 을 해당 클래스로 부른 (FP) 행 기준

context 설계의 대상 = prior 형 (scanning) 과 희소 양성형 (web attack) · 겹침 · 라벨 모순은 데이터 상한으로 보고 · drift 는 시간순 라벨 갱신으로 다룬다

동일 feature 를 공유하는 클래스

행 : 원래 라벨 · 열 : 동일 feature 의 다른 라벨 · 셀 : 행 클래스 대비 비율 (%) · 정제 전 표본 수 내림차순

CIC2018

전체 상충 행 26.65%

	Ben	DDoS	Brute	DoS	Bot	Inf	Web
Benign		.		.		26.7	.
DDoS	.						
Brute force				67.2			
DoS	.		34.8				
Bot							
Infiltration	75.1						.
Web attack	69.5					17.0	

ToN-IoT

전체 상충 행 60.73%

	Ben	DDoS	XSS	Pass	Scan	Inj	DoS	Back	MitM	Ran
Benign		13.7	3.3	.	49.9	.	8.6	2.3	8.2	2.4
DDoS	76.3		69.1	22.4	1.4	75.0	.	.	.	.
XSS	37.0	12.2		15.4	.	29.4	6.8	.	.	.
Password	33.3	.	.		.	.	.	.	.	.
Scanning	97.1	.	.	.		.	.	.	.	3.6
Injection	7.5	3.4	9.0	2.1	2.0		2.0	.	.	.
DoS	33.1	12.8	26.3	.	9.1	12.2		.	1.6	
Backdoor	1.3	.	.	.	.	.	.			.
MitM	8.5	3.1	7.2	2.1	2.8	5.3	7.5			
Ransomware	9.2	.	1.0		1.9	.		.		

BoT-IoT

전체 상충 행 6.11%


	DoS	DDoS	Recon	Ben	Theft
DoS		2.0	1.2	1.2	
DDoS	1.6		.	.	
Recon	2.5	.		35.6	1.4
Benign	7.7	.	63.8		
Theft			67.6		

UNSW-NB15

전체 상충 행 1.33%

	Ben	Expl	Fuzz	Gen	Recon	DoS	Back	Shell	Anal	Worm
Benign										
Exploits			6.0	4.6	4.7	3.9	4.0	3.6		.
Fuzzers		18.0		15.2	15.8	13.4	14.0	13.0		.
Generic		4.6	1.4		.	.	66.6	.		.
Recon		30.5	31.0	3.9		29.4	29.6	3.4		
DoS		9.2	9.1	8.4	8.6		8.6	7.5		
Backdoor		18.1	18.7	19.1	17.1	16.7		13.7		.
Shellcode		5.8	6.6	3.5	3.7	3.3	11.8			
Analysis										
Worms		.	.	4.4			4.4			

빈칸 : 0% · ∴ 1% 미만 회색 : 동일 클래스 같은 행의 중복 집계로 합산 불가



Web attack: 1,764 + 432 - 중복 429 = 1,767 행 제거 · 771 행 잔존

정제 이후 클래스 분포

전체 데이터 기준 (train + validation + test) · 정제 후 표본 수 내림차순 · 비중 단위 %

CIC2018

클래스	정제 전	정제 후	비중 전	비중 후
Benign	17,514,626	12,798,328	87.070	86.736
DDoS	1,324,350	1,316,025	6.584	8.919
Bot	207,703	207,703	1.033	1.408
DoS	302,966	197,415	1.506	1.338
Brute force	575,194	188,414	2.859	1.277
Infiltration	188,152	46,761	0.935	0.317
Web attack	2,538	771	0.013	0.005
합계	20,115,529	14,755,417	100.000	100.000

Infiltration 75.1% 감소
Web attack 69.6% 감소 · 정제 후 771 행

ToN-IoT

클래스	정제 전	정제 후	비중 전	비중 후
Benign	16,792,214	6,446,120	61.018	59.646
XSS	2,834,435	1,670,497	10.299	15.457
Password	1,594,777	1,061,699	5.795	9.824
DDoS	4,141,256	925,247	15.048	8.561
Injection	381,777	341,263	1.387	3.158
Backdoor	203,384	200,688	0.739	1.857
DoS	203,456	113,655	0.739	1.052
Scanning	1,358,977	39,069	4.938	0.362
MitM	6,013	5,446	0.022	0.050
Ransomware	3,971	3,604	0.014	0.033
합계	27,520,260	10,807,288	100.000	100.000

Global 과 residual expert 구조


학습 데이터의 역할 분리 · Global 구성 / Expert 구성 / S·V 학습

Global 풀 · 공통 context


Expert 풀 · residual 과 expert

Route 풀 · S/V 학습

오프라인 · 모델 구성



온라인 · 입력별 예측



첫 context 구성 실험 · 공통 anchor 와 residual block

정제 CIC2018·ToN · seed 43 · Global 고정 · K = 2, 4, 6, 8

각 expert 에 제공하는 context

공통 anchor

모든 클래스의 기본 사례 · 클래스당 최대 2,000 행

+

Residual 군집별 특화 block

Global 오류 양상과 입력 특성을 반영한 표본 선택

같은 TabPFN backbone · 서로 다른 context

K 에 따른 expert 구성과 context 행 수 합계

Expert 수	CIC2018	ToN
K = 2	250,481	231,534
K = 4	277,505	270,546
K = 6	328,037	338,908
K = 8	376,411	421,513

공통 anchor	CIC2018	ToN
행 수	12,224	18,717

합계에 expert 별 anchor 반복 포함 · K 별 총예산 상이

동일 test 에서 비교한 Global 과 expert 의 분류 성능

K = 4 · 클래스별 F1 · test 표본 수 내림차순 · 파란 숫자 : 표시값 기준 Global 대비 개선

CIC2018

클래스	표본 수	Global	e1	e2	e3	e4
Benign	2,652,203	0.996	0.998	0.894	0.795	0.875
DDoS	262,680	0.992	0.992	1.000	1.000	1.000
Bot	41,542	0.998	0.998	0.993	0.998	0.998
DoS	39,483	0.992	0.992	0.986	0.996	0.992
Brute force	37,696	1.000	1.000	1.000	1.000	1.000
Infiltration	8,742	0.288	0.229	0.027	0.018	0.023
Web attack	127	0.210	0.353	0.069	0.077	0.199
Macro-F1		0.782	0.794	0.710	0.698	0.727

Infiltration: 모든 expert 에서 Global 보다 낮은 F1
Web attack: e1 의 test 개선 , validation 확인에서는 미개선

ToN

클래스	표본 수	Global	e1	e2	e3	e4
Benign	1,474,302	0.922	0.912	0.909	0.858	0.920
XSS	343,854	0.830	0.825	0.850	0.834	0.850
Password	210,951	0.892	0.890	0.892	0.891	0.891
DDoS	103,338	0.980	0.975	0.982	0.968	0.971
Injection	68,891	0.903	0.850	0.935	0.460	0.873
Backdoor	40,030	0.999	0.998	0.999	0.997	0.999
DoS	22,458	0.977	0.962	0.954	0.715	0.969
Scanning	6,029	0.039	0.616	0.564	0.761	0.660
MitM	1,161	0.132	0.032	0.039	0.036	0.052
Ransomware	709	0.121	0.094	0.106	0.132	0.117
Macro-F1		0.680	0.715	0.723	0.665	0.730

각 expert 가 같은 전체 test 를 분류 · 다른 클래스에서 발생한 FP 까지 포함한 F1

S/V 적용 결과 · ToN 호출 활성화, CIC2018 호출 0 건

Seed 43 · validation 에서 호출 · 채택 기준 선택 · 전체 test 평가

CIC2018

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.7824	0.00	0.00
K = 2	0.7824	0.00	0.00
K = 4	0.7824	0.00	0.00
K = 6	0.7824	0.00	0.00
K = 8	0.7824	0.00	0.00

K = 2, 4, 6, 8 모두 Global 예측 유지

ToN

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.6796	0.00	0.00
K = 2	0.7636	100.00	5.26
K = 4	0.7617	100.00	1.23
K = 6	0.7677	100.00	4.09
K = 8	0.7463	100.00	0.69

K = 4 Scanning F1 0.0394 → 0.8587

호출률 : 정책상 expert 호출 표본 비율 · 채택률 : expert 출력 수락 표본 비율 · 분모는 전체 test

정제 데이터의 SOTA 와 현재 모델 성능

Seed 43 · 동일 정제 test · 대표 설정 K = 4 · Macro-F1

방법	CIC2018	ToN	학습 정보
Global TabPFN v3	0.7824	0.6796	공통 100,000 행
XGBoost	0.7821	0.6983	공통 100,000 행
BoostPFN	0.7148	0.5866	공통 100,000 행
LoCalPFN · FT	0.7024	0.6462	공통 100,000 행
DistPFN · v3	0.7839	0.6682	공통 100,000 행
XGBoost · 전체 train	0.7795	0.7162	전체 train
현재 모델 · K = 4 · S+V	0.7824	0.7617	Global + Expert·Route 풀

첫 5 개 방법은 같은 100,000 개 train ID 사용 · 전체 train XGB 와 현재 모델은 추가 학습 데이터 사용

Global·DistPFN: v3 · BoostPFN·LoCalPFN: v1 · LoCalPFN 은 미세조정 포함

SOTA 측정 비용과 현재 모델의 호출

RTX 4090 24GB · 최대 2 개 작업 병렬 · 자원 경합을 포함한 경과 시간

방법	CIC 학습 초	CIC 추론 초	ToN 학습 초	ToN 추론 초	CIC GPU GiB	ToN GPU GiB
Global TabPFN v3	36.4	1,099.3	36.7	821.7	2.92	2.94
XGBoost	2.3	1.0	55.4	1.0	0.55	0.53
BoostPFN	98.5	2,308.5	97.8	1,737.6	0.89	0.89
LoCalPFN · FT	3,196.3	17,300.8	5,783.1	11,144.8	7.54	7.54
DistPFN · v3	36.4	1,099.4	36.7	821.9	2.92	2.94
XGBoost · 전체 train	107.8	1.0	143.2	1.1	2.20	1.59

LoCalPFN: 학습에 validation, 추론에 검색 포함 · DistPFN: Global 계산과 prior 보정 포함

현재 모델 K = 4 · 정책상 호출률 CIC2018 0.00%, ToN 100.00% · 조건부 추론 시간 별도 측정 예정

후속 네 접근의 feasibility · context 최적화만 새 정보를 만든다

10-01 저녁 · seed 43 단일 (4 번은 seed 44 추가) · 전체 test macro-F1 · feasibility 규모 , 기록급 실험 아님

접근	무엇을 바꿨나	결과 (전체 test)	판정
1 Benign 다양화	C0 의 benign 75,000 행만 교체 (time · k-center · 역밀도 · 공격 근접)	ToN 0.830 → 0.813 ... 0.834, scanning ≤ 0.07	효과 없음 · scanning 은 prior 문제
2 LITO 식 tail 합성	web 224 행 → 합성 2,000 행 , self-authentication 통과 1,479 행	CIC 0.7824 → 합성 0.7680 · 실제 복제 0.7997 (web F1 0.21 → 0.32)	합성 기각 · 양성 비율은 유효한 knob
3 SupCon 임베딩	route 풀로 encoder 학습 , 16 차원 임베딩을 feature 에 추가	ToN 0.836 → 0.827 (raw+emb) · 0.836 (emb)	효과 없음
4 Context 최적화	3,000 행 context 를 train 풀 query 의 NLL 로 300 step 최적화 (backbone 고정)	ToN 0.645 → 0.710 / 0.745 (seed 43 / 44) · CIC 2,100 행 0.783	100k C0 0.680 / 0.782 상회 · 동급

ToN: 3,000 행 최적화 context 0.710 / 0.745 > 100,000 행 무작위 C0 0.680 > XGBoost-100k 0.698 · 최적화 query 는 자연 비율이어야 한다 (균형 query 0.672)
제한 : 미분 경로는 24 GB 에서 5,000 행까지 · estimator 1 개 · seed 민감 (mitm 0.32 / 0.65)

다음 실험 · 공격이 시간순으로 나타나는 시나리오

test 를 시간순 5 구간으로 분할 · 구간마다 각 family 의 첫 10% 중 최대 50 행만 라벨 → 나머지 평가 · 라벨은 누적 · ToN seed 43

ToN test 에서 family 가 나타나는 순서 (구간별 출현 클래스)

구간 1	구간 2	구간 3	구간 4	구간 5
ddos dos injection scanning	ddos	password	xss	backdoor mitm ransomware

benign 은 전 구간에 공존 · 구간 5 의 benign 은 train 에 없는 블록을 포함

비교 조건 (같은 평가 행)

조건	갱신 방식	구간당 비용
TabPFN 고정	갱신 없음 (현재 Global)	0 s
TabPFN + context	라벨 행을 context 에 추가 , 학습 없음	적재 17 s / 구간
XGBoost 고정	갱신 없음	0 s
XGBoost 재학습	C0 + 누적 라벨로 재학습	재학습 4 s / 구간

첫 결과 (EXP68, ToN, seed 43) · 구간별 macro-F1 은 그 구간에 출현한 클래스 기준 · 아래 세 행은 tail F1

구간	TabPFN 고정	+context	XGB 고정	XGB 재학습
1	0.793	0.796	0.790	0.799
2	0.972	0.976	0.976	0.976
3	0.868	0.868	0.874	0.874
4	0.906	0.941	0.961	0.961
5	0.563	0.554	0.605	0.610
scanning (1)	0.038	0.043	0.047	0.053
mitm (5)	0.145	0.123	0.270	0.290
ransomware (5)	0.156	0.156	0.166	0.164

라벨 50 행을 100,000 행 context 에 더하는 것만으로는 scanning 이 열리지 않는다 (0.038 → 0.043; XGB 재학습 0.053) · 효과를 낸 것은 구성이다 : scanning block expert + V 0.86, 최적화 context 0.71 · 적응의 단위는 라벨 추가가 아니라 context 구성