


새로운 공격 사례를 반영하는 IDS

공격 C의 라벨 사례 확보 이후 · 기존 공격과 새 공격을 함께 분류하는 탐지기 갱신



새로운 공격의 라벨 사례가 확보됐을 때 ,
TabPFN 은 context 확장만으로 XGBoost 재학습보다
효과적으로 새로운 공격을 분류할 수 있는가 ?

새 공격 분류 · 기존 탐지 유지 · 갱신과 추론에 드는 비용

모델 재학습과 context 확장을 통한 갱신

동일한 기존 사례와 신규 공격 사례 제공 · 갱신 방식의 차이에 대한 비교

XGBoost

동일한 누적 사례

기존 사례 + 새 공격 사례

누적 데이터로 재학습

분류 규칙 · 모델 파라미터 갱신

갱신된 XGB

기존 공격 + 새 공격 분류

TabPFN

동일한 누적 사례

기존 사례 + 새 공격 사례

Context 확장

Backbone 고정
전처리 · 캐시 재구성

동일한 TabPFN

확장된 context 로 분류

TabPFN 의 구조적 특성 : backbone 가중치 재학습 없이 사례 구성 변경

효용 검증 : 새 공격 성능 · 기존 탐지 유지와 전처리 · 캐시 · 추론 비용의 동시 비교

입력 · 라벨 품질 검토 · 동일 feature 의 상충 라벨

행 : 원래 라벨 · 열 : 동일 feature 의 다른 라벨 · 셀 : 행 클래스 대비 비율 (%) · 정제 전 표본 수 내림차순

CIC2018

전체 상충 행 26.65%

	Ben	DDoS	Brute	DoS	Bot	Inf	Web
Benign		.		.		26.7	.
DDoS	.						
Brute force				67.2			
DoS	.		34.8				
Bot							
Infiltration	75.1						.
Web attack	69.5					17.0	

ToN-IoT

전체 상충 행 60.73%

	Ben	DDoS	XSS	Pass	Scan	Inj	DoS	Back	MitM	Ran
Benign		13.7	3.3	.	49.9	.	8.6	2.3	8.2	2.4
DDoS	76.3		69.1	22.4	1.4	75.0	.	.	.	.
XSS	37.0	12.2		15.4	.	29.4	6.8	.	.	.
Password	33.3	.	.		.	.	.	.	.	.
Scanning	97.1	.	.	.		.	.	.	.	3.6
Injection	7.5	3.4	9.0	2.1	2.0		2.0	.	.	.
DoS	33.1	12.8	26.3	.	9.1	12.2		.	1.6	
Backdoor	1.3	.	.	.	.	.	.			.
MitM	8.5	3.1	7.2	2.1	2.8	5.3	7.5			
Ransomware	9.2	.	1.0		1.9	.		.		

BoT-IoT

전체 상충 행 6.11%


	DoS	DDoS	Recon	Ben	Theft
DoS		2.0	1.2	1.2	
DDoS	1.6		.	.	
Recon	2.5	.		35.6	1.4
Benign	7.7	.	63.8		
Theft			67.6		

UNSW-NB15

전체 상충 행 1.33%

	Ben	Expl	Fuzz	Gen	Recon	DoS	Back	Shell	Anal	Worm
Benign										
Exploits			6.0	4.6	4.7	3.9	4.0	3.6		.
Fuzzers		18.0		15.2	15.8	13.4	14.0	13.0		.
Generic		4.6	1.4		.	.	66.6	.		.
Recon		30.5	31.0	3.9		29.4	29.6	3.4		
DoS		9.2	9.1	8.4	8.6		8.6	7.5		
Backdoor		18.1	18.7	19.1	17.1	16.7		13.7		.
Shellcode		5.8	6.6	3.5	3.7	3.3	11.8			
Analysis										
Worms		.	.	4.4			4.4			

빈칸 : 0% · ∴ 1% 미만 회색 : 동일 클래스 같은 행의 중복 집계로 합산 불가



Web attack: 1,764 + 432 - 중복 429 = 1,767 행 제거 · 771 행 잔존

정제 이후 클래스 분포와 고정 test

정제 전후 : 전체 데이터 · Test: 정제 후 평가 표본 · 정제 후 전체 표본 수 내림차순

CIC2018

클래스	정제 전 전체	정제 후 전체	Test
Benign	17,514,626	12,798,328	2,652,203
DDoS	1,324,350	1,316,025	262,680
Bot	207,703	207,703	41,542
DoS	302,966	197,415	39,483
Brute force	575,194	188,414	37,696
Infiltration	188,152	46,761	8,742
Web attack	2,538	771	127
합계	20,115,529	14,755,417	3,042,473


Tail: 고정 test 에서 표본 수가 적은 클래스
Context 에 제공한 학습 사례 수와 별도 표기

ToN


클래스	정제 전 전체	정제 후 전체	Test
Benign	16,792,214	6,446,120	1,474,302
XSS	2,834,435	1,670,497	343,854
Password	1,594,777	1,061,699	210,951
DDoS	4,141,256	925,247	103,338
Injection	381,777	341,263	68,891
Backdoor	203,384	200,688	40,030
DoS	203,456	113,655	22,458
Scanning	1,358,977	39,069	6,029
MitM	6,013	5,446	1,161
Ransomware	3,971	3,604	709
합계	27,520,260	10,807,288	2,271,723

Context 기반 Global·expert 모델 구조


공통 context 와 전문 context 활용 · TabPFN backbone 고정 · Scorer·Verifier 별도 학습



오프라인 · 모델 구성



온라인 · 입력별 예측



정제 데이터의 현재 성능 · SOTA 비교

전체 공격 클래스를 학습한 정적 조건 · 동일 정제 test · Seed 43 · Macro-F1 (%)

방법	CIC2018	ToN	학습 정보
Global TabPFN v3	78.24	67.96	공통 100,000 행
XGBoost	78.21	69.83	공통 100,000 행
BoostPFN	71.48	58.66	공통 100,000 행
LoCalPFN · FT	70.24	64.62	공통 100,000 행
DistPFN · v3	78.39	66.82	공통 100,000 행
XGBoost · 전체 train	77.95	71.62	전체 train
제안 모델 · $K = 4 \cdot S/V$	78.24	76.17	Global + Expert·Route 풀

제안 모델 : 기존 anchor + residual block 결과 · Expert·Route 의 추가 학습 정보 사용

현재 성능 수준의 확인 · 신규 공격 반영 효과와 갱신 · 추론 비용은 순차 도입으로 검증


신규 공격의 순차 도입을 통한 검증

EXP70 실행 중 · XGBoost 재학습과 Global TabPFN context 확장 · 동일한 누적 사례 제공

CIC2018 · 2018 년



ToN · 2019 년



최종 각 100,000 행 · 등장 전 클래스 학습 제외 · 기존 test 유지 · Seed 43

원본의 클래스 최초 출현 순서 보존 · 확인 대상: 새 공격 분류 / 기존 탐지 유지 / 갱신 · 추론 비용

후속 검증 · 새로운 공격을 반영하는 시스템

새 공격 사례를 반영하는 방식의 효용 확인 · 성능 · 기존 탐지 유지 · 운영 비용의 연결

새 공격 반영

동일한 신규 사례 제공
갱신 후 공격별 분류 성능
희소 클래스의 탐지 변화

기존 탐지 유지

동일한 기존 표본 비교
교정 · 훼손과 정상 오탐
Context 구성의 영향 확인

운영 비용

사례 추가 시 갱신 비용
다음 갱신까지의 추론 비용
처리량 · 메모리의 비교

**연구의 판단 기준 : 새 공격을 얼마나 잘 반영하고,
기존 탐지 성능을 어느 비용으로 유지하는가**

Context 구성 개선 → Expert-S/V 의 역할과 갱신 검증 → 운영 조건별 효과 확인

F1 은 시스템 효용을 확인하는 지표 중 하나 · 미지 공격 인지는 이후 OOD 확장

동일 test 에서 비교한 Global 과 expert 의 분류 성능

K = 4 · 클래스별 F1 · test 표본 수 내림차순 · 파란 숫자 : 표시값 기준 Global 대비 개선

CIC2018

클래스	표본 수	Global	e1	e2	e3	e4
Benign	2,652,203	0.996	0.998	0.894	0.795	0.875
DDoS	262,680	0.992	0.992	1.000	1.000	1.000
Bot	41,542	0.998	0.998	0.993	0.998	0.998
DoS	39,483	0.992	0.992	0.986	0.996	0.992
Brute force	37,696	1.000	1.000	1.000	1.000	1.000
Infiltration	8,742	0.288	0.229	0.027	0.018	0.023
Web attack	127	0.210	0.353	0.069	0.077	0.199
Macro-F1		0.782	0.794	0.710	0.698	0.727

Infiltration: 모든 expert 에서 Global 보다 낮은 F1
Web attack: e1 의 test 개선 , validation 확인에서는 미개선

ToN

클래스	표본 수	Global	e1	e2	e3	e4
Benign	1,474,302	0.922	0.912	0.909	0.858	0.920
XSS	343,854	0.830	0.825	0.850	0.834	0.850
Password	210,951	0.892	0.890	0.892	0.891	0.891
DDoS	103,338	0.980	0.975	0.982	0.968	0.971
Injection	68,891	0.903	0.850	0.935	0.460	0.873
Backdoor	40,030	0.999	0.998	0.999	0.997	0.999
DoS	22,458	0.977	0.962	0.954	0.715	0.969
Scanning	6,029	0.039	0.616	0.564	0.761	0.660
MitM	1,161	0.132	0.032	0.039	0.036	0.052
Ransomware	709	0.121	0.094	0.106	0.132	0.117
Macro-F1		0.680	0.715	0.723	0.665	0.730

각 expert 가 같은 전체 test 를 분류 · 다른 클래스에서 발생한 FP 까지 포함한 F1

S/V 적용 결과 · ToN 호출 활성화, CIC2018 호출 0 건

Seed 43 · validation 에서 호출 · 채택 기준 선택 · 전체 test 평가

CIC2018

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.7824	0.00	0.00
K = 2	0.7824	0.00	0.00
K = 4	0.7824	0.00	0.00
K = 6	0.7824	0.00	0.00
K = 8	0.7824	0.00	0.00

K = 2, 4, 6, 8 모두 Global 예측 유지

ToN

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.6796	0.00	0.00
K = 2	0.7636	100.00	5.26
K = 4	0.7617	100.00	1.23
K = 6	0.7677	100.00	4.09
K = 8	0.7463	100.00	0.69

K = 4 Scanning F1 0.0394 → 0.8587

호출률 : 정책상 expert 호출 표본 비율 · 채택률 : expert 출력 수락 표본 비율 · 분모는 전체 test

SOTA 측정 비용과 현재 모델의 호출

RTX 4090 24GB · 최대 2 개 작업 병렬 · 자원 경합을 포함한 경과 시간

방법	CIC 학습 초	CIC 추론 초	ToN 학습 초	ToN 추론 초	CIC GPU GiB	ToN GPU GiB
Global TabPFN v3	36.4	1,099.3	36.7	821.7	2.92	2.94
XGBoost	2.3	1.0	55.4	1.0	0.55	0.53
BoostPFN	98.5	2,308.5	97.8	1,737.6	0.89	0.89
LoCalPFN · FT	3,196.3	17,300.8	5,783.1	11,144.8	7.54	7.54
DistPFN · v3	36.4	1,099.4	36.7	821.9	2.92	2.94
XGBoost · 전체 train	107.8	1.0	143.2	1.1	2.20	1.59

LoCalPFN: 학습에 validation, 추론에 검색 포함 · DistPFN: Global 계산과 prior 보정 포함

현재 모델 K = 4 · 정책상 호출률 CIC2018 0.00%, ToN 100.00% · 조건부 추론 시간 별도 측정 예정

Context 구성의 후속 후보

새 공격 반영과 기존 탐지 유지를 위한 구성 후보 · 동일 정보량 · context 예산에서 효과 분리

접근	검증할 가설	확인할 변화
1 Benign 다양화	정상 트래픽의 여러 동작을 대표	공격 recall 유지 시 Benign 오탐 감소
2 Tail 합성	희소 공격의 관측 범위를 보완	동일 개수 실제 사례 · 단순 복제와 비교
3 표현 학습 · 임베딩	유사한 입력에서도 클래스 구분 강화	원본 feature 대비 분리력과 추가 학습 비용
4 Context 최적화	적은 행에 유용한 정보를 집중	동일 context 크기의 선택 방식과 비교

2 LITO (ICLR 2024) · 3 Supervised contrastive prototype embedding · 4 In-context data distillation

표현 학습 · 합성 · 최적화의 비용도 합산 · 성능이 오른 이유를 분리할 수 있는 비교 조건 설계

최종 100,000 행의 단계별 배분

Benign 75,000 행 + 공격 25,000 행 · 가용 수를 고려한 균등 배분 · 전체 clean train 에서 추출

CIC2018

단계	추가 클래스	추가 수	누적 수
초기	Benign · Brute force · DoS	84,820	84,820
1	DDoS	4,910	89,730
2	Web attack	450	90,180
3	Infiltration	4,910	95,090
4	Bot	4,910	100,000

ToN

단계	추가 클래스	추가 수	누적 수
초기	Benign · Scanning · DoS	80,712	80,712
1	Injection · DDoS	5,712	86,424
2	Password	2,856	89,280
3	XSS	2,856	92,136
4	Ransomware · Backdoor	5,008	97,144
5	MitM	2,856	100,000

Web attack 450 행 · Ransomware 2,151 행은 가용 사례 전체 사용

XGB 와 TabPFN 에 동일한 사례 제공 · 이전 소규모 실험 사례를 포함해 증설 · Test 고정