

연구 목표 · 라벨이 적은 공격을 잘 탐지하는 IDS

제한된 context 안에서 희소 공격의 구분에 필요한 사례를 구성 · 클래스별 성능과 비용으로 검증

공격의 라벨 사례가 적을 때 , 무엇을 context 에 담아야
Benign 과 다른 공격 사이에서 그 공격을 더 잘 구분할 수 있는가 ?

대상 · 희소 공격

학습 사례가 적은 공격의 탐지 개선
전체 클래스의 일률적 개선은 부차 목표

제약 · 라벨과 메모리

제한된 라벨 획득량과 context 크기
Context 구성 · 모델 학습 · 추론 비용

보존 · 기존 탐지 능력

Benign 오탐과 기존 공격 성능 확인
희소 공격 개선과 함께 평가

아이디어 : Global 의 공통 사례 + 공격 구분에 필요한 전문 사례를 context 로 구성

현재 확인 : 고정 test 에서 일부 클래스 개선 다음 검증 : 희소 공격 성능과 구성 · 추론 비용

왜 TabPFN 인가 · 적은 사례를 context 로 활용하는 분류기

XGBoost 는 강한 비교 기준 · TabPFN 의 선택 근거는 사전학습 지식과 소수 context 사례의 활용 가능성

XGBoost · 주어진 데이터로 학습

주어진 라벨 데이터로 결정 규칙 학습

현재 고정 test 에서 강한 성능과 빠른 추론
희소 공격에서도 반드시 비교할 기준

TabPFN · 사례를 조건으로 추론

사전학습된 backbone 과 라벨 context 로 추론


가중치 재학습 없이 사례 구성 변경 가능
적은 공격 사례의 효과적인 활용이 가설

비교해야 할 질문


동일한 라벨 정보에서 , 어떤 context 구성이 희소 공격의 구분을 돕는가 ?
XGBoost / Global TabPFN / 제안 context-expert 구성의 성능과 비용 비교

Global 과 residual expert 구조


학습 데이터의 역할 분리 · Global 구성 / Expert 구성 / S·V 학습



오프라인 · 모델 구성



온라인 · 입력별 예측



동일 feature 를 공유하는 클래스

행 : 원래 라벨 · 열 : 동일 feature 의 다른 라벨 · 셀 : 행 클래스 대비 비율 (%) · 정제 전 표본 수 내림차순

CIC2018

전체 상충 행 26.65%

	Ben	DDoS	Brute	DoS	Bot	Inf	Web
Benign		.		.		26.7	.
DDoS	.						
Brute force				67.2			
DoS	.		34.8				
Bot							
Infiltration	75.1						.
Web attack	69.5					17.0	

ToN-IoT

전체 상충 행 60.73%

	Ben	DDoS	XSS	Pass	Scan	Inj	DoS	Back	MitM	Ran
Benign		13.7	3.3	.	49.9	.	8.6	2.3	8.2	2.4
DDoS	76.3		69.1	22.4	1.4	75.0	.	.	.	.
XSS	37.0	12.2		15.4	.	29.4	6.8	.	.	.
Password	33.3	.	.		.	.	.	.	.	.
Scanning	97.1	.	.	.		.	.	.	.	3.6
Injection	7.5	3.4	9.0	2.1	2.0		2.0	.	.	.
DoS	33.1	12.8	26.3	.	9.1	12.2		.	1.6	
Backdoor	1.3	.	.	.	.	.	.			.
MitM	8.5	3.1	7.2	2.1	2.8	5.3	7.5			
Ransomware	9.2	.	1.0		1.9	.		.		

BoT-IoT

전체 상충 행 6.11%

	DoS	DDoS	Recon	Ben	Theft
DoS		2.0	1.2	1.2	
DDoS	1.6		.	.	
Recon	2.5	.		35.6	1.4
Benign	7.7	.	63.8		
Theft			67.6		

UNSW-NB15

전체 상충 행 1.33%

	Ben	Expl	Fuzz	Gen	Recon	DoS	Back	Shell	Anal	Worm
Benign										
Exploits			6.0	4.6	4.7	3.9	4.0	3.6		.
Fuzzers		18.0		15.2	15.8	13.4	14.0	13.0		.
Generic		4.6	1.4		.	.	66.6	.		.
Recon		30.5	31.0	3.9		29.4	29.6	3.4		
DoS		9.2	9.1	8.4	8.6		8.6	7.5		
Backdoor		18.1	18.7	19.1	17.1	16.7		13.7		.
Shellcode		5.8	6.6	3.5	3.7	3.3	11.8			
Analysis										
Worms		.	.	4.4			4.4			

빈칸 : 0% · ∴ 1% 미만 회색 : 동일 클래스 같은 행의 중복 집계로 합산 불가



정제 이후 클래스 분포

전체 데이터 기준 (train + validation + test) · 정제 후 표본 수 내림차순 · 비중 단위 %

CIC2018

클래스	정제 전	정제 후	비중 전	비중 후
Benign	17,514,626	12,798,328	87.070	86.736
DDoS	1,324,350	1,316,025	6.584	8.919
Bot	207,703	207,703	1.033	1.408
DoS	302,966	197,415	1.506	1.338
Brute force	575,194	188,414	2.859	1.277
Infiltration	188,152	46,761	0.935	0.317
Web attack	2,538	771	0.013	0.005
합계	20,115,529	14,755,417	100.000	100.000

Infiltration 75.1% 감소
Web attack 69.6% 감소 · 정제 후 771 행

ToN-IoT

클래스	정제 전	정제 후	비중 전	비중 후
Benign	16,792,214	6,446,120	61.018	59.646
XSS	2,834,435	1,670,497	10.299	15.457
Password	1,594,777	1,061,699	5.795	9.824
DDoS	4,141,256	925,247	15.048	8.561
Injection	381,777	341,263	1.387	3.158
Backdoor	203,384	200,688	0.739	1.857
DoS	203,456	113,655	0.739	1.052
Scanning	1,358,977	39,069	4.938	0.362
MitM	6,013	5,446	0.022	0.050
Ransomware	3,971	3,604	0.014	0.033
합계	27,520,260	10,807,288	100.000	100.000

첫 context 구성 실험 · 공통 anchor 와 residual block

정제 CIC2018·ToN · seed 43 · Global 고정 · K = 2, 4, 6, 8

각 expert 에 제공하는 context

공통 anchor

모든 클래스의 기본 사례 · 클래스당 최대 2,000 행

+

Residual 군집별 특화 block

Global 오류 양상과 입력 특성을 반영한 표본 선택

같은 TabPFN backbone · 서로 다른 context

K 에 따른 expert 구성과 context 행 수 합계

Expert 수	CIC2018	ToN
K = 2	250,481	231,534
K = 4	277,505	270,546
K = 6	328,037	338,908
K = 8	376,411	421,513

공통 anchor	CIC2018	ToN
행 수	12,224	18,717

합계에 expert 별 anchor 반복 포함 · K 별 총예산 상이

현재 근거 · residual context 는 일부 공격에서 효과

정제 데이터 · 고정 test · seed 43 · 대표 K = 4 · 순차 공격 도입 시나리오는 아직 설계 단계

데이터	XGB 100k F1	Global F1	현재 모델 F1	Expert 호출 (%)	출력 채택 (%)
CIC2018	0.7821	0.7824	0.7824	0.00	0.00
ToN	0.6983	0.6796	0.7617	100.00	1.23

F1 은 Macro-F1 · 현재 모델은 expert/route 추가 학습 데이터 사용 · 같은 100k 예산의 우위 주장 불가

관찰 · 무엇이 달라졌나

ToN Scanning F1: 0.0394 → 0.8587
CIC2018: 호출 0 건으로 Global 예측 유지
모든 tail 의 개선을 확인한 상태는 아님

다음 질문 · 어떤 정보가 필요한가

공통 · 전문 사례의 구성으로 얻은 개선인가?
라벨이 적은 다른 공격에도 효과가 있는가?
Benign 오탐과 구성 · 추론 비용의 변화는 ?

평가 방향 · 공격을 순차적으로 도입해 희소 공격 탐지 확인

설계안 · 공격 도입 순서 · 혼합 비율을 통제 · 보유 라벨 수와 context 갱신 여부는 별도 설정

초기 배경

Benign 과 일부 공격이
함께 존재하는 트래픽



공격 도입

라벨이 적은 공격이
순차적으로 출현



혼합 변화

기존 · 신규 도입 공격의
혼합 비율 변화



성능 관찰

공격별 탐지와 오탐
기존 공격 성능 추적

먼저 볼 것 · 라벨이 적은 공격의 구분

동일한 학습 정보 · 공격 도입 순서로 비교
공격별 Precision / Recall / F1 과 Benign 오탐
구간별 혼합 조건의 영향 확인
Context 갱신 여부는 별도 설계 항목

후속 확장 · OOD 와 새로운 공격

평가 흐름에 뒤늦게 등장한 공격과
학습에 없던 공격은 서로 다른 조건
먼저 소수 라벨 조건의 탐지 성능 검증
이후 미지 공격 · 분포 밖 입력으로 확장

Context 설계 후보 · 부족한 정보에 대한 가설부터 검증

Anchor + residual block 은 하나의 출발점 · 같은 라벨 · 메모리 예산에서 구성 요소의 역할을 확인

접근	검증할 가설	확인할 변화
1 Benign 다양화	정상 트래픽의 여러 동작을 대표	공격 recall 유지 시 Benign 오탐 감소
2 Tail 합성	희소 공격의 관측 범위를 보완	동일 개수 실제 사례 · 단순 복제와 비교
3 표현 학습 · 임베딩	유사한 입력에서도 클래스 구분 강화	원본 feature 대비 분리력과 추가 학습 비용
4 Context 최적화	적은 행에 유용한 정보를 집중	동일 context 크기의 선택 방식과 비교

2 LITO (ICLR 2024) · 3 Supervised contrastive prototype embedding · 4 In-context data distillation

표현 학습 · 합성 · 최적화의 비용도 합산 · 성능이 오른 이유를 분리할 수 있는 비교 조건 설계

다음 단계 · 희소 공격 개선이라는 주장에 맞춰 검증

핵심 주장 후보 : 제한된 라벨 ·context 예산에서 희소 공격을 더 잘 구분하고 기존 탐지 능력 유지

순서	확인할 내용
① 목표와 조건	대상 희소 공격 · 보유 라벨 수 · 순차 도입 방식 ·context 예산 정의
② 단순 비교부터	같은 라벨 데이터로 XGB / Global / 제안 context 구성 비교
③ 제안의 역할 확인	Context 구성의 기여 확인 후 expert·S/V 기여 분리
④ OOD 확장	새 분포 · 미지 공격의 인지와 라벨 확보 후 적응을 분리

판단 기준 : 라벨이 적은 어떤 공격을 더 잘 구분하며 , 오탐과 기존 성능을 보존하는 데 드는 비용은 ?

동일 test 에서 비교한 Global 과 expert 의 분류 성능

K = 4 · 클래스별 F1 · test 표본 수 내림차순 · 파란 숫자 : 표시값 기준 Global 대비 개선

CIC2018

클래스	표본 수	Global	e1	e2	e3	e4
Benign	2,652,203	0.996	0.998	0.894	0.795	0.875
DDoS	262,680	0.992	0.992	1.000	1.000	1.000
Bot	41,542	0.998	0.998	0.993	0.998	0.998
DoS	39,483	0.992	0.992	0.986	0.996	0.992
Brute force	37,696	1.000	1.000	1.000	1.000	1.000
Infiltration	8,742	0.288	0.229	0.027	0.018	0.023
Web attack	127	0.210	0.353	0.069	0.077	0.199
Macro-F1		0.782	0.794	0.710	0.698	0.727

Infiltration: 모든 expert 에서 Global 보다 낮은 F1
Web attack: e1 의 test 개선 , validation 확인에서는 미개선

ToN

클래스	표본 수	Global	e1	e2	e3	e4
Benign	1,474,302	0.922	0.912	0.909	0.858	0.920
XSS	343,854	0.830	0.825	0.850	0.834	0.850
Password	210,951	0.892	0.890	0.892	0.891	0.891
DDoS	103,338	0.980	0.975	0.982	0.968	0.971
Injection	68,891	0.903	0.850	0.935	0.460	0.873
Backdoor	40,030	0.999	0.998	0.999	0.997	0.999
DoS	22,458	0.977	0.962	0.954	0.715	0.969
Scanning	6,029	0.039	0.616	0.564	0.761	0.660
MitM	1,161	0.132	0.032	0.039	0.036	0.052
Ransomware	709	0.121	0.094	0.106	0.132	0.117
Macro-F1		0.680	0.715	0.723	0.665	0.730

각 expert 가 같은 전체 test 를 분류 · 다른 클래스에서 발생한 FP 까지 포함한 F1

S/V 적용 결과 · ToN 호출 활성화, CIC2018 호출 0 건

Seed 43 · validation 에서 호출 · 채택 기준 선택 · 전체 test 평가

CIC2018

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.7824	0.00	0.00
K = 2	0.7824	0.00	0.00
K = 4	0.7824	0.00	0.00
K = 6	0.7824	0.00	0.00
K = 8	0.7824	0.00	0.00

K = 2, 4, 6, 8 모두 Global 예측 유지

ToN

구성	Macro-F1	호출률 (%)	채택률 (%)
Global	0.6796	0.00	0.00
K = 2	0.7636	100.00	5.26
K = 4	0.7617	100.00	1.23
K = 6	0.7677	100.00	4.09
K = 8	0.7463	100.00	0.69

K = 4 Scanning F1 0.0394 → 0.8587

호출률 : 정책상 expert 호출 표본 비율 · 채택률 : expert 출력 수락 표본 비율 · 분모는 전체 test

정제 데이터의 SOTA 와 현재 모델 성능

Seed 43 · 동일 정제 test · 대표 설정 K = 4 · Macro-F1

방법	CIC2018	ToN	학습 정보
Global TabPFN v3	0.7824	0.6796	공통 100,000 행
XGBoost	0.7821	0.6983	공통 100,000 행
BoostPFN	0.7148	0.5866	공통 100,000 행
LoCalPFN · FT	0.7024	0.6462	공통 100,000 행
DistPFN · v3	0.7839	0.6682	공통 100,000 행
XGBoost · 전체 train	0.7795	0.7162	전체 train
현재 모델 · K = 4 · S+V	0.7824	0.7617	Global + Expert·Route 풀

첫 5 개 방법은 같은 100,000 개 train ID 사용 · 전체 train XGB 와 현재 모델은 추가 학습 데이터 사용

Global·DistPFN: v3 · BoostPFN·LoCalPFN: v1 · LoCalPFN 은 미세조정 포함

SOTA 측정 비용과 현재 모델의 호출

RTX 4090 24GB · 최대 2 개 작업 병렬 · 자원 경합을 포함한 경과 시간

방법	CIC 학습 초	CIC 추론 초	ToN 학습 초	ToN 추론 초	CIC GPU GiB	ToN GPU GiB
Global TabPFN v3	36.4	1,099.3	36.7	821.7	2.92	2.94
XGBoost	2.3	1.0	55.4	1.0	0.55	0.53
BoostPFN	98.5	2,308.5	97.8	1,737.6	0.89	0.89
LoCalPFN · FT	3,196.3	17,300.8	5,783.1	11,144.8	7.54	7.54
DistPFN · v3	36.4	1,099.4	36.7	821.9	2.92	2.94
XGBoost · 전체 train	107.8	1.0	143.2	1.1	2.20	1.59

LoCalPFN: 학습에 validation, 추론에 검색 포함 · DistPFN: Global 계산과 prior 보정 포함

현재 모델 K = 4 · 정책상 호출률 CIC2018 0.00%, ToN 100.00% · 조건부 추론 시간 별도 측정 예정