

IDS 운영을 위한 TabPFN 활용

기존 평가

날짜별 공격 시나리오로 수집된 IDS 데이터
전체 공격 유형을 포함해 학습하고, baseline 대비 F1 향상에 집중

실제 운영

새 공격 라벨의 추가 · 환경 변화에 따라 모델 갱신 · 재학습 필요
고정 test 의 F1 만으로는 실제 운영 적합성을 판단하기 어려움

TabPFN 활용

사전학습된 tabular foundation model 을 추론에 바로 활용
소규모 데이터의 예측 능력과 가중치 재학습 없는 context 갱신 활용


새 공격 사례 추가에 따른 탐지기 갱신 실험

XGBoost 누적 재학습과 Global TabPFN context 확장 · 동일 사례 · Seed 43

CIC2018 · 2018 년



ToN · 2019 년



최종 각 100,000 행 · 미래 클래스 학습 제외 · 정제 test 중 도입한 클래스 전체 평가

클래스 최초 출현 순서 보존 · 새 공격 성능 · 기존 탐지 유지 · 갱신 및 추론 비용 비교

CIC2018 · 신규 공격 반영 성능과 비용

동일 누적 사례 · Global TabPFN v3 · Seed 43 · RTX 4090 · GPU 작업 순차 실행

각 신규 공격의 도입 직후 F1 (%)

정제 test 표본 수 내림차순 · 괄호는 도입 단계

신규 공격	Test 수	XGBoost	TabPFN
DDoS (1)	262,680	99.96	99.53
Bot (4)	41,542	99.70	99.77
Infiltration (3)	8,742	10.68	25.43
Web attack (2)	127	17.32	31.52

최종 100,000 행에서의 성능 · 비용

전체 test 3,042,473 행 · 시간 단위: 초

지표	XGBoost	TabPFN
Macro-F1 (%)	77.59	78.64
정상 오탐률 (%)	2.10	0.14
학습 · 구성 시간	1.98	16.98
추론 시간	1.44	522.63

TabPFN: 가중치 고정, 전처리 · cache 구성
XGBoost: 누적 데이터로 매 단계 재학습

Web attack · Infiltration 의 도입 직후 F1 개선 · 큰 context 의 추론 비용 절감 필요

데이터 검토 : 동일 feature 의 상충 라벨 삭제

행 : 원래 라벨 · 열 : 동일 feature 의 다른 라벨 · 셀 : 행 클래스 대비 비율 (%) · 정제 전 표본 수 내림차순

CIC2018

전체 상충 행 26.65%

	Ben	DDoS	Brute	DoS	Bot	Inf	Web
Benign		.		.		26.7	.
DDoS	.						
Brute force				67.2			
DoS	.		34.8				
Bot							
Infiltration	75.1						.
Web attack	69.5					17.0	

ToN-IoT

전체 상충 행 60.73%

	Ben	DDoS	XSS	Pass	Scan	Inj	DoS	Back	MitM	Ran
Benign		13.7	3.3	.	49.9	.	8.6	2.3	8.2	2.4
DDoS	76.3		69.1	22.4	1.4	75.0	.	.	.	.
XSS	37.0	12.2		15.4	.	29.4	6.8	.	.	.
Password	33.3	.	.		.	.	.	.	.	.
Scanning	97.1	.	.	.		.	.	.	.	3.6
Injection	7.5	3.4	9.0	2.1	2.0		2.0	.	.	.
DoS	33.1	12.8	26.3	.	9.1	12.2		.	1.6	
Backdoor	1.3	.	.	.	.	.	.			.
MitM	8.5	3.1	7.2	2.1	2.8	5.3	7.5			
Ransomware	9.2	.	1.0		1.9	.		.		

BoT-IoT

전체 상충 행 6.11%


	DoS	DDoS	Recon	Ben	Theft
DoS		2.0	1.2	1.2	
DDoS	1.6		.	.	
Recon	2.5	.		35.6	1.4
Benign	7.7	.	63.8		
Theft			67.6		

UNSW-NB15

전체 상충 행 1.33%

	Ben	Expl	Fuzz	Gen	Recon	DoS	Back	Shell	Anal	Worm
Benign										
Exploits			6.0	4.6	4.7	3.9	4.0	3.6		.
Fuzzers		18.0		15.2	15.8	13.4	14.0	13.0		.
Generic		4.6	1.4		.	.	66.6	.		.
Recon		30.5	31.0	3.9		29.4	29.6	3.4		
DoS		9.2	9.1	8.4	8.6		8.6	7.5		
Backdoor		18.1	18.7	19.1	17.1	16.7		13.7		.
Shellcode		5.8	6.6	3.5	3.7	3.3	11.8			
Analysis										
Worms		.	.	4.4			4.4			

빈칸 : 0% · ∴ 1% 미만 회색 : 동일 클래스 같은 행의 중복 집계로 합산 불가



Web attack: 1,764 + 432 - 중복 429 = 1,767 행 제거 · 771 행 잔존

정제 이후 클래스 분포와 고정 test

정제 전후 : 전체 데이터 · Test: 정제 후 평가 표본 · 정제 후 전체 표본 수 내림차순

CIC2018


클래스	정제 전 전체	정제 후 전체	Test
Benign	17,514,626	12,798,328	2,652,203
DDoS	1,324,350	1,316,025	262,680
Bot	207,703	207,703	41,542
DoS	302,966	197,415	39,483
Brute force	575,194	188,414	37,696
Infiltration	188,152	46,761	8,742
Web attack	2,538	771	127
합계	20,115,529	14,755,417	3,042,473

ToN


클래스	정제 전 전체	정제 후 전체	Test
Benign	16,792,214	6,446,120	1,474,302
XSS	2,834,435	1,670,497	343,854
Password	1,594,777	1,061,699	210,951
DDoS	4,141,256	925,247	103,338
Injection	381,777	341,263	68,891
Backdoor	203,384	200,688	40,030
DoS	203,456	113,655	22,458
Scanning	1,358,977	39,069	6,029
MitM	6,013	5,446	1,161
Ransomware	3,971	3,604	709
합계	27,520,260	10,807,288	2,271,723

Context 기반 Global·expert 모델 구조


공통 context 와 전문 context 활용 · TabPFN backbone 고정 · Scorer·Verifier 별도 학습



오프라인 · 모델 구성



온라인 · 입력별 예측



정제 데이터의 현재 성능 · SOTA 비교

전체 공격 클래스를 학습한 정적 조건 · 동일 정제 test · Seed 43 · Macro-F1 (%)

방법	CIC2018	ToN	학습 정보
Global TabPFN v3	78.24	67.96	공통 100,000 행
XGBoost	78.21	69.83	공통 100,000 행
BoostPFN	71.48	58.66	공통 100,000 행
LoCalPFN · FT	70.24	64.62	공통 100,000 행
DistPFN · v3	78.39	66.82	공통 100,000 행
XGBoost · 전체 train	77.95	71.62	전체 train
제안 모델 · K = 4 · S/V	78.24	76.17	Global + Expert·Route 풀

제안 모델 : 기존 anchor + residual block 결과 · Expert·Route 의 추가 학습 정보 사용

정적 평가에서의 현재 성능 · 순차 도입의 Global 비교와 별도로 해석

정제 데이터의 SOTA 비용

RTX 4090 24GB · 최대 2 개 작업 병렬 · 자원 경합을 포함한 경과 시간

방법	CIC 학습 · 구성 초	CIC 추론 초	ToN 학습 · 구성 초	ToN 추론 초	CIC GPU GiB	ToN GPU GiB
Global TabPFN v3	36.4	1,099.3	36.7	821.7	2.92	2.94
XGBoost	2.3	1.0	55.4	1.0	0.55	0.53
BoostPFN	98.5	2,308.5	97.8	1,737.6	0.89	0.89
LoCalPFN · FT	3,196.3	17,300.8	5,783.1	11,144.8	7.54	7.54
DistPFN · v3	36.4	1,099.4	36.7	821.9	2.92	2.94
XGBoost · 전체 train	107.8	1.0	143.2	1.1	2.20	1.59

LoCalPFN: 학습에 validation, 추론에 검색 포함 · DistPFN: Global 계산과 prior 보정 포함

현재 모델 K = 4 · 정책상 호출률 CIC2018 0.00%, ToN 100.00% · 조건부 추론 시간 별도 측정 예정

후속 검증 · 새로운 공격을 반영하는 시스템

새 공격 사례를 반영하는 방식의 효용 확인 · 성능 · 기존 탐지 유지 · 운영 비용의 연결

새 공격 반영

동일한 신규 사례 제공
갱신 후 공격별 분류 성능
희소 클래스의 탐지 변화

기존 탐지 유지

동일한 기존 표본 비교
교정 · 훼손과 정상 오탐
Context 구성의 영향 확인

운영 비용

사례 추가 시 갱신 비용
다음 갱신까지의 추론 비용
처리량 · 메모리의 비교

**연구의 판단 기준 : 새 공격을 얼마나 잘 반영하고,
기존 탐지 성능을 어느 비용으로 유지하는가**

Context 구성 개선 → Expert-S/V 의 역할과 갱신 검증 → 운영 조건별 효과 확인

F1 은 시스템 효용을 확인하는 지표 중 하나 · 미지 공격 인지는 이후 OOD 확장