

OOD-aware Stability-gated Expert MoE

CIC-IDS2017 불균형공격분류를위한 Expert Gate, 외부 OOD 학습, 진단체계

westpark

CIC-IDS2017 / Auxiliary OOD: CIC2018 후보


2026-06-17

- 기존 MoE/TTA 실험은 rare attack recall 개선가능성을보였지만, expert 선택실패원인해석이 어려웠다.
- 새구조에서는 benign 을 expert 에배정하지않고, 공격클래스만 disjoint expert 로분할한다.
- 핵심질문은세가지다.

진단해야할병목

- ① expert 가자기공격샘플을 OOD 로 reject 하는가?
- ② OOD 또는 benign 이특정 expert 로잘못 accept 되는가?
- ③ expert 가선택된뒤 local classifier 가내부공격클래스를구분하지못하는가?

제안방법: 전체구조



학습단계

- ID 데이터: CIC-IDS2017
- Benign 은 expert 에배정하지않음
- 공격클래스만 taxonomy 기반으로분할
- 각 expert 는 owned attack class 만 local classifier 로학습
- OE gate 는 owned class vs negative 를 binary 로학습

추론단계

- 각 expert 가독립적으로 accept/reject 수행
- 모든 expert 가 reject 하면 benign 예측
- 하나만 accept 하면해당 expert 선택
- 여러 expert 가 accept 하면 gate margin 과 TTA stability 로선택
- 선택된 expert 의 local 예측을 global label 로변환

OOD 학습재정의

기존 OE gate 의한계

기존 negative 는같은데이터셋내부의 non-owning class 였다. 따라서엄밀한 open-set OOD 라기 보다 **owning class vs not** 에가까웠다.

수정된방향

ImOOD 에서 TinyImages80M 을 auxiliary OOD training data 로쓰는위치에대응하여, IDS 실험에서는 feature-aligned 외부트래픽데이터셋을 OE gate negative 로추가한다.

역할	이미지 OOD 예시	IDS 실험대응
ID train/test	CIFAR/ImageNet	CIC-IDS2017
Auxiliary OOD train	TinyImages80M	CIC2018 train split
SC-OOD eval	SVHN/LSUN/Places	CIC2018 test split 또는다른 IDS

OOD 데이터준비

새준비스크립트

- data/prepare_external_ood.py
- ID 데이터셋 feature schema 를기준으로 source OOD feature 를재정렬
- CICFlowMeter 2017/2018 컬럼명차이를 alias rule 로보정
- CIC2017 기준 CIC2018 feature alignment: 70/70 matched 확인

생성예시

```
python src/prepare_external_ood.py \  
--id-data data/cic2017_proc.pkl \  
--source-data data/cic2018_proc.pkl \  
--out data/cic2018_ood_for_cic2017.pkl \  
--max-samples 500000
```

Expert 별 Threshold Sweep

- 기존방식: 모든 expert 가같은 threshold_quantile 사용
- 문제: DoS/Scan 은낮은 threshold 가유리하지만, WebBot/Rare 는낮추면 precision 이크게 붕괴
- 수정: validation split 에서 expert 마다 threshold 후보를 sweep

목적함수식관

$$\text{score} = \text{owned accept} - \lambda_b \cdot \text{benign accept} - \lambda_o \cdot \text{non-owned attack accept}$$

저장파일

- expert_threshold_sweep.csv: 모든후보 threshold 결과
- expert_threshold_selected.csv: expert 별최종선택 threshold

SC-OOD Accept-rate 평가

- external_ood_data: gate 학습에들어가는 auxiliary OOD
- sc_ood_data: 학습후 accept/reject 성능만보는평가용 OOD
- 같은파일을둘다쓰면 sanity check 이고, 논문식평가는 train/test 또는 dataset 분리가필요하다.

파일	해석
sc_ood_accept_summary.csv	전체 OOD all-reject / any-accept
sc_ood_expert_accept.csv	expert 별 OOD accept, selected, margin 분포

결과파일해석체계

파일	주요컬럼	용도
run_summary.csv	macro-F1, all-reject, threshold	실험전체요약
bottleneck_by_class.csv	primary_bottleneck	class 별병목식별
expert_summary.csv	owned/benign/non-owned accept	expert 단위 gate 해석
activation_matrix.csv	class 별 expert accept/selected	상세 activation 확인
selection_reason.csv	all_reject/only_accept/tiebreak	TTA 선택개입여부

핵심판독법

- gate_reject: threshold 가너무보수적
- local_classifier: expert 는맞게선택됐지만내부분류실패
- benign_false_accept: threshold 가너무느슨하거나 OOD gate 약함

실험명령예시

1 단계: CIC2018 OOD 준비

```
python src/prepare_external_ood.py \  
  --id-data data/cic2017_proc.pkl \  
  --source-data data/cic2018_proc.pkl \  
  --out data/cic2018_ood_for_cic2017.pkl \  
  --max-samples 500000
```

2 단계: Expert threshold sweep + auxiliary OOD 학습

```
python src/code_ood_tta.py \  
  --data data/cic2017_proc.pkl \  
  --ood_gate oe \  
  --threshold_mode expert_sweep \  
  --external_ood_data data/cic2018_ood_train_for_cic2017.pkl \  
  --sc_ood_data data/cic2018_ood_test_for_cic2017.pkl
```

현재까지의 결론

- 기존 $q=0.05$ 결과의 주된 성능 하락은 TTA 가 아니라 gate reject 였다.
- $q=0.01$ 은 attack recall 을 회복하지만, $q=0.001$ 은 WebBot/Rare precision 붕괴를 유발했다.
- 따라서 공통 threshold 가 아니라 expert 별 threshold 가 필요하다.
- OOD 학습도 in-dataset non-owning class 만으로는 부족하므로 external auxiliary OOD 를 negative 로 추가했다.
- 앞으로는 ID 성능, SC-OOD reject, class 별 병목을 동시에 보고 개선해야 한다.

다음실험체크리스트

- ① CIC2018 OOD 를 train/test artifact 로분리
- ② expert_sweep + external_ood_data run 실행
- ③ run_summary.csv 에서 macro-F1 과 all-reject 확인
- ④ expert_threshold_selected.csv 에서 expert 별 threshold 확인
- ⑤ sc_ood_accept_summary.csv 에서 SC-OOD reject 확인
- ⑥ WebBot/Rare 가 OOD sink 가되는지 sc_ood_expert_accept.csv 로확인